

浅谈 PCA 和 SVD

evilayuria *

2026 年 4 月 16 日

这是一篇介绍 PCA（principal component analysis，主成分分析）和 SVD（singular value decomposition，奇异值分解）的短文，旨在推导这方面的一系列重要结论，并以一种比较系统的视角分析人们需要这些知识的原因。本文使用 Gemini 进行辅助创作，并借鉴了大量网上公开的线性代数讲义的内容。

本文涉及内容对应中国人民大学信息学院 2025-2026 学年《高等代数 II（计算机类）》的第 9, 10, 11, 12 讲（当然，也适用于高瓴人工智能学院的同名课程）。

本作品采用 Creative Commons “署名 4.0 国际”许可协议进行许可。



*WeChat: autoLambda8080, Email: lqwql4x@gmail.com

目录

1 矩阵相似对角化	3
2 谱定理	4
3 矩阵范数	6
4 矩阵近似的目标和困难	8
5 从矩阵近似角度导出的主成分分析	9
6 从数据逼近角度导出的主成分分析 I	10
7 矩阵的迹	12
8 从数据逼近角度导出的主成分分析 II	14
9 数据中心化处理与样本协方差矩阵	17
10 从随机向量角度导出的主成分分析	18
11 方差的有偏估计和无偏估计	20
12 整体方差和方差解释比例	21
13 奇异值分解	22
14 截断奇异值分解与主成分分析	24
15 四个子空间与奇异值分解	27
16 奇异值分解的几何解释	29
17 结语	31

1 矩阵相似对角化

在数域 $\mathbb{R}$ 内, 对 n 阶方阵 A , 称 A 是可相似对角化的, 当且仅当存在可逆矩阵 P 和对角矩阵 D , 使得

$$P^{-1}AP = D.$$

不是所有的方阵 A 都是可相似对角化的。我们指出, n 阶方阵 A 可相似对角化, 当且仅当 A 拥有 n 个线性无关的特征向量。下面是对这个定理的证明。

先证明充分性。已知 A 具有 n 个线性无关的特征向量 $\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_n$, 即

$$A\mathbf{x}_i = \lambda_i\mathbf{x}_i, \quad \forall i = 1, 2, \dots, n.$$

从而可以写成矩阵乘法的形式

$$\begin{aligned} A \begin{pmatrix} \mathbf{x}_1 & \mathbf{x}_2 & \cdots & \mathbf{x}_n \end{pmatrix} &= \begin{pmatrix} \lambda_1\mathbf{x}_1 & \lambda_2\mathbf{x}_2 & \cdots & \lambda_n\mathbf{x}_n \end{pmatrix}, \\ &= \begin{pmatrix} \mathbf{x}_1 & \mathbf{x}_2 & \cdots & \mathbf{x}_n \end{pmatrix} \begin{pmatrix} \lambda_1 & 0 & \cdots & 0 \\ 0 & \lambda_2 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & \lambda_n \end{pmatrix}. \end{aligned}$$

不妨记

$$P = \begin{pmatrix} \mathbf{x}_1 & \mathbf{x}_2 & \cdots & \mathbf{x}_n \end{pmatrix}, \quad \Lambda = \begin{pmatrix} \lambda_1 & 0 & \cdots & 0 \\ 0 & \lambda_2 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & \lambda_n \end{pmatrix},$$

上式即为 $AP = P\Lambda$, 由于 $\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_n$ 线性无关, 从而由其作列向量组成的方阵 P 可逆, 变形后有

$$A = P\Lambda P^{-1} \iff P^{-1}AP = \Lambda.$$

再证明必要性. 设若存在可逆矩阵 P 和对角矩阵 D 满足 $P^{-1}AP = D$, 左乘 P 得到

$$\begin{aligned} AP = PD \iff A \begin{pmatrix} \mathbf{p}_1 & \mathbf{p}_2 & \cdots & \mathbf{p}_n \end{pmatrix} &= \begin{pmatrix} \mathbf{p}_1 & \mathbf{p}_2 & \cdots & \mathbf{p}_n \end{pmatrix} \begin{pmatrix} d_1 & 0 & \cdots & 0 \\ 0 & d_2 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & d_n \end{pmatrix}, \\ &= \begin{pmatrix} d_1\mathbf{p}_1 & d_2\mathbf{p}_2 & \cdots & d_n\mathbf{p}_n \end{pmatrix}. \end{aligned}$$

对比每列得到 $A\mathbf{p}_i = d_i\mathbf{p}_i$, 从而 P 的每个列向量 $\mathbf{p}_i$ 均为 A 的特征值 d_i 对应下的特征向量, 又由 P 可逆见 $\mathbf{p}_i$ 线性无关。证明完毕。

2 谱定理

上一节我们讨论的 A 是一般的方阵。如果加强 A 为对称矩阵, 则存在正交矩阵 Q 使得

$$A = Q\Lambda Q^\top, \quad \Lambda = \text{diag}(\lambda_1, \lambda_2, \dots, \lambda_n).$$

其中 Q 的列向量为 A 的特征向量, 即实对称矩阵必定可以正交对角化。该结论即为谱定理。

接下来开始证明谱定理。

Lemma. 实对称矩阵的特征值均为实数。

设 A 是 n 阶实对称矩阵, 解特征方程 $\det(A - \lambda I) = 0$, 由代数基本定理可保证得到 n 个特征值

$$\lambda_1, \lambda_2, \dots, \lambda_n,$$

其中可能存在重根, 这里各 λ_i 尚不能保证是实数。

设 $\lambda = a + bi$ 是一个特征值, 其中 $a, b \in \mathbb{R}$, $i = \sqrt{-1}$ 。其对应了一个非零的 (复) 特征向量 $\mathbf{x}$, 由 $A\mathbf{x} = \lambda\mathbf{x}$ 可得

$$A\mathbf{x} = \lambda\mathbf{x} \implies A\bar{\mathbf{x}} = \bar{\lambda}\bar{\mathbf{x}}.$$

其中 $\bar{\mathbf{x}}$ 是 $\mathbf{x}$ 的共轭向量, $\bar{\lambda}$ 是 λ 的共轭复数。对上式再取转置得到

$$\bar{\mathbf{x}}^\top A^\top = \bar{\mathbf{x}}^\top \bar{\lambda}, \quad A = A^\top \implies \bar{\mathbf{x}}^\top A = \bar{\mathbf{x}}^\top \bar{\lambda}.$$

上式右乘 $\mathbf{x}$ 得到

$$\bar{\mathbf{x}}^\top A\mathbf{x} = \bar{\mathbf{x}}^\top \bar{\lambda}\mathbf{x}.$$

对 $A\mathbf{x} = \lambda\mathbf{x}$, 左乘 $\bar{\mathbf{x}}^\top$ 得到

$$\bar{\mathbf{x}}^\top A\mathbf{x} = \bar{\mathbf{x}}^\top \lambda\mathbf{x}.$$

从而

$$\begin{cases} \bar{\mathbf{x}}^\top A\mathbf{x} = \bar{\mathbf{x}}^\top \bar{\lambda}\mathbf{x} \\ \bar{\mathbf{x}}^\top A\mathbf{x} = \bar{\mathbf{x}}^\top \lambda\mathbf{x} \end{cases} \iff \bar{\mathbf{x}}^\top \bar{\lambda}\mathbf{x} = \bar{\mathbf{x}}^\top \lambda\mathbf{x} \iff (\bar{\lambda} - \lambda) \bar{\mathbf{x}}^\top \mathbf{x} = 0.$$

由于

$$\bar{\mathbf{x}}^\top \mathbf{x} = \sum_{j=1}^n \bar{x}_j x_j = \sum_{j=1}^n (a_j - b_j i)(a_j + b_j i) = \sum_{j=1}^n (a_j^2 + b_j^2) > 0,$$

因此 $\bar{\lambda} - \lambda = 0$, 即 λ 是实数。证明完毕。

既然特征值是实数, 那么特征向量也是实向量。接下来证明原定理

Theorem. 实对称矩阵可以正交对角化。

施数学归纳法, 易见 $n = 1$ 时成立。假定当 $n = k - 1$ 时结论成立, 即 $(k - 1)$ 阶的实对称矩阵可以正交对角化, 下面证明当 $n = k$ 时结论也成立。

取 k 阶实对称矩阵 A , 由上一个引理可知 A 至少有一个实特征值 λ_1 , 设 $\mathbf{v}_1$ 是 λ_1 对应的特征向量, 即 $A\mathbf{v}_1 = \lambda_1\mathbf{v}_1$ 。不妨假设 $\mathbf{v}_1$ 已经被单位化了, 即 $\|\mathbf{v}_1\|_2 = 1$ 。

这里 $\mathbf{v}_1 \in \mathbb{R}^k$, 必然存在 $(k-1)$ 个单位向量 $\mathbf{w}_2, \mathbf{w}_3, \dots, \mathbf{w}_k$, 使得 $\mathbf{v}_1, \mathbf{w}_2, \dots, \mathbf{w}_k$ 线性无关且两两正交, 即

$$\text{span}\{\mathbf{v}_1, \mathbf{w}_2, \dots, \mathbf{w}_k\} = \mathbb{R}^k.$$

将这些向量作为列向量构造正交矩阵

$$P_1 = \begin{pmatrix} \mathbf{v}_1 & \mathbf{w}_2 & \cdots & \mathbf{w}_k \end{pmatrix}, \quad P_1^\top P_1 = I.$$

这里的存在性由 Gram - Schmidt 正交化过程保证, 并且这些向量 $\mathbf{w}_i$ 未必是 A 的特征向量。计算 $P_1^\top A P_1$ 即

$$\begin{aligned} P_1^\top A P_1 &= \begin{pmatrix} \mathbf{v}_1^\top \\ \mathbf{w}_2^\top \\ \vdots \\ \mathbf{w}_k^\top \end{pmatrix} A \begin{pmatrix} \mathbf{v}_1 & \mathbf{w}_2 & \cdots & \mathbf{w}_k \end{pmatrix} = \begin{pmatrix} \mathbf{v}_1^\top \\ \mathbf{w}_2^\top \\ \vdots \\ \mathbf{w}_k^\top \end{pmatrix} \begin{pmatrix} A\mathbf{v}_1 & A\mathbf{w}_2 & \cdots & A\mathbf{w}_k \end{pmatrix}, \\ &= \begin{pmatrix} \mathbf{v}_1^\top \\ \mathbf{w}_2^\top \\ \vdots \\ \mathbf{w}_k^\top \end{pmatrix} \begin{pmatrix} \lambda_1 \mathbf{v}_1 & A\mathbf{w}_2 & \cdots & A\mathbf{w}_k \end{pmatrix} = \begin{pmatrix} \lambda_1 \mathbf{v}_1^\top \mathbf{v}_1 & \mathbf{v}_1^\top A\mathbf{w}_2 & \cdots & \mathbf{v}_1^\top A\mathbf{w}_k \\ \lambda_1 \mathbf{w}_2^\top \mathbf{v}_1 & \mathbf{w}_2^\top A\mathbf{w}_2 & \cdots & \mathbf{w}_2^\top A\mathbf{w}_k \\ \vdots & \vdots & \ddots & \vdots \\ \lambda_1 \mathbf{w}_k^\top \mathbf{v}_1 & \mathbf{w}_k^\top A\mathbf{w}_2 & \cdots & \mathbf{w}_k^\top A\mathbf{w}_k \end{pmatrix}, \\ &= \begin{pmatrix} \lambda_1 & * \\ 0 & A_1 \end{pmatrix}. \end{aligned}$$

由于 $P_1^\top A P_1$ 是对称矩阵, 因此

$$P_1^\top A P_1 = \begin{pmatrix} \lambda_1 & * \\ 0 & A_1 \end{pmatrix} = \begin{pmatrix} \lambda_1 & 0 \\ 0 & A_1 \end{pmatrix}, \quad A_1 = A_1^\top.$$

由于 A_1 是 $(k-1)$ 阶的实对称矩阵, 根据归纳假设, 存在正交矩阵 Q 使得

$$Q^\top A_1 Q = D, \quad D = \text{diag}(\lambda_2, \lambda_3, \dots, \lambda_k)$$

从而记

$$P_2 = \begin{pmatrix} 1 & 0 \\ 0 & Q \end{pmatrix}, \quad P = P_1 P_2,$$

于是

$$P^\top A P = P_2^\top P_1^\top A P_1 P_2 = \begin{pmatrix} \lambda_1 & 0 \\ 0 & D \end{pmatrix} = \text{diag}(\lambda_1, \lambda_2, \dots, \lambda_k).$$

证明完毕。实对称矩阵可以正交对角化的结论非常重要, 后续我们会在多个地方用到它。

3 矩阵范数

想要记录一个 $m \times n$ 的矩阵 A ，需要记录 mn 个数。有时我们希望节约一点空间，利用较少的信息表示一个近似的矩阵 A' ，使得 A' 与 A 尽可能接近。

为了衡量矩阵之间的接近程度，我们引入矩阵范数的概念。

称函数 $\|\cdot\| : \mathbb{R}^{m \times n} \rightarrow [0, +\infty)$ 为矩阵范数，当且仅当其满足以下条件：

- 严格正定性。对任意 $A \in \mathbb{R}^{m \times n}$ ，都有 $\|A\| \geq 0$ ，并且等号成立当且仅当 $A = 0$ 。
- 线性性。对任意 $A \in \mathbb{R}^{m \times n}, a \in \mathbb{R}$ ，都有 $\|aA\| = |a| \cdot \|A\|$ 。
- 三角不等式。对任意 $A, B \in \mathbb{R}^{m \times n}$ ，都有 $\|A + B\| \leq \|A\| + \|B\|$ 。

矩阵范数有很多种，下文中我们使用谱范数进行讨论。对任意 $A \in \mathbb{R}^{m \times n}$ ，定义

$$\|A\|_2 = \sup_{\mathbf{x} \in \mathbb{R}^n, \mathbf{x} \neq 0} \frac{\|A\mathbf{x}\|_2}{\|\mathbf{x}\|_2} = \sup_{\|\mathbf{x}\|_2=1} \|A\mathbf{x}\|_2.$$

其中第二个等号利用了矩阵范数的线性性。可以看出，谱范数 $\|A\|_2$ 衡量了矩阵 A 作为线性变换的“放大能力”，即 A 将单位球面映射成一个椭球面， $\|A\|_2$ 就是这个椭球面长轴的长度。

为了求解 $\|A\|_2$ ，我们考虑

$$\begin{aligned} \|A\|_2^2 &= \sup_{\|\mathbf{x}\|_2=1} \|A\mathbf{x}\|_2^2 = \sup_{\|\mathbf{x}\|_2=1} (A\mathbf{x})^\top (A\mathbf{x}), \\ &= \sup_{\|\mathbf{x}\|_2=1} \mathbf{x}^\top (A^\top A) \mathbf{x}. \end{aligned}$$

$A^\top A$ 是一个半正定矩阵，存在正交矩阵 Q 和对角矩阵 Λ 使得

$$A^\top A = Q^\top \Lambda Q, \quad \Lambda = \text{diag}(\sigma_1, \sigma_2, \dots, \sigma_n), \quad \sigma_1 \geq \sigma_2 \geq \dots \geq \sigma_n \geq 0.$$

此处 σ_i 是 $A^\top A$ 的特征值。代回得到

$$\begin{aligned} \|A\|_2^2 &= \sup_{\|\mathbf{x}\|_2=1} \mathbf{x}^\top (A^\top A) \mathbf{x}, \\ &= \sup_{\|\mathbf{x}\|_2=1} \mathbf{x}^\top (Q^\top \Lambda Q) \mathbf{x}, \\ &= \sup_{\|\mathbf{x}\|_2=1} (Q\mathbf{x})^\top \Lambda (Q\mathbf{x}). \end{aligned}$$

记向量

$$\mathbf{y} = Q\mathbf{x} = (y_1, y_2, \dots, y_n),$$

由于 Q 是正交矩阵， $\mathbf{y}$ 仍然满足

$$\|\mathbf{y}\|_2 = \mathbf{y}^\top \mathbf{y} = \mathbf{x}^\top Q^\top Q \mathbf{x} = \mathbf{x}^\top \mathbf{x} = \|\mathbf{x}\|_2 = 1,$$

且 $\mathbf{y} = Q\mathbf{x}$ 是一一映射，因此

$$\begin{aligned}\|A\|_2^2 &= \sup_{\|\mathbf{y}\|_2=1} \mathbf{y}^\top \Lambda \mathbf{y}, \\ &= \sup_{\|\mathbf{y}\|_2=1} \sum_{i=1}^n \sigma_i y_i^2 = \max_{1 \leq i \leq n} \sigma_i.\end{aligned}$$

最后一个等号利用了 $\sigma_i \geq 0$ 以及 $\|\mathbf{y}\|_2^2 = \sum_{i=1}^n y_i^2 = 1$ 。于是

$$\|A\|_2 = \sqrt{\max_{1 \leq i \leq n} \sigma_i}.$$

特别地，对实对称矩阵 A ，其特征值 λ_i 均为实数，且 $A^\top A = A^2$ 的特征值为 λ_i^2 ，因此

$$\|A\|_2 = \max_{1 \leq i \leq n} |\lambda_i|.$$

若无特殊说明，后文提及矩阵范数时均指矩阵谱范数。

4 矩阵近似的目标和困难

前面提到我们需要记录一个 $m \times n$ 的矩阵 A ，需要记录 mn 个数。引入矩阵范数的概念，可以衡量矩阵之间的“接近”程度，从而实现矩阵的近似表示。

对 n 阶方阵 A 和构造出的近似矩阵 A' ，我们希望：

- A' 的信息量足够小，即 A' 需要记录的数足够少。这里记录的信息不一定要记录 A' 本身，而是它的某种表示方式；
- A' 与 A 足够接近，即 $\|A - A'\|_2$ 足够小。

两个目标很难同时取到最优，因为 A' 的信息量越小， A' 与 A 的误差就越大；反之亦然。因此我们需要在两者之间进行权衡。

刚刚介绍的矩阵相似对角化给出了表示矩阵 A 的另一种方式：记录可逆矩阵 P 和对角矩阵 D ，即有 $A' = PDP^{-1} = A$ 。

- 信息量 P, P^{-1}, D ，需要记录 $n^2 + n^2 + n = 2n^2 + n$ 个数。记录 P^{-1} 的原因是计算逆矩阵的开销远大于记录逆矩阵本身的开销。
- 误差 $A - A'$ ，其范数 $\|A - A'\|_2 = \|O\|_2 = 0$ 。

由此可见，引入矩阵相似对角化既不能减少需要记录的信息量，又会在将 A 从方阵推广到一般矩阵时失效。因此我们需要寻找其他的矩阵近似方法。

5 从矩阵近似角度导出的主成分分析

主成分分析（PCA）是一种常用的矩阵近似方法，旨在找到一个低秩矩阵 A' ，使得 A' 与 A 足够接近，并且 A' 的信息量足够小。

对 n 阶实对称矩阵 A ，设 A 的特征值为 $\lambda_1, \lambda_2, \dots, \lambda_n$ ，且 $|\lambda_1| \geq |\lambda_2| \geq \dots \geq |\lambda_n|$ 。则存在正交矩阵 Q 和对角矩阵 Λ 使得

$$A = Q\Lambda Q^\top, \quad \Lambda = \text{diag}(\lambda_1, \lambda_2, \dots, \lambda_n).$$

设 $\mathbf{q}_i$ 是 Q 的列向量，则

$$A = \sum_{i=1}^n \lambda_i \mathbf{q}_i \mathbf{q}_i^\top.$$

主成分分析的核心思想就发源于此：直觉上认为，特征值 λ_i 的绝对值越大，对矩阵 A 的贡献就越大，因此我们可以保留前 k 个特征值（假定均非零）及其对应的特征向量，构造出一个秩为 k 的近似矩阵

$$A' = \sum_{i=1}^k \lambda_i \mathbf{q}_i \mathbf{q}_i^\top.$$

基于前面提到的两个角度评估近似矩阵 A' ：

- 信息量。对 $1 \leq i \leq k$ ，记录 $\lambda_i, \mathbf{q}_i$ ，总共需要记录 $k(n+1)$ 个数。
- 误差。对误差矩阵 $E = A - A' = \sum_{i=k+1}^n \lambda_i \mathbf{q}_i \mathbf{q}_i^\top$ ，显然这是个对称矩阵，右乘 $\mathbf{q}_i$ 得到
 - 当 $1 \leq i \leq k$ 时， $E\mathbf{q}_i = \sum_{j=k+1}^n \lambda_j \mathbf{q}_j (\mathbf{q}_j^\top \mathbf{q}_i) = 0$ ，这是因为 $\mathbf{q}_i$ 和 $\mathbf{q}_j$ 是正交的，从而 $\mathbf{q}_i$ 是误差矩阵 E 的特征向量，对应特征值为 0；
 - 当 $k+1 \leq i \leq n$ 时， $E\mathbf{q}_i = \sum_{j=k+1}^n \lambda_j \mathbf{q}_j (\mathbf{q}_j^\top \mathbf{q}_i) = \lambda_i \mathbf{q}_i$ ，从而 $\mathbf{q}_i$ 是误差矩阵 E 的特征向量，对应特征值为 λ_i 。

因此误差矩阵 E 的特征值为

$$\underbrace{0, 0, \dots, 0}_k, \lambda_{k+1}, \lambda_{k+2}, \dots, \lambda_n,$$

从而

$$\|A - A'\|_2 = \|E\|_2 = \max_{k+1 \leq i \leq n} |\lambda_i| = |\lambda_{k+1}|.$$

6 从数据逼近角度导出的主成分分析 I

让我们暂时忘掉矩阵近似吧，取而代之的是一堆 d 维的数据点 $\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_n$ 。现在的任务是，由于数据点的维度 d 可能很大，我们希望找到一个低维空间，使得数据点在这个空间中的投影能够尽可能地保留原始数据点的信息。

原始数据点是 d 维的，因此有一组 d 维的标准正交基 $\mathbf{z}_1, \mathbf{z}_2, \dots, \mathbf{z}_d$ ，使得

$$\begin{aligned}\|\mathbf{z}_i\| &= \mathbf{z}_i^\top \mathbf{z}_i = 1, \quad \forall i = 1, 2, \dots, d \\ \mathbf{z}_i^\top \mathbf{z}_j &= 0, \quad \forall 1 \leq i < j \leq d \\ \mathbf{x}_i &= \sum_{j=1}^d w_{ij} \mathbf{z}_j, \quad \forall i = 1, 2, \dots, n.\end{aligned}$$

现在希望减少基方向的个数，保留 $d' < d$ 个方向，即

$$\begin{aligned}Z &= \begin{pmatrix} \mathbf{z}_1 & \mathbf{z}_2 & \cdots & \mathbf{z}_{d'} \end{pmatrix}, \\ \tilde{\mathbf{x}}_i &= \sum_{j=1}^{d'} w_{ij} \mathbf{z}_j = Z \mathbf{w}_i, \quad \forall i = 1, 2, \dots, n.\end{aligned}$$

其中 $\mathbf{w}_i = (w_{i1}, w_{i2}, \dots, w_{id'})$ ，并且 W 是 $d' \times n$ 维的矩阵， Z 是 $d \times d'$ 维的矩阵，满足

$$Z^\top Z = I.$$

我们希望最小化

$$\min_{Z, W} \frac{1}{n} \sum_{i=1}^n \|\mathbf{x}_i - \tilde{\mathbf{x}}_i\|^2$$

对式子进行变形得到

$$\begin{aligned}\frac{1}{n} \sum_{i=1}^n \|\mathbf{x}_i - \tilde{\mathbf{x}}_i\|^2 &= \frac{1}{n} \sum_{i=1}^n \left\| \mathbf{x}_i - \sum_{j=1}^{d'} w_{ij} \mathbf{z}_j \right\|^2, \\ &= \frac{1}{n} \sum_{i=1}^n \left(\mathbf{x}_i - \sum_{j=1}^{d'} w_{ij} \mathbf{z}_j \right)^\top \left(\mathbf{x}_i - \sum_{k=1}^{d'} w_{ik} \mathbf{z}_k \right), \\ &= \frac{1}{n} \sum_{i=1}^n (\mathbf{x}_i - Z \mathbf{w}_i)^\top (\mathbf{x}_i - Z \mathbf{w}_i), \\ &= \frac{1}{n} \sum_{i=1}^n (\mathbf{x}_i^\top - \mathbf{w}_i^\top Z^\top) (\mathbf{x}_i - Z \mathbf{w}_i), \\ &= \frac{1}{n} \sum_{i=1}^n (\mathbf{x}_i^\top \mathbf{x}_i - \mathbf{x}_i^\top Z \mathbf{w}_i - \mathbf{w}_i^\top Z^\top \mathbf{x}_i + \mathbf{w}_i^\top Z^\top Z \mathbf{w}_i).\end{aligned}$$

注意到 $\mathbf{x}_i^\top Z \mathbf{w}_i = \mathbf{w}_i^\top Z^\top \mathbf{x}_i$ ，并且 $Z^\top Z = I$ ，因此上式可以简化为

$$\begin{aligned}\frac{1}{n} \sum_{i=1}^n \|\mathbf{x}_i - \tilde{\mathbf{x}}_i\|^2 &= \frac{1}{n} \sum_{i=1}^n (\mathbf{x}_i^\top \mathbf{x}_i - 2 \mathbf{w}_i^\top Z^\top \mathbf{x}_i + \mathbf{w}_i^\top Z^\top Z \mathbf{w}_i), \\ &= \frac{1}{n} \sum_{i=1}^n \mathbf{x}_i^\top \mathbf{x}_i - \frac{2}{n} \sum_{i=1}^n \mathbf{w}_i^\top Z^\top \mathbf{x}_i + \frac{1}{n} \sum_{i=1}^n \mathbf{w}_i^\top \mathbf{w}_i.\end{aligned}$$

对每个 $i = 1, 2, \dots, n$ 分别讨论

$$f(Z, \mathbf{w}_i) \triangleq \|\mathbf{x}_i - \tilde{\mathbf{x}}_i\|^2 = \mathbf{x}_i^\top \mathbf{x}_i - 2\mathbf{w}_i^\top Z^\top \mathbf{x}_i + \mathbf{w}_i^\top \mathbf{w}_i.$$

对 $\mathbf{w}_i$ 求偏导并令其为零, 得到

$$\begin{aligned} \frac{\partial f(Z, \mathbf{w}_i)}{\partial \mathbf{w}_i} &= -2Z^\top \mathbf{x}_i + 2\mathbf{w}_i = 0, \\ \implies \mathbf{w}_i &= Z^\top \mathbf{x}_i \implies W = Z^\top X. \end{aligned}$$

或者对 $\mathbf{w}_i$ 的每一维分别进行考虑, 能够发现各维取值之间是相互独立的, 即

$$f(Z, w_{i,1}, w_{i,2}, \dots, w_{i,d'}) = \sum_{j=1}^d x_{i,j}^2 - 2 \sum_{j=1}^{d'} w_{i,j} (Z^\top \mathbf{x}_i)_j + \sum_{j=1}^{d'} w_{i,j}^2.$$

对每个 $j = 1, 2, \dots, d'$, f 均可视为关于 $w_{i,j}$ 的二次函数, 二次项系数为 $1 > 0$, 从而在 $x = -b/2a$ 处取最小值

$$w_{i,j} = -\frac{-2(Z^\top \mathbf{x}_i)_j}{2 \cdot 1} = (Z^\top \mathbf{x}_i)_j \iff \mathbf{w}_i = Z^\top \mathbf{x}_i \iff W = Z^\top X.$$

思考 $W = Z^\top X$ 意味着什么。考虑数据点 $\mathbf{x}_i$ 及其近似 $\tilde{\mathbf{x}}_i$ 有

$$\tilde{\mathbf{x}}_i = Z\mathbf{w}_i = ZZ^\top \mathbf{x}_i, \quad \forall i = 1, 2, \dots, n.$$

注意到

$$(ZZ^\top)^2 = Z(Z^\top Z)Z^\top = ZZ^\top, \quad (ZZ^\top)^\top = ZZ^\top.$$

从而 $ZZ^\top$ 是一个投影矩阵, 它将 $\mathbf{x}_i$ 投影至由 Z 的列向量 $\mathbf{z}_1, \mathbf{z}_2, \dots, \mathbf{z}_{d'}$ 张成的子空间上, 也就是说, $\mathbf{w}_i$ 的每个维度 $w_{i,j}$ 就是 $\mathbf{x}_i$ 在 $\mathbf{z}_j$ 方向上的投影长度。

请注意, $ZZ^\top$ 是一个很重要的矩阵, 我们稍后还会讨论它。接下来将 $\mathbf{w}_i$ 的表达式代回原式, 得到关于 Z 的表达式

$$\begin{aligned} g(Z) &= \frac{1}{n} \sum_{i=1}^n \mathbf{x}_i^\top \mathbf{x}_i - \frac{2}{n} \sum_{i=1}^n \mathbf{w}_i^\top Z^\top \mathbf{x}_i + \frac{1}{n} \sum_{i=1}^n \mathbf{w}_i^\top \mathbf{w}_i, \quad \mathbf{w}_i = Z^\top \mathbf{x}_i, \\ &= \frac{1}{n} \sum_{i=1}^n \mathbf{x}_i^\top \mathbf{x}_i - \frac{2}{n} \sum_{i=1}^n \mathbf{x}_i^\top Z Z^\top \mathbf{x}_i + \frac{1}{n} \sum_{i=1}^n \mathbf{x}_i^\top Z Z^\top \mathbf{x}_i. \\ &= \frac{1}{n} \sum_{i=1}^n \mathbf{x}_i^\top \mathbf{x}_i - \frac{1}{n} \sum_{i=1}^n \mathbf{x}_i^\top Z Z^\top \mathbf{x}_i. \end{aligned}$$

总结一下我们现在的结论, 即

$$\begin{aligned} \min_{Z, W} \frac{1}{n} \sum_{i=1}^n \|\mathbf{x}_i - \tilde{\mathbf{x}}_i\|^2 &\stackrel{W=Z^\top X}{=} \min_Z \left(\frac{1}{n} \sum_{i=1}^n \mathbf{x}_i^\top \mathbf{x}_i - \frac{1}{n} \sum_{i=1}^n \mathbf{x}_i^\top Z Z^\top \mathbf{x}_i \right), \\ &\iff \max_Z \frac{1}{n} \sum_{i=1}^n \mathbf{x}_i^\top Z Z^\top \mathbf{x}_i = \max_Z \frac{1}{n} \sum_{i=1}^n \|Z^\top \mathbf{x}_i\|^2. \end{aligned}$$

稍后我们再回来看这个式子——先介绍一个非常重要的工具。

7 矩阵的迹

矩阵的迹是一个重要的概念，定义为方阵 A 的主对角线元素之和，即

$$\operatorname{tr}(A) = \sum_{i=1}^n a_{ii}.$$

由矩阵的迹定义可以推出以下结论：

1. 对任意 n 阶方阵 A 和 B ，都有 $\operatorname{tr}(A+B) = \operatorname{tr}(A) + \operatorname{tr}(B)$ 。
2. 对任意 $n \times m$ 的矩阵 A 和 $m \times n$ 的矩阵 B ，都有 $\operatorname{tr}(AB) = \operatorname{tr}(BA)$ 。
3. 对任意 n 阶方阵 A 和可逆矩阵 P ，都有 $\operatorname{tr}(P^{-1}AP) = \operatorname{tr}(A)$ 。
4. 对任意 n 阶方阵 A ， $\operatorname{tr}(A) = \sum_{i=1}^n \lambda_i$ ，其中 λ_i 是 A 的特征值。

结论 1 是平凡的。对结论 2，证明考虑矩阵乘法的定义：

$$\operatorname{tr}(AB) = \sum_{i=1}^n (AB)_{ii} = \boxed{\sum_{i=1}^n \sum_{j=1}^m a_{ij} b_{ji} = \sum_{j=1}^m \sum_{i=1}^n b_{ji} a_{ij}} = \sum_{j=1}^m (BA)_{jj} = \operatorname{tr}(BA).$$

其中加框部分的等式利用了求和次序的交换。

结论 2 非常重要。一种针对结论 2 的解释是矩阵乘法对矩阵的迹满足交换律，但实际上并非如此。其真正含义是，**矩阵乘法对矩阵的迹满足循环律**，即 A, B, C 是分别是任意的 $n \times m$ 、 $m \times n$ 、 $n \times n$ 阶矩阵，则 $\operatorname{tr}(ABC) = \operatorname{tr}(BCA) = \operatorname{tr}(CAB)$ 。证明依旧考虑矩阵乘法定义（以 $\operatorname{tr}(ABC) = \operatorname{tr}(BCA)$ 为例）：

$$\begin{aligned} \operatorname{tr}(ABC) &= \sum_{i=1}^n (ABC)_{ii} = \sum_{i=1}^n \sum_{j=1}^m a_{ij} (BC)_{ji} = \sum_{i=1}^n \sum_{j=1}^m a_{ij} \sum_{k=1}^n b_{jk} c_{ki}, \\ &= \sum_{i=1}^n \sum_{j=1}^m \sum_{k=1}^n a_{ij} b_{jk} c_{ki} = \sum_{j=1}^m \sum_{k=1}^n \sum_{i=1}^n b_{jk} c_{ki} a_{ij}, \\ &= \sum_{j=1}^m \sum_{k=1}^n b_{jk} \sum_{i=1}^n c_{ki} a_{ij} = \sum_{j=1}^m \sum_{k=1}^n b_{jk} (CA)_{kj} = \sum_{j=1}^m (BCA)_{jj} = \operatorname{tr}(BCA). \end{aligned}$$

其中第二行利用了求和次序的交换。

结论 3 可由结论 2 推出，考虑

$$\operatorname{tr}(P^{-1}AP) = \operatorname{tr}(APP^{-1}) = \operatorname{tr}(A).$$

即证毕。

结论 4 可由结论 3 推出，考虑 A 的相似对角化 $A = PDP^{-1}$ ，其中 D 是 A 的特征值构成的对角矩阵，因此

$$\operatorname{tr}(A) = \operatorname{tr}(PDP^{-1}) = \operatorname{tr}(DP^{-1}P) = \operatorname{tr}(D) = \sum_{i=1}^n \lambda_i.$$

当然这只针对 A 可相似对角化的情况, 对于更一般的情况, 利用特征多项式 $\det(\lambda I - A)$ 可以得到

$$\begin{aligned} \lambda^n - \left(\sum_{i=1}^n a_{ii} \right) \lambda^{n-1} + \cdots &= \begin{vmatrix} \lambda - a_{11} & -a_{12} & \cdots & -a_{1n} \\ -a_{21} & \lambda - a_{22} & \cdots & -a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ -a_{n1} & -a_{n2} & \cdots & \lambda - a_{nn} \end{vmatrix}, \\ &= \det(\lambda I - A) = \prod_{i=1}^n (\lambda - \lambda_i) = \lambda^n - \left(\sum_{i=1}^n \lambda_i \right) \lambda^{n-1} + \cdots. \end{aligned}$$

对比 λ^{n-1} 的系数, 从而 $\sum_{i=1}^n \lambda_i = \sum_{i=1}^n a_{ii} = \text{tr}(A)$ 。

上面式子的第一个等号利用了 Laplace 展开, 选择不同的元素展开时, 余子式贡献的 λ 项次数有所差异。若选择了非对角线元素, 得到的余子式缺失了与该元素所在行和列相关的两个 λ 项, 因此得到的 λ 项次数为 $n-2$; 若选择了对角线元素, 得到的余子式仅缺失该元素提供的 λ 项, 因此得到的 λ 项次数为 $n-1$ 。因此只有选择了对角线元素进行展开时, 才能得到 λ^{n-1} 的项, 从而得到 $\sum_{i=1}^n a_{ii}$ 的系数。

矩阵的迹就介绍到这里, 接下来我们将利用矩阵的迹来对前面得到的式子进行变形。

8 从数据逼近角度导出的主成分分析 II

我们从式子

$$\frac{1}{n} \sum_{i=1}^n \|Z^\top \mathbf{x}_i\|^2$$

出发, 接下来利用矩阵的迹来对其进行变形。

考虑一个向量 $\mathbf{a}$, 我们有

$$\|\mathbf{a}\|^2 = \mathbf{a}^\top \mathbf{a} = \underbrace{\sum_{i=1}^n a_i^2}_{\mathbb{R}^{1 \times 1}} = \text{tr} \left(\sum_{i=1}^n a_i^2 \right) = \text{tr}(\mathbf{a}^\top \mathbf{a}) = \text{tr}(\mathbf{a} \mathbf{a}^\top).$$

其中最后一个等号利用了矩阵的迹的循环律。对 $\|Z^\top \mathbf{x}_i\|^2$ 进行同样的变形, 得到

$$\|Z^\top \mathbf{x}_i\|^2 = \text{tr}(Z^\top \mathbf{x}_i \mathbf{x}_i^\top Z).$$

放入求和式内有

$$\begin{aligned} \frac{1}{n} \sum_{i=1}^n \|Z^\top \mathbf{x}_i\|^2 &= \frac{1}{n} \sum_{i=1}^n \text{tr}(Z^\top \mathbf{x}_i \mathbf{x}_i^\top Z), \\ &= \text{tr} \left(\sum_{i=1}^n \frac{1}{n} Z^\top \mathbf{x}_i \mathbf{x}_i^\top Z \right), \\ &= \text{tr} \left(Z^\top \left(\frac{1}{n} \sum_{i=1}^n \mathbf{x}_i \mathbf{x}_i^\top \right) Z \right), \\ &= \text{tr} \left(Z^\top \cdot \frac{1}{n} \cdot \begin{pmatrix} \mathbf{x}_1 & \cdots & \mathbf{x}_n \end{pmatrix} \begin{pmatrix} \mathbf{x}_1^\top \\ \vdots \\ \mathbf{x}_n^\top \end{pmatrix} Z \right), \\ &= \text{tr} \left(Z^\top \left(\frac{1}{n} X X^\top \right) Z \right). \end{aligned}$$

从而

$$\max_Z \frac{1}{n} \sum_{i=1}^n \|Z^\top \mathbf{x}_i\|^2 = \max_Z \text{tr} \left(Z^\top \left(\frac{1}{n} \sum_{i=1}^n \mathbf{x}_i \mathbf{x}_i^\top \right) Z \right) = \max_Z \text{tr} \left(Z^\top \left(\frac{1}{n} X X^\top \right) Z \right).$$

记 $\hat{\Sigma} \triangleq \frac{1}{n} X X^\top$, 则 $\hat{\Sigma}$ 是一个 $d \times d$ 的半正定矩阵, 存在正交矩阵 Q 和对角矩阵 Λ 使得

$$\hat{\Sigma} = Q \Lambda Q^\top, \quad \Lambda = \text{diag}(\lambda_1, \lambda_2, \dots, \lambda_d), \quad \lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_d \geq 0.$$

于是

$$\begin{aligned} \max_Z \text{tr}(Z^\top \hat{\Sigma} Z) &= \max_Z \text{tr}(Z^\top Q \Lambda Q^\top Z), \\ &= \max_Z \text{tr}((Q^\top Z)^\top \Lambda (Q^\top Z)). \end{aligned}$$

设 $P \triangleq Q^\top Z$, 则

$$\begin{aligned}\max_Z \operatorname{tr} \left(Z^\top \hat{\Sigma} Z \right) &= \max_Z \operatorname{tr} \left((Q^\top Z)^\top \Lambda (Q^\top Z) \right), \\ &= \max_Z \operatorname{tr} (P^\top \Lambda P).\end{aligned}$$

其中 P 是一个 $d \times d'$ 的矩阵, 且

$$P^\top P = Z^\top Q Q^\top Z = Z^\top Z = I.$$

即 P 的列向量依旧构成一组标准正交基的子集。设

$$P^\top = \begin{pmatrix} \mathbf{p}'_1 & \mathbf{p}'_2 & \cdots & \mathbf{p}'_d \end{pmatrix}$$

由矩阵乘法定义得到

$$\begin{aligned}\max_Z \operatorname{tr} (P^\top \Lambda P) &= \max_Z \operatorname{tr} \left(\begin{pmatrix} \mathbf{p}'_1 & \mathbf{p}'_2 & \cdots & \mathbf{p}'_d \end{pmatrix} \operatorname{diag}(\lambda_1, \lambda_2, \dots, \lambda_d) \begin{pmatrix} \mathbf{p}'_1{}^\top \\ \mathbf{p}'_2{}^\top \\ \vdots \\ \mathbf{p}'_d{}^\top \end{pmatrix} \right), \\ &= \max_Z \operatorname{tr} \left(\begin{pmatrix} \lambda_1 \mathbf{p}'_1 & \lambda_2 \mathbf{p}'_2 & \cdots & \lambda_d \mathbf{p}'_d \end{pmatrix} \begin{pmatrix} \mathbf{p}'_1{}^\top \\ \mathbf{p}'_2{}^\top \\ \vdots \\ \mathbf{p}'_d{}^\top \end{pmatrix} \right) = \max_Z \operatorname{tr} \left(\sum_{i=1}^d \lambda_i \mathbf{p}'_i \mathbf{p}'_i{}^\top \right), \\ &= \max_Z \sum_{i=1}^d \lambda_i \operatorname{tr} (\mathbf{p}'_i \mathbf{p}'_i{}^\top) = \max_Z \sum_{i=1}^d \lambda_i \operatorname{tr} (\mathbf{p}'_i{}^\top \mathbf{p}'_i) = \max_Z \sum_{i=1}^d \lambda_i \|\mathbf{p}'_i\|^2.\end{aligned}$$

记 $c_i \triangleq \|\mathbf{p}'_i\|^2$, 则

$$\max_Z \sum_{i=1}^d \lambda_i \|\mathbf{p}'_i\|^2 = \max_Z \sum_{i=1}^d \lambda_i c_i.$$

考虑 c_i 的一些性质

$$\sum_{i=1}^d c_i = \sum_{i=1}^d \|\mathbf{p}'_i\|^2 = \sum_{i=1}^d \sum_{j=1}^{d'} p_{ij}^2 = \sum_{j=1}^{d'} \sum_{i=1}^d p_{ij}^2 = \sum_{j=1}^{d'} 1 = d'.$$

其中倒数第二个等号利用了 P 的列向量都是单位向量的事实 (见 $P^\top P = I$)。

此外, 我们能够将 P 扩充为一组标准正交基 (只需让 Z 变为原来的 d 个向量)。扩充后的 P 每行都是单位向量, 范数为 1, 因此扩充前的 $c_i = \|\mathbf{p}'_i\|^2 \leq 1$ 。

这是一个线性规划问题: 在 $\sum_{i=1}^d c_i = d'$ 且 $0 \leq c_i \leq 1, \forall i$ 的约束下, 最大化 $\sum_{i=1}^d \lambda_i c_i$ 。由于 $\lambda_1 \geq \lambda_2 \geq \cdots \geq \lambda_d \geq 0$, 为了使目标函数最大, 我们应该让 i 越小的 c_i 尽可能大, 即让

$$c_i = \begin{cases} 1, & 1 \leq i \leq d', \\ 0, & d' + 1 \leq i \leq d. \end{cases}$$

证明考虑调整法，在此省略。因此

$$\max_Z \operatorname{tr} \left(Z^\top \hat{\Sigma} Z \right) = \sum_{i=1}^{d'} \lambda_i.$$

这时要求 P 的前 d' 行是单位向量，其余行为零向量。回忆 P 的列向量线性无关，对 P 作分块有

$$P = \begin{pmatrix} \hat{P} \\ O \end{pmatrix}, \quad \hat{P}^\top \hat{P} = \hat{P} \hat{P}^\top = I, \quad \hat{P} \in \mathbb{R}^{d' \times d'}.$$

从而反推 Z 的取值

$$P = Q^\top Z \implies Z = QP = \begin{pmatrix} Q_{d'} & * \end{pmatrix} \begin{pmatrix} \hat{P} \\ O \end{pmatrix} = Q_{d'} \hat{P} = \begin{pmatrix} \mathbf{q}_1 & \mathbf{q}_2 & \cdots & \mathbf{q}_{d'} \end{pmatrix} \hat{P}.$$

从 Z 的列向量来看， Z 的列向量是 $Q_{d'}$ 的列向量 $\mathbf{q}_1, \mathbf{q}_2, \dots, \mathbf{q}_{d'}$ 上的线性组合，再考虑 $\hat{P}$ 的可逆性，因此 Z 的列向量张成的子空间就是 $\mathbf{q}_1, \mathbf{q}_2, \dots, \mathbf{q}_{d'}$ 张成的子空间，即

$$\operatorname{span} \{ \mathbf{z}_1, \mathbf{z}_2, \dots, \mathbf{z}_{d'} \} = \operatorname{span} \{ \mathbf{q}_1, \mathbf{q}_2, \dots, \mathbf{q}_{d'} \}.$$

实践上，我们常取 $Z = Q_{d'}$ ，即取前 d' 大的特征向量作为基方向。

综上所述，我们得到了主成分分析的第二种解释：为了将子空间 V 的数据点

$$\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_n$$

在子空间 W 中进行投影，其中

$$\dim V = d > d' = \dim W,$$

并且使得投影后的数据点能够尽可能地保留原始数据点的信息，我们应该选择矩阵

$$\hat{\Sigma} = \frac{1}{n} X X^\top$$

按从大到小排序的前 d' 个特征值，它们对应的特征向量作为新的基方向，即

$$W = \operatorname{span} \{ \mathbf{q}_1, \mathbf{q}_2, \dots, \mathbf{q}_{d'} \}.$$

矩阵 $S \triangleq X X^\top$ 描述了数据点在原点的各个方向上的分布情况，当数据点中心为原点时，被称为**散度矩阵**。特征值 λ_i 描述了数据点在第 i 个特征向量 $\mathbf{q}_i$ 方向上的分布程度，特征值越大，说明数据点在该方向上的分布程度越大，因此保留该方向能够更好地保留原始数据点的信息。

这两种角度体现了 PCA 的本质，即在信息损失尽量小的前提下，找到一组最重要的正交方向，用来描述原始矩阵或原始数据中的主要结构。

9 数据中心化处理与样本协方差矩阵

现实生活中，我们的数据点通常会分布在一个点的附近，即数据点的均值

$$\bar{\mathbf{x}} = \frac{1}{n} \sum_{i=1}^n \mathbf{x}_i.$$

如果 $\|\bar{\mathbf{x}}\|$ 比较大，那么进行主成分分析时，第一主成分往往就会捕捉到 $\bar{\mathbf{x}}$ 的方向。在进行主成分分析时，我们往往关心数据点之间的差异，而非整体的分布趋势（这很容易做到！只需要计算 $\bar{\mathbf{x}}$ ）。

为了使得 PCA 能够更好地捕捉数据点之间的差异，我们对数据点进行**中心化处理**，即将每个数据点减去均值 $\bar{\mathbf{x}}$ ，得到中心化后的数据点 $\tilde{\mathbf{x}}_i = \mathbf{x}_i - \bar{\mathbf{x}}$ 。

回忆上一节的

$$\hat{\Sigma} = \frac{1}{n} X X^\top.$$

如果 X 是由中心化后的数据点 $\tilde{\mathbf{x}}_1, \tilde{\mathbf{x}}_2, \dots, \tilde{\mathbf{x}}_n$ 组成的矩阵，那么 $\hat{\Sigma}$ 被定义为样本协方差矩阵。样本协方差矩阵反映了样本数据的平均离散程度。

若没有经过中心化处理，那么散度矩阵定义为

$$S = \sum_{i=1}^n (\mathbf{x}_i - \bar{\mathbf{x}})(\mathbf{x}_i - \bar{\mathbf{x}})^\top = X X^\top - n \bar{\mathbf{x}} \bar{\mathbf{x}}^\top,$$

样本协方差矩阵定义为

$$\hat{\Sigma} = \frac{1}{n} \sum_{i=1}^n (\mathbf{x}_i - \bar{\mathbf{x}})(\mathbf{x}_i - \bar{\mathbf{x}})^\top = \frac{1}{n} X X^\top - \bar{\mathbf{x}} \bar{\mathbf{x}}^\top.$$

10 从随机向量角度导出的主成分分析

之前我们有 n 个 d 维的（已经中心化的）数据点 $\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_n$ ，对它们形成的矩阵 X ，我们构造了散度矩阵 $S = XX^\top$ 和样本协方差矩阵 $\Sigma = \frac{1}{n}XX^\top$ ，表示这 n 个具体的数据点在各个方向上的分布情况。

数据点个数 n 是有限的，因此 S 只能反映数据点在各个方向上的分布情况的一个近似。为了更好地预测数据点的特征，我们可以将数据点视为从一个随机向量 $\boldsymbol{\xi}$ 的分布中独立同分布地采样得到的，即 $\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_n$ 是 $\boldsymbol{\xi}$ 的 n 个独立同分布的样本，即 $\mathbf{x}_i$ 之间相互独立。

随机向量 $\boldsymbol{\xi}$ 的每个分量 ξ_i 都是一个随机变量，其期望为 $E[\xi_i]$ ，方差为 $\text{Var}[\xi_i]$ 。随机变量的期望满足线性性，即 $E[a\xi_i + b\xi_j + c] = aE[\xi_i] + bE[\xi_j] + c$ ，其中 a, b, c 是任意实数。随后的推导会反复使用这个性质。

一般地，方差 $\text{Var}[\xi_i]$ 定义为

$$\begin{aligned}\text{Var}[\xi_i] &= E[(\xi_i - E[\xi_i])^2] = E[\xi_i^2 - 2\xi_i E[\xi_i] + (E[\xi_i])^2], \\ &= E[\xi_i^2] - 2(E[\xi_i])^2 + (E[\xi_i])^2 = E[\xi_i^2] - (E[\xi_i])^2.\end{aligned}$$

由于数据点已经中心化，因此 $E[\xi_i] = 0$ ，从而 $\text{Var}[\xi_i] = E[\xi_i^2]$ 。

只有这些信息仍然不够充分，因为各个 ξ_i 之间不一定独立。引入协方差的概念， ξ_i 和 ξ_j 的协方差定义为

$$\text{Cov}[\xi_i, \xi_j] = E[(\xi_i - E[\xi_i])(\xi_j - E[\xi_j])] = E[\xi_i \xi_j] - E[\xi_i]E[\xi_j] = E[\xi_i \xi_j].$$

协方差反映了两个随机变量之间的关系，如果 $\text{Cov}[\xi_i, \xi_j] > 0$ ，说明 ξ_i 和 ξ_j 之间存在正相关关系；如果 $\text{Cov}[\xi_i, \xi_j] < 0$ ，说明 ξ_i 和 ξ_j 之间存在负相关关系；如果 $\text{Cov}[\xi_i, \xi_j] = 0$ ，说明 ξ_i 和 ξ_j 之间没有线性关系。

n 个随机变量 $\xi_1, \xi_2, \dots, \xi_n$ 放进协方差计算符 $\text{Cov}[\cdot, \cdot]$ 中有 n^2 种方式，对应一个 $n \times n$ 的矩阵，即协方差矩阵，记为 Σ ，定义为

$$\Sigma = \begin{pmatrix} \text{Cov}[\xi_1, \xi_1] & \text{Cov}[\xi_1, \xi_2] & \cdots & \text{Cov}[\xi_1, \xi_n] \\ \text{Cov}[\xi_2, \xi_1] & \text{Cov}[\xi_2, \xi_2] & \cdots & \text{Cov}[\xi_2, \xi_n] \\ \vdots & \vdots & \ddots & \vdots \\ \text{Cov}[\xi_n, \xi_1] & \text{Cov}[\xi_n, \xi_2] & \cdots & \text{Cov}[\xi_n, \xi_n] \end{pmatrix}$$

其中第 i 行第 j 列的元素 $\sigma_{ij} = \text{Cov}[\xi_i, \xi_j]$ ，特别地， $\sigma_{ii} = \text{Cov}[\xi_i, \xi_i] = \text{Var}[\xi_i]$ 。

协方差矩阵 Σ 是随机向量 $\boldsymbol{\xi}$ 的各分量之间关系的度量，形式上符合

$$\text{Cov}[\boldsymbol{\xi}] = E[(\boldsymbol{\xi} - E[\boldsymbol{\xi}])(\boldsymbol{\xi} - E[\boldsymbol{\xi}])^\top], \quad E[\boldsymbol{\xi}] = (E[\xi_1], E[\xi_2], \dots, E[\xi_n]) = \mathbf{0}.$$

代入并展开得

$$\text{Cov}[\boldsymbol{\xi}] = E[\boldsymbol{\xi}\boldsymbol{\xi}^\top] = E \begin{bmatrix} \xi_1^2 & \xi_1 \xi_2 & \cdots & \xi_1 \xi_n \\ \xi_2 \xi_1 & \xi_2^2 & \cdots & \xi_2 \xi_n \\ \vdots & \vdots & \ddots & \vdots \\ \xi_n \xi_1 & \xi_n \xi_2 & \cdots & \xi_n^2 \end{bmatrix} = \begin{pmatrix} E[\xi_1^2] & E[\xi_1 \xi_2] & \cdots & E[\xi_1 \xi_n] \\ E[\xi_2 \xi_1] & E[\xi_2^2] & \cdots & E[\xi_2 \xi_n] \\ \vdots & \vdots & \ddots & \vdots \\ E[\xi_n \xi_1] & E[\xi_n \xi_2] & \cdots & E[\xi_n^2] \end{pmatrix} = \Sigma.$$

对于中心化的随机向量 $\boldsymbol{\xi}$ ，可以选取任意向量 $\boldsymbol{a}$ 得到随机向量各个分量的线性组合

$$\boldsymbol{a}^\top \boldsymbol{\xi},$$

它也是一个随机变量。先考虑其期望

$$\mathbb{E}[\boldsymbol{a}^\top \boldsymbol{\xi}] = \boldsymbol{a}^\top \mathbb{E}[\boldsymbol{\xi}] = \boldsymbol{a}^\top \mathbf{0} = 0.$$

再考虑其方差

$$\text{Var}[\boldsymbol{a}^\top \boldsymbol{\xi}] = \mathbb{E}[(\boldsymbol{a}^\top \boldsymbol{\xi} - \mathbb{E}[\boldsymbol{a}^\top \boldsymbol{\xi}])^2] = \mathbb{E}[(\boldsymbol{a}^\top \boldsymbol{\xi})^2] = \mathbb{E}[\boldsymbol{a}^\top \boldsymbol{\xi} \boldsymbol{\xi}^\top \boldsymbol{a}] = \boldsymbol{a}^\top \mathbb{E}[\boldsymbol{\xi} \boldsymbol{\xi}^\top] \boldsymbol{a} = \boldsymbol{a}^\top \boldsymbol{\Sigma} \boldsymbol{a}.$$

等式最右边的 $\boldsymbol{a}^\top \boldsymbol{\Sigma} \boldsymbol{a}$ 是一个二次型，向量 $\boldsymbol{a}$ 是任取的，从而方差的非负性保证了 $\boldsymbol{\Sigma}$ 是一个半正定矩阵。

回顾数据逼近角度导出的 PCA，中间过程出现了一个形式相似的优化目标，即

$$\max_Z \text{tr}(Z^\top \hat{\boldsymbol{\Sigma}} Z), \quad \hat{\boldsymbol{\Sigma}} = \frac{1}{n} X X^\top.$$

回忆 $\hat{\boldsymbol{\Sigma}}$ 被称为样本 $\boldsymbol{x}_1, \boldsymbol{x}_2, \dots, \boldsymbol{x}_n$ 的协方差矩阵，由于 $\boldsymbol{x}_1, \boldsymbol{x}_2, \dots, \boldsymbol{x}_n$ 是 $\boldsymbol{\xi}$ 的 n 个独立同分布的样本，因此 $\hat{\boldsymbol{\Sigma}}$ 是 $\boldsymbol{\Sigma}$ 的一个近似，即 $\hat{\boldsymbol{\Sigma}} \approx \boldsymbol{\Sigma}$ 。因此 PCA 的目标也可以视为

$$\max_Z \text{tr}(Z^\top \boldsymbol{\Sigma} Z).$$

令 $d' = 1$ ，只保留最大主成分，此时 Z 退化为一个向量 $\boldsymbol{z}$ ，优化目标化为

$$\max_{\boldsymbol{z}} \boldsymbol{z}^\top \boldsymbol{\Sigma} \boldsymbol{z} = \max_{\boldsymbol{z}} \text{Var}[\boldsymbol{z}^\top \boldsymbol{\xi}], \quad \|\boldsymbol{z}\| = 1.$$

也就是说，对协方差矩阵保留最大主成分的意义在于，找到一个（单位）方向 $\boldsymbol{z}$ ，使得随机向量 $\boldsymbol{\xi}$ 在这个方向的线性组合 $\boldsymbol{z}^\top \boldsymbol{\xi}$ 的方差 $\text{Var}[\boldsymbol{z}^\top \boldsymbol{\xi}]$ 最大。更一般的情况将在下一节介绍。

11 方差的有偏估计和无偏估计

有的参考资料声称样本协方差矩阵的定义为

$$\hat{\Sigma} = \frac{1}{n-1} X X^{\top}.$$

这是有原因的。设 $\mathbf{x}_i$ 是 $\boldsymbol{\xi}$ 的 n 个独立同分布的样本，且 $\boldsymbol{\xi}$ 的协方差矩阵为 Σ ，均值为 $\boldsymbol{\mu}$ ，则

$$\begin{aligned} \mathbb{E}[\mathbf{x}_i] &= \boldsymbol{\mu}, \\ \Sigma &= \mathbb{E}[(\mathbf{x}_i - \boldsymbol{\mu})(\mathbf{x}_i - \boldsymbol{\mu})^{\top}] = \mathbb{E}[\mathbf{x}_i \mathbf{x}_i^{\top}] - \boldsymbol{\mu} \boldsymbol{\mu}^{\top}, \\ \mathbb{E}[\mathbf{x}_i \mathbf{x}_i^{\top}] &= \Sigma + \boldsymbol{\mu} \boldsymbol{\mu}^{\top}. \end{aligned}$$

对两个样本 $\mathbf{x}_i$ 和 $\mathbf{x}_j$ ，利用独立性知期望乘积可拆，有

$$\mathbb{E}[\mathbf{x}_i \mathbf{x}_j^{\top}] = \mathbb{E}[\mathbf{x}_i] \mathbb{E}[\mathbf{x}_j^{\top}] = \boldsymbol{\mu} \boldsymbol{\mu}^{\top},$$

对样本均值 $\bar{\mathbf{x}}$ ，计算其期望

$$\mathbb{E}[\bar{\mathbf{x}}] = \mathbb{E}\left[\frac{1}{n} \sum_{i=1}^n \mathbf{x}_i\right] = \frac{1}{n} \sum_{i=1}^n \mathbb{E}[\mathbf{x}_i] = \boldsymbol{\mu},$$

和外积期望

$$\begin{aligned} \mathbb{E}[\bar{\mathbf{x}} \bar{\mathbf{x}}^{\top}] &= \mathbb{E}\left[\left(\frac{1}{n} \sum_{i=1}^n \mathbf{x}_i\right) \left(\frac{1}{n} \sum_{j=1}^n \mathbf{x}_j\right)^{\top}\right] = \frac{1}{n^2} \sum_{i=1}^n \sum_{j=1}^n \mathbb{E}[\mathbf{x}_i \mathbf{x}_j^{\top}] \\ &= \frac{1}{n^2} \left(\sum_{i \neq j} \mathbb{E}[\mathbf{x}_i \mathbf{x}_j^{\top}] + \sum_{i=j} \mathbb{E}[\mathbf{x}_i \mathbf{x}_i^{\top}] \right), \\ &= \frac{1}{n^2} (n(n-1) \boldsymbol{\mu} \boldsymbol{\mu}^{\top} + n(\Sigma + \boldsymbol{\mu} \boldsymbol{\mu}^{\top})) = \frac{1}{n} \Sigma + \boldsymbol{\mu} \boldsymbol{\mu}^{\top}. \end{aligned}$$

计算散度矩阵

$$S = \sum_{i=1}^n (\mathbf{x}_i - \bar{\mathbf{x}})(\mathbf{x}_i - \bar{\mathbf{x}})^{\top} = \left(\sum_{i=1}^n \mathbf{x}_i \mathbf{x}_i^{\top} \right) - n \bar{\mathbf{x}} \bar{\mathbf{x}}^{\top},$$

并取期望

$$\mathbb{E}[S] = \mathbb{E}\left[\sum_{i=1}^n \mathbf{x}_i \mathbf{x}_i^{\top}\right] - n \mathbb{E}[\bar{\mathbf{x}} \bar{\mathbf{x}}^{\top}] = n \Sigma + n \boldsymbol{\mu} \boldsymbol{\mu}^{\top} - n \left(\frac{1}{n} \Sigma + \boldsymbol{\mu} \boldsymbol{\mu}^{\top} \right) = (n-1) \Sigma.$$

若定义 $\hat{\Sigma} = \frac{1}{n} S$ ，则 $\mathbb{E}[\hat{\Sigma}] = \frac{n-1}{n} \Sigma$ ，是 Σ 的一个有偏估计；若定义 $\hat{\Sigma} = \frac{1}{n-1} S$ ，则 $\mathbb{E}[\hat{\Sigma}] = \Sigma$ ，是 Σ 的一个无偏估计。

然而无论分母取 n 还是 $(n-1)$ ，都不会影响 PCA 的结果，因为 PCA 只关心协方差矩阵的特征值和特征向量，而 $\frac{1}{n}$ 和 $\frac{1}{n-1}$ 只是一个常数因子，不会改变特征向量本身和特征值大小顺序。并且，在 $n \rightarrow +\infty$ 时，这两种估计都趋于 Σ 。

12 整体方差和方差解释比例

有时候我们只考虑随机向量整体的波动，不关心各分量之间的联系，此时协方差矩阵就有些大材小用了。我们可以考虑随机向量 $\boldsymbol{\xi}$ 的整体方差，定义为

$$\text{Var}[\boldsymbol{\xi}] = \text{E}[\|\boldsymbol{\xi}\|^2] = \sum_{i=1}^n \text{E}[\xi_i^2] = \sum_{i=1}^n \text{Var}[\xi_i].$$

即随机向量 $\boldsymbol{\xi}$ 的每个分量的方差之和。

协方差矩阵的对角线上是随机向量 $\boldsymbol{\xi}$ 的每个分量的方差，因此 $\text{Var}[\boldsymbol{\xi}]$ 也可以表示为协方差矩阵 Σ 的迹，即 $\text{Var}[\boldsymbol{\xi}] = \text{tr}(\Sigma)$ 。

利用前述矩阵的迹的结论 5， Σ 的迹也可以表示为 Σ 的特征值之和，即 $\text{Var}[\boldsymbol{\xi}] = \sum_{i=1}^n \lambda_i$ ，其中 λ_i 是 Σ 的第 i 大的特征值。

对 Σ 做 PCA 时，保留前 d' 个方向，对应保留了最大的 d' 个特征值而将其余置零，此时

$$\sum_{i=1}^{d'} \lambda_i$$

就是保留的主成分所解释的方差。因此

$$\frac{\sum_{i=1}^{d'} \lambda_i}{\sum_{i=1}^n \lambda_i}$$

就是保留的主成分所解释的方差占整体方差的比例，称为**方差解释比例**，是一个非常重要的指标，反映了保留的主成分能够解释原始数据中多少的信息。

一般地，保留前 d' 个主成分的意义在于，找到一个 d' 维的子空间 W ，使得随机向量 $\boldsymbol{\xi}$ 在这个子空间的线性组合 $Z^\top \boldsymbol{\xi}$ 的整体方差 $\text{Var}[Z^\top \boldsymbol{\xi}]$ 最大。

13 奇异值分解

回顾谱定理, 即实对称矩阵的正交对角化, 对实对称矩阵 A , 存在正交矩阵 Q 和对角矩阵 D 使得

$$A = QDQ^{\top}, \quad Q^{\top}Q = I, \quad D = \text{diag}(\lambda_1, \lambda_2, \dots, \lambda_n).$$

这是一个性质良好的分解, 但它仅适用于实对称矩阵。对于一般的矩阵, 我们也希望能够得到一个类似的分解, 即存在两个正交矩阵 U 和 V , 以及一个稀疏矩阵 D , 使得

$$A = UDV^{\top}, \quad U^{\top}U = I, \quad V^{\top}V = I, \quad D_{ij} = 0, \quad i \neq j.$$

回顾从数据逼近角度导出的 PCA, 对于一般的数据矩阵 X , 我们引入了散度矩阵 $S = \frac{1}{n}XX^{\top}$ 。我们发现 $XX^{\top}$ 这样的矩阵有非常良好的性质, 即它是一个半正定矩阵, 研究它的特征值或许有所帮助。

对一般的 $m \times n$ 的矩阵 A , 构造矩阵

$$M = A^{\top}A, \quad N = AA^{\top}.$$

研究它们的特征值。取 $M = A^{\top}A$ 的任意非零特征值 λ , 对应特征向量 $\mathbf{x}$, 有

$$M\mathbf{x} = A^{\top}A\mathbf{x} = \lambda\mathbf{x}$$

左乘 A 得

$$A(A^{\top}A\mathbf{x}) = A(\lambda\mathbf{x}) \iff (AA^{\top})A\mathbf{x} = \lambda(A\mathbf{x}) \iff N(A\mathbf{x}) = \lambda(A\mathbf{x}).$$

只要 $A\mathbf{x} \neq \mathbf{0}$ 则 N 也具有特征值 λ 。这一点确实成立, 因为 $\lambda \neq 0$, 故 $\lambda\mathbf{x} \neq \mathbf{0}$, 若 $A\mathbf{x} = \mathbf{0}$, 则

$$\lambda\mathbf{x} = A^{\top}A\mathbf{x} = A^{\top}(A\mathbf{x}) = \mathbf{0}.$$

产生了矛盾。上述讨论表明 $M = A^{\top}A, N = AA^{\top}$ 有相同的非零特征值, 这被称为谱性质。

一般地, 对矩阵 A , 定义 $A^{\top}A$ (或 $AA^{\top}$) 的非零特征值的算术平方根为 A 的奇异值 σ_i , 即

$$\sigma_i = \sqrt{\lambda_i}, \quad \lambda_i \neq 0, \quad \det(\lambda_i I - A^{\top}A) = 0.$$

易见奇异值个数为 $r = \text{rank}(A^{\top}A)$, 并由

$$\text{rank}(A) = \text{rank}(A^{\top}A),$$

可知奇异值个数 $r = \text{rank}(A)$ 。

对矩阵 $A^{\top}A$ 做正交对角化, 存在正交矩阵 V 使得

$$V^{\top}A^{\top}AV = \text{diag}\left(\sigma_1^2, \sigma_2^2, \dots, \sigma_r^2, \underbrace{0, \dots, 0}_{(n-r)}\right).$$

式中出现了 $V^\top A^\top AV = (AV)^\top (AV)$, 记

$$W \triangleq AV = \begin{pmatrix} \mathbf{w}_1 & \mathbf{w}_2 & \cdots & \mathbf{w}_n \end{pmatrix},$$

其中 $\mathbf{w}_1, \mathbf{w}_2, \dots, \mathbf{w}_n$ 是 $\mathbb{R}^m$ 中的一组向量。则

$$\begin{aligned} V^\top A^\top AV &= (AV)^\top (AV) = W^\top W, \\ &= \begin{pmatrix} \mathbf{w}_1^\top \\ \mathbf{w}_2^\top \\ \vdots \\ \mathbf{w}_n^\top \end{pmatrix} \begin{pmatrix} \mathbf{w}_1 & \mathbf{w}_2 & \cdots & \mathbf{w}_n \end{pmatrix} = \begin{pmatrix} \mathbf{w}_1^\top \mathbf{w}_1 & \mathbf{w}_1^\top \mathbf{w}_2 & \cdots & \mathbf{w}_1^\top \mathbf{w}_n \\ \mathbf{w}_2^\top \mathbf{w}_1 & \mathbf{w}_2^\top \mathbf{w}_2 & \cdots & \mathbf{w}_2^\top \mathbf{w}_n \\ \vdots & \vdots & \ddots & \vdots \\ \mathbf{w}_n^\top \mathbf{w}_1 & \mathbf{w}_n^\top \mathbf{w}_2 & \cdots & \mathbf{w}_n^\top \mathbf{w}_n \end{pmatrix}. \end{aligned}$$

对比各元素 $\mathbf{w}_i^\top \mathbf{w}_j$ 并进行分类

- 当 $i = j \leq r$ 时, $\mathbf{w}_i^\top \mathbf{w}_i = \sigma_i^2$ 。
- 当 $i = j > r$ 时, $\mathbf{w}_i^\top \mathbf{w}_i = 0$ 。这同时也告诉我们 $\mathbf{w}_i = \mathbf{0}$ 。
- 当 $i \neq j$ 时, $\mathbf{w}_i^\top \mathbf{w}_j = 0$ 。

不妨记

$$\mathbf{u}_i = \sigma_i^{-1} \mathbf{w}_i, \quad 1 \leq i \leq r,$$

则 $\mathbf{u}_1, \mathbf{u}_2, \dots, \mathbf{u}_r$ 两两正交且均为单位向量, 因此可以扩充为 $\mathbb{R}^m$ 中的一组标准正交基

$$\mathbf{u}_1, \mathbf{u}_2, \dots, \mathbf{u}_r, \mathbf{u}_{r+1}, \mathbf{u}_{r+2}, \dots, \mathbf{u}_m.$$

并且

$$\begin{aligned} AV &= \begin{pmatrix} \mathbf{w}_1 & \mathbf{w}_2 & \cdots & \mathbf{w}_r & \mathbf{0} & \cdots & \mathbf{0} \end{pmatrix} = \begin{pmatrix} \sigma_1 \mathbf{u}_1 & \sigma_2 \mathbf{u}_2 & \cdots & \sigma_r \mathbf{u}_r & \mathbf{0} & \cdots & \mathbf{0} \end{pmatrix}, \\ &= \begin{pmatrix} \mathbf{u}_1 & \mathbf{u}_2 & \cdots & \mathbf{u}_r & \mathbf{u}_{r+1} & \mathbf{u}_{r+2} & \cdots & \mathbf{u}_m \end{pmatrix} \begin{pmatrix} \text{diag}(\sigma_1, \sigma_2, \dots, \sigma_r) & O_{r \times (n-r)} \\ O_{(m-r) \times r} & O_{(m-r) \times (n-r)} \end{pmatrix}. \end{aligned}$$

分别记

$$U = \begin{pmatrix} \mathbf{u}_1 & \mathbf{u}_2 & \cdots & \mathbf{u}_m \end{pmatrix}, \quad D = \begin{pmatrix} \text{diag}(\sigma_1, \sigma_2, \dots, \sigma_r) & O_{r \times (n-r)} \\ O_{(m-r) \times r} & O_{(m-r) \times (n-r)} \end{pmatrix}.$$

于是

$$AV = UD, U^\top U = I, V^\top V = I \implies A = UDV^\top.$$

其中

$$D = \begin{pmatrix} \text{diag}(\sigma_1, \sigma_2, \dots, \sigma_r) & O_{r \times (n-r)} \\ O_{(m-r) \times r} & O_{(m-r) \times (n-r)} \end{pmatrix}.$$

也就是说 D 是一个广义对角矩阵, 非对角线元素均为零。

上述讨论导出了任意矩阵的**奇异值分解**。

14 截断奇异值分解与主成分分析

对于任意的 $m \times n$ 矩阵 A , 有奇异值分解

$$A = UDV^\top = \sum_{i=1}^r \sigma_i \mathbf{u}_i \mathbf{v}_i^\top.$$

其中 $\mathbf{u}_i$ 和 $\mathbf{v}_i$ 分别是 U 和 V 的第 i 列向量。额外地, 我们要求

$$\sigma_1 \geq \sigma_2 \geq \cdots \geq \sigma_r > 0,$$

即 σ_i 是 A 的第 i 大的奇异值。

回忆矩阵近似角度导出的 PCA, 当时我们限制 A 是一个对称矩阵, 并保留了它的前 k 个特征值。效仿此法进行讨论, 保留前 $k \leq r$ 个奇异值, 得到近似矩阵

$$A_k = \sum_{i=1}^k \sigma_i \mathbf{u}_i \mathbf{v}_i^\top.$$

误差矩阵可表为

$$A - A_k = \sum_{i=k+1}^r \sigma_i \mathbf{u}_i \mathbf{v}_i^\top = U D_k V^\top,$$

$$D_k = \begin{pmatrix} O_{k \times k} & O_{k \times (r-k)} & O_{k \times (n-r)} \\ O_{(r-k) \times k} & \text{diag}(\sigma_{k+1}, \sigma_{k+2}, \dots, \sigma_r) & O_{(r-k) \times (n-r)} \\ O_{(m-r) \times k} & O_{(m-r) \times (r-k)} & O_{(m-r) \times (n-r)} \end{pmatrix},$$

计算误差矩阵谱范数

$$(A - A_k)^\top (A - A_k) = V D^\top D V^\top = V \text{diag} \left(\underbrace{0, \dots, 0}_{(r-k)}, \sigma_{k+1}^2, \dots, \sigma_r^2, \underbrace{0, \dots, 0}_{(m-r)} \right) V^\top$$

$$\implies \|A - A_k\|^2 = \max_{k+1 \leq i \leq r} \sigma_i^2 = \sigma_{k+1}^2 \implies \|A - A_k\| = \sigma_{k+1}.$$

这实际上也是某种 PCA 过程, 从两个角度进行评估:

- 信息量。对 $1 \leq i \leq k$, 记录 $\sigma_i, \mathbf{u}_i, \mathbf{v}_i$, 保留了 $k \cdot (1 + m + n)$ 个数。
- 误差。保留前 k 个奇异值, 误差矩阵的谱范数为 σ_{k+1} 。

我们知道 A_k 是 A 的一个秩不超过 k 的近似矩阵。在所有秩不超过 k 的矩阵中, 是否存在异于 A_k 的矩阵 B 使得 $\|A - B\| < \|A - A_k\|$? 答案是否定的。

Theorem (谱范数情形下的 Eckart-Young-Mirsky 定理). 对任意矩阵 A 和 $k < r = \text{rank}(A)$, 有奇异值分解和截断奇异值分解

$$A = UDV^\top, \quad A_k = \sum_{i=1}^k \sigma_i \mathbf{u}_i \mathbf{v}_i^\top,$$

对于任意秩不超过 k 的矩阵 B , 有

$$\|A - B\| \geq \|A - A_k\| = \sigma_{k+1}.$$

证明. 由谱范数定义

$$\|A - B\| = \sup_{\|x\|=1} \|(A - B)x\|.$$

由于要证的结论是一个不小于号, 我们可以给 $\sup$ 符号增加限制, 从而保证不小于号成立。

一方面, 我们没有 B 的很好的性质, 因此在式子中保留 B 是不可接受的。这时我们希望增加限制, 要求 x 处于 B 的零空间内, 即

$$x \in N(B).$$

另一方面, 最坏情况下 B 会试图拟合 A 的前 k 个奇异值, 但它无法再多拟合 σ_{k+1} 。同时, 为了使保留的特征值尽可能大, 并且在计算 $Ax = UDV^T x$ 时产生一些便利, 我们希望再次增加限制, 要求 x 处于 V 的前 $(k+1)$ 列向量所张成的子空间内, 即

$$x \in \text{span}\{v_1, v_2, \dots, v_{k+1}\}.$$

现在希望这两个限制能够同时被非平凡向量满足, 即

$$N(B) \cap \text{span}\{v_1, v_2, \dots, v_{k+1}\} \neq \{0\}.$$

由于 B 的秩不超过 k , 因此据秩-零度化定理有 $\dim N(B) \geq n - k$; 由于 $v_1, v_2, \dots, v_{k+1}$ 线性无关, 因此 $\dim \text{span}\{v_1, v_2, \dots, v_{k+1}\} = k + 1$ 。从而

$$\dim N(B) + \dim \text{span}\{v_1, v_2, \dots, v_{k+1}\} \geq n - k + k + 1 = n + 1 > n.$$

这提示我们两个子空间交集非平凡, 即

$$\exists x, \quad x \in N(B) \cap \text{span}\{v_1, v_2, \dots, v_{k+1}\}, \quad \|x\| = 1$$

于是对这些 x 有

$$Bx = 0, \quad \begin{cases} x = Vy \iff y = V^T x, \\ x \in \text{span}\{v_1, v_2, \dots, v_{k+1}\}. \end{cases} \implies y_i = 0, \quad k+1 < i \leq n,$$

代入有

$$\begin{aligned} (A - B)x &= Ax - Bx = Ax, \\ &= UDV^T x = UDV^T Vy = UDy, \\ &= UD(y_1, y_2, \dots, y_k, y_{k+1}, 0, \dots, 0) = U(\sigma_1 y_1, \sigma_2 y_2, \dots, \sigma_k y_k, \sigma_{k+1} y_{k+1}, 0, \dots, 0). \end{aligned}$$

记

$$z = (\sigma_1 y_1, \sigma_2 y_2, \dots, \sigma_k y_k, \sigma_{k+1} y_{k+1}, 0, \dots, 0),$$

则

$$\|(A - B)x\|^2 = \|Uz\|^2 = z^T U^T U z = z^T z.$$

对 $\mathbf{y}$ 有

$$\begin{aligned}\|\mathbf{y}\|^2 &= \mathbf{y}^\top \mathbf{y} = \mathbf{x}^\top V V^\top \mathbf{x} = \mathbf{x}^\top \mathbf{x} = \|\mathbf{x}\|^2 = 1, \\ &= \sum_{i=1}^{k+1} y_i^2 = 1.\end{aligned}$$

于是对 $\mathbf{z}$ 有

$$\begin{aligned}\|\mathbf{z}\| &= \sqrt{\sum_{i=1}^{k+1} \sigma_i^2 y_i^2}, \quad \sigma_1^2 \geq \sigma_2^2 \geq \cdots \geq \sigma_{k+1}^2 > 0, \\ &\geq \sqrt{\sum_{i=1}^{k+1} \sigma_{k+1}^2 y_i^2} = \sigma_{k+1} \sqrt{\sum_{i=1}^{k+1} y_i^2} = \sigma_{k+1}.\end{aligned}$$

从而

$$\begin{aligned}\|A - B\| &= \sup_{\|\mathbf{x}\|=1} \|(A - B) \mathbf{x}\| \geq \sup_{\substack{\|\mathbf{x}\|=1, \mathbf{x} \in N(B), \\ \mathbf{x} \in \text{span}\{\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_{k+1}\}}} \|(A - B) \mathbf{x}\| \\ &\geq \sigma_{k+1} = \|A - A_k\|.\end{aligned}$$

□

15 四个子空间与奇异值分解

回忆 A 的四个子空间

$$\begin{aligned} C(A) &= \{A\mathbf{x} \mid \mathbf{x} \in \mathbb{R}^n\} \subseteq \mathbb{R}^m, \\ N(A) &= \{\mathbf{x} \mid A\mathbf{x} = \mathbf{0}, \mathbf{x} \in \mathbb{R}^n\} \subseteq \mathbb{R}^n, \\ C(A^\top) &= \{A^\top \mathbf{y} \mid \mathbf{y} \in \mathbb{R}^m\} \subseteq \mathbb{R}^n, \\ N(A^\top) &= \{\mathbf{y} \mid A^\top \mathbf{y} = \mathbf{0}, \mathbf{y} \in \mathbb{R}^m\} \subseteq \mathbb{R}^m, \end{aligned}$$

各子空间存在维数关系

$$\begin{aligned} \dim C(A) = r, \quad \dim N(A^\top) = m - r, \quad \dim C(A) + \dim N(A^\top) = m, \\ \dim C(A^\top) = r, \quad \dim N(A) = n - r, \quad \dim C(A^\top) + \dim N(A) = n. \end{aligned}$$

以及正交补关系

$$C(A) \perp N(A^\top), \quad C(A^\top) \perp N(A).$$

将 A 的奇异值分解写成向量的形式

$$A = UDV^\top \iff AV = UD \iff \begin{cases} A\mathbf{v}_i = \sigma_i \mathbf{u}_i, & 1 \leq i \leq r, \\ A\mathbf{v}_i = \mathbf{0}, & r+1 \leq i \leq n. \end{cases}$$

对于 U 的前 r 列向量 $\mathbf{u}_1, \mathbf{u}_2, \dots, \mathbf{u}_r$, 有

$$A\mathbf{v}_i = \sigma_i \mathbf{u}_i \in C(A) \implies \mathbf{u}_i \in C(A), \quad 1 \leq i \leq r.$$

考虑 $\dim C(A) = r$ 并且 $\mathbf{u}_i$ 线性无关, 从而

$$C(A) = \text{span}\{\mathbf{u}_1, \mathbf{u}_2, \dots, \mathbf{u}_r\}.$$

对于 V 的后 $n-r$ 列向量 $\mathbf{v}_{r+1}, \mathbf{v}_{r+2}, \dots, \mathbf{v}_n$, 有

$$A\mathbf{v}_i = \mathbf{0} \implies \mathbf{v}_i \in N(A), \quad r+1 \leq i \leq n.$$

考虑 $\dim N(A) = n-r$ 并且 $\mathbf{v}_i$ 线性无关, 从而

$$N(A) = \text{span}\{\mathbf{v}_{r+1}, \mathbf{v}_{r+2}, \dots, \mathbf{v}_n\}.$$

考虑子空间的正交补关系, 不难得到

$$\begin{cases} C(A) \perp N(A^\top), \\ C(A) \oplus N(A^\top) = \mathbb{R}^m, \\ C(A) = \text{span}\{\mathbf{u}_1, \mathbf{u}_2, \dots, \mathbf{u}_r\}. \end{cases} \implies N(A^\top) = \text{span}\{\mathbf{u}_{r+1}, \mathbf{u}_{r+2}, \dots, \mathbf{u}_m\},$$

$$\begin{cases} C(A^\top) \perp N(A), \\ C(A^\top) \oplus N(A) = \mathbb{R}^n, \\ N(A) = \text{span}\{\mathbf{v}_{r+1}, \mathbf{v}_{r+2}, \dots, \mathbf{v}_n\}. \end{cases} \implies C(A^\top) = \text{span}\{\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_r\}.$$

这两个结论也可以通过另外的方式得到：对 $A = UDV^\top$ ，两边转置有

$$A = UDV^\top \iff A^\top = VD^\top U^\top \iff A^\top U = VD^\top.$$

其中

$$D^\top = \begin{pmatrix} \text{diag}(\sigma_1, \sigma_2, \dots, \sigma_r) & O_{r \times (m-r)} \\ O_{(n-r) \times r} & O_{(n-r) \times (m-r)} \end{pmatrix}.$$

取各列向量有

$$\begin{cases} A^\top \mathbf{u}_i = \sigma_i \mathbf{v}_i, & 1 \leq i \leq r, \\ A^\top \mathbf{u}_i = \mathbf{0}, & r+1 \leq i \leq m. \end{cases}$$

因此

$$\begin{cases} \mathbf{v}_i \in C(A^\top), & 1 \leq i \leq r, \\ \mathbf{u}_i \in N(A^\top), & r+1 \leq i \leq m. \end{cases}$$

并由维数关系和线性无关性得到

$$\begin{aligned} C(A^\top) &= \text{span}\{\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_r\}, \\ N(A^\top) &= \text{span}\{\mathbf{u}_{r+1}, \mathbf{u}_{r+2}, \dots, \mathbf{u}_m\}. \end{aligned}$$

上述的讨论表明，矩阵 A 的四个子空间可以通过 A 的奇异值分解中的 U 和 V 来刻画， U 和 V 的列向量分别构成了矩阵 A 的四个子空间的一组标准正交基。

$$\begin{aligned} C(A) &= \text{span}\{\mathbf{u}_1, \mathbf{u}_2, \dots, \mathbf{u}_r\}, \\ N(A^\top) &= \text{span}\{\mathbf{u}_{r+1}, \mathbf{u}_{r+2}, \dots, \mathbf{u}_m\}, \\ C(A^\top) &= \text{span}\{\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_r\}, \\ N(A) &= \text{span}\{\mathbf{v}_{r+1}, \mathbf{v}_{r+2}, \dots, \mathbf{v}_n\}. \end{aligned}$$

16 奇异值分解的几何解释

考虑线性映射 $\mathcal{A}: \mathbb{R}^n \rightarrow \mathbb{R}^m$, 对于任意 $\mathbf{x} \in \mathbb{R}^n$, 有

$$\mathcal{A}: \boxed{\mathbf{x}} \mapsto \boxed{A\mathbf{x}}, \quad A \in \mathbb{R}^{m \times n}.$$

对矩阵 A 做奇异值分解 $A = UDV^\top$, 则 $A\mathbf{x} = UDV^\top\mathbf{x}$, 可拆分成三个线性映射的复合

$$\boxed{\mathbf{x}} \xrightarrow{V^\top} \boxed{V^\top\mathbf{x}} \xrightarrow{D} \boxed{DV^\top\mathbf{x}} \xrightarrow{U} \boxed{UDV^\top\mathbf{x}} = \boxed{A\mathbf{x}},$$

接下来分别对这三个线性映射进行几何解释。

•

$$\boxed{\mathbf{x}} \mapsto \boxed{V^\top\mathbf{x}}$$

是一个旋转映射, 这是由于 $V^\top$ 是一个正交矩阵, 左乘 $V^\top$ 不改变向量的长度。此时

$$V^\top\mathbf{x} = \begin{pmatrix} \mathbf{v}_1^\top\mathbf{x} \\ \mathbf{v}_2^\top\mathbf{x} \\ \vdots \\ \mathbf{v}_n^\top\mathbf{x} \end{pmatrix},$$

从而左乘 $V^\top$ 将输入向量 $\mathbf{x}$ 投影到 V 的列空间上, $V^\top\mathbf{x}$ 的每个分量对应其在各个 $\mathbf{v}_i$ 方向上的坐标。

亦可考虑 $\mathbf{x} = VV^\top\mathbf{x} = V(V^\top\mathbf{x})$, 更直接地理解 $V^\top$ 将标准基坐标改为 V 的列向量组成的基的坐标。

•

$$\boxed{V^\top\mathbf{x}} \mapsto \boxed{DV^\top\mathbf{x}}$$

是一个伸缩映射, 这是由于 D 是一个广义对角矩阵, 对于输入向量 $V^\top\mathbf{x}$ 的不同分量有

– $1 \leq i \leq r$, D 将输入向量 $V^\top\mathbf{x}$ 在 $\mathbf{v}_i$ 方向上伸缩 σ_i 倍。

即在构成 $C(A)$ 的基上, D 将对应坐标伸缩 σ_i 倍。

– $r+1 \leq i \leq n$, D 将输入向量 $V^\top\mathbf{x}$ 在 $\mathbf{v}_i$ 方向上压缩为零。

即在构成 $N(A)$ 的基上, D 将对应坐标压缩为零。

这同时将 V 的列向量组成的基的坐标转换到 U 的列向量组成的基的坐标, 后者即

$$DV^\top\mathbf{x} = \begin{pmatrix} \sigma_1\mathbf{v}_1^\top\mathbf{x} \\ \sigma_2\mathbf{v}_2^\top\mathbf{x} \\ \vdots \\ \sigma_r\mathbf{v}_r^\top\mathbf{x} \\ 0 \\ \vdots \\ 0 \end{pmatrix}.$$

•

$$\boxed{DV^\top \mathbf{x}} \mapsto \boxed{UDV^\top \mathbf{x}} = \boxed{A\mathbf{x}}$$

是一个旋转映射，这是由于 U 是一个正交矩阵，左乘 U 不改变向量的长度。此时


$$UDV^\top \mathbf{x} = \begin{pmatrix} \mathbf{u}_1 & \mathbf{u}_2 & \cdots & \mathbf{u}_m \end{pmatrix} \begin{pmatrix} \sigma_1 \mathbf{v}_1^\top \mathbf{x} \\ \sigma_2 \mathbf{v}_2^\top \mathbf{x} \\ \vdots \\ \sigma_r \mathbf{v}_r^\top \mathbf{x} \\ 0 \\ \vdots \\ 0 \end{pmatrix}$$

这步变换将 U 的列向量组成的基的坐标转换为标准基的坐标，也即输出向量。

由此可见，任意线性变换都可以分解成旋转、伸缩、旋转的复合，这就是奇异值分解的几何解释。

每一个映射作用如下：

- $V^\top$ 将 $\mathbf{x}$ 投影到输入特征向量上（寻找新坐标）。
- D 在特征方向上进行拉伸或压缩或置零。
- U 将结果投影到输出特征向量上（转换为标准基坐标）。



17 结语

从矩阵相似对角化出发，我们探讨了矩阵所蕴含的优美分解结构——对角化或类对角化。谱定理让我们得以对实对称矩阵进行正交对角化，然而对于一般的矩阵却需要更为普适的方法。

另一条主线则与信息的有损压缩有关——我们希望用尽可能少的信息来表达原始矩阵，并且希望误差能够控制在一定范围内。衡量信息量是平凡的；为了衡量误差，我们引入了矩阵范数并主要利用谱范数对矩阵进行刻画。

通过特征值与特征向量，我们将实对称矩阵视为一系列秩 1 矩阵的线性组合；并通过保留前几个特征值来实现矩阵的有损压缩，这种保留高特征值及特征向量的方式即为主成分分析（PCA）。信息的有损压缩在统计学和概率论中亦有应用，这也是 PCA 的一种情形。我们引入矩阵的迹作为工具，集中讨论了 PCA 的数据逼近角度和随机向量角度，指出 PCA 的目标在于找到一个子空间，使得所有数据或随机向量在这个子空间的投影的方差最大。

对矩阵的近似分解的讨论引入了奇异值分解（SVD），它是对任意矩阵的一种分解方式，将矩阵分解成正交矩阵、广义对角矩阵、正交矩阵的乘积。SVD 的一个重要应用是截断 SVD，即保留前几个奇异值及对应的奇异向量来实现矩阵的有损压缩。由 Eckart-Young-Mirsky 定理可知，这是在给定秩约束下最优的矩阵近似。

SVD 与矩阵的四个子空间有着密切的联系，SVD 的奇异向量构成了矩阵四个子空间的一组标准正交基。SVD 的几何解释则是任意线性变换都可以分解成旋转、伸缩、旋转的复合。线性代数在此展现了其深刻的统一美和对称美。

撰写本文的初衷是为了复习、总结和梳理线性代数中的一部分重要知识，尤其是 PCA 和 SVD 的相关内容。进行有关推导时，有的经典结论常被反复利用，为了文章的完备性，作者在开启正题之前花了大量篇幅介绍了基础知识。本文参考了部分线性代数教材和大量相关资料，力求内容的准确性和清晰性，并希望读者能在咀嚼推敲用语凝炼精简的官方讲义之余，收获一些微不足道的额外帮助。

感谢中国人民大学信息学院 2025-2026 学年《高等代数 II（计算机类）》的主讲老师易鸣洋老师和各位助教，提供了作者撰写本文的参考材料和动机。感谢张泽昌同学提供了 Eckart-Young-Mirsky 定理的证明与解释。感谢各位帮忙审校本文的同学，还有全天候陪伴我的 Gemini，提供了宝贵的意见和建议。希望本文能够帮助读者更好地理解这些重要的矩阵分解方法，能够在实际应用中灵活运用它们，并且在有关这些知识的考试中取得好成绩。限于作者水平，文中难免有疏漏或错误之处，恳请读者批评指正。