

最小二乘法

最小二乘法的

对于直线 $y = C + Dt$ 方程，假设其截距 C 与斜率 D 未知。为确定该直线，只须取两点即可。设 $t = 0$ 时 $y = 6$ ，即点 $(0, 6)$ 在直线上。 $t = 1$ 时 $y = 0$ ，即 $(1, 0)$ 在直线上。代入方程得：

$$\begin{cases} C + 0D = 6 \\ C + 1D = 0 \end{cases}$$

或写成矩阵方程组的形式：

$$\begin{pmatrix} 1 & 0 \\ 1 & 1 \end{pmatrix} \begin{pmatrix} C \\ D \end{pmatrix} = \begin{pmatrix} 6 \\ 0 \end{pmatrix}$$

可解得：

$$\begin{pmatrix} C \\ D \end{pmatrix} = \begin{pmatrix} 1 & 0 \\ 1 & 1 \end{pmatrix}^{-1} \begin{pmatrix} 6 \\ 0 \end{pmatrix} = \begin{pmatrix} 1 & 0 \\ -1 & 1 \end{pmatrix} \begin{pmatrix} 6 \\ 0 \end{pmatrix} = \begin{pmatrix} 6 \\ -6 \end{pmatrix}.$$

故所求直线为：

$$y = 6 - 6t$$

在实际应用中，为求得直线 $y = C + Dt$ ，需要测量出直线上的点，如：

$$t = 0 \text{ 时}, \quad y = 6$$

$$t = 1 \text{ 时}, \quad y = 0$$

但在实际测量中，一定存在误差，即所测量的 t 与 y 均有可能不准。因此，需要多次测量再估计对应系数。例如，在上例中，再做一次测量得到：

$$t = 3 \text{ 时}, \quad y = 0.$$

则从 3 次测得中找出 C 与 D 等价于求解：

$$\begin{cases} C + 0D = 6 \\ C + 1D = 0 \\ C + 3D = 0 \end{cases}$$




图 1 图：从直线拟合和到列空间投影两个角度共同理解最小二乘问题。

即

$$Ax = b, \quad A = \begin{pmatrix} 1 & 0 \\ 1 & 1 \\ 1 & 2 \end{pmatrix}, \quad x = \begin{pmatrix} C \\ D \end{pmatrix}, \quad b = \begin{pmatrix} 6 \\ 0 \\ 0 \end{pmatrix}$$

然而，我们发现在这一情况下由于 $b \notin C(A)$ ，上述线性方程组无解。那么，在这种方程无解的情况下，我们应该如何找到对应直线？

直观上，我们应该找一条直线，使其“最靠近”得到的三个点：

“最靠近” $\Leftrightarrow$ 真实点和预测点之间的误差 $e = b - Ax$ 的长度最小

在上述例子中，误差为

$$\sum_{i=1}^3 (y_i - C - t_i D)^2,$$

其中 $(t_1, y_1) = (0, 6)$, $(t_2, y_2) = (1, 0)$, $(t_3, y_3) = (2, 0)$ ，即是直线到采集到的数据点之间的距离的总和。

用矩阵乘法语言，上述问题等价于求解如下最小二乘问题：

$$\min_x \|Ax - b\|^2 = \|e\|^2.$$

最小二乘问题从直观上可以理解成寻找一个“解” x^* 使其尽可能的满足 $Ax^* = b$ 。

上述最小二乘问题应该如何求解？这个解等价于找 $C(A)$ 中与向量 b 最近的向量 p 。由投影问题的求解可知 (b 到 $C(A)$ 上的投影导出的误差与 $C(A)$ 中所有向量正交)，当 A 的列满秩时：

$$x^* = (A^T A)^{-1} A^T b$$

投影 $p = Ax^* = A(A^T A)^{-1} A^T b = Pb$ ，其中 P 为 $C(A)$ 所对应的投影矩阵。代入计算得到

$$x^* = (A^T A)^{-1} A^T b = \begin{pmatrix} \frac{5}{6} & -\frac{1}{2} \\ -\frac{1}{2} & \frac{1}{2} \end{pmatrix} \begin{pmatrix} 6 \\ 0 \end{pmatrix} = \begin{pmatrix} 5 \\ -3 \end{pmatrix}$$

故 $C = 5, D = -3$ 。从直线到数据点之间的距离和到 $C(A)$ 空间上的投影理解最小二乘法可以参考图1。

定义 1 设 $m \times n$ 维矩阵 A 列满秩, 若 $\mathbf{x}^* \in \mathbb{R}^n$ 使得

$$\|A\mathbf{x}^* - \mathbf{b}\|^2 = \min_{\mathbf{x}} \|A\mathbf{x} - \mathbf{b}\|^2$$

即 $\mathbf{x}^* = \arg \min_{\mathbf{x}} \|A\mathbf{x} - \mathbf{b}\|^2$, 则称 $\mathbf{x}^*$ 是 $A\mathbf{x} = \mathbf{b}$ 的最小二乘解。

定理 1 若 A 列满秩, 则最小二乘解 $\mathbf{x}^*$ 存在且唯一。

证明 取 $\mathbf{b} = \mathbf{p} + \mathbf{e}$, 其中 $\mathbf{p} \in C(A), \mathbf{e} \in N(A^\top)$ 。则

$$\|\mathbf{b} - A\mathbf{x}\|^2 = \|\mathbf{p} + \mathbf{e} - A\mathbf{x}\|^2 = \|\mathbf{p} - A\mathbf{x}\|^2 + \|\mathbf{e}\|^2 \geq \|\mathbf{e}\|^2.$$

当存在 $\mathbf{p} = A\mathbf{x}$ 时上述问题达到最小, 即问题有解。由 $\mathbf{p}$ 的定义知, 这样的 $\mathbf{x}$ 一定存在, 故最小二乘问题有解。

下证唯一性, 由 A 列满秩知 $\mathbf{p} \in C(A)$ 中 $\mathbf{p} = A\mathbf{x}$ 的表示唯一, 故解的唯一性得证。 ■

由上一章的结论知, 在 A 列满秩的情况下, 最小二乘问题的唯一解为 $\mathbf{x}^* = (A^\top A)^{-1} A^\top \mathbf{b}$ 。

最小二乘法的应用

最小二乘法这种近似求解的思想在人工智能、数据科学中占据重要地位, 我们用如下例子进行说明:

例 1 在二维平面上有 m 个数据对 $\{(t_i, y_i)\}_{i=1}^m$, 希望找一条直线能够最大程度的拟合这些数据点。

从上面三个数据点的例子可以推广到 m 个数据点的情况, 即希望找到一条直线 $\alpha x + \beta = y$, 使得这条直线能尽量表示这些数据点之间的关系。

直观上, 要使得整体的拟合误差尽可能小, 我们考虑如下极小化问题:

$$\min_{\alpha, \beta} \sum_{i=1}^m (y_i - \alpha t_i - \beta)^2, \quad (1)$$

选取

$$A = \begin{pmatrix} 1 & t_1 \\ \vdots & \vdots \\ 1 & t_m \end{pmatrix}, \quad \mathbf{x} = \begin{pmatrix} \alpha \\ \beta \end{pmatrix}, \quad \mathbf{b} = \begin{pmatrix} y_1 \\ \vdots \\ y_m \end{pmatrix}$$

由

$$\|A\mathbf{x} - \mathbf{b}\|^2 = \sum_{i=1}^m (\mathbf{a}^{(i)\top} \mathbf{x} - b_i)^2 = \sum_{i=1}^m (y_i - \alpha t_i - \beta)^2$$

知, 上述数据科学中的拟合问题变成了一个最小二乘问题。在这个例子中, 变量 $(1, x)$ 被称为自变量, 而 y 则被称为因变量。

注 1 最小二乘法的误差向量 $\mathbf{e} = \mathbf{b} - A\mathbf{x}^*$ 与 A 的列向量正交。而 $\mathbf{a}_1 = (1, \dots, 1)$,

$$\mathbf{e}^\top \mathbf{a}_1 = \sum_{i=1}^m e_i = 0.$$

故最小二乘法的误差之和为零。

下面考虑最小二乘问题(1)的求解过程。首先, 假设数据点的横坐标 $\{t_i\}_{i=1}^m$ 不完全相同, 故矩阵 $\mathbf{A}$ 列满秩, 从而矩阵 $\mathbf{A}^\top \mathbf{A}$ 可逆, 正规方程有解。此时,

$$\mathbf{A}^\top \mathbf{A} = \begin{pmatrix} 1 & \cdots & 1 \\ t_1 & \cdots & t_m \end{pmatrix} \begin{pmatrix} 1 & t_1 \\ \vdots & \vdots \\ 1 & t_m \end{pmatrix} = \begin{pmatrix} m & \sum t_i \\ \sum t_i & \sum t_i^2 \end{pmatrix}$$

而

$$\mathbf{A}^\top \mathbf{b} = \begin{pmatrix} 1 & \cdots & 1 \\ t_1 & \cdots & t_m \end{pmatrix} \begin{pmatrix} y_1 \\ \vdots \\ y_m \end{pmatrix} = \begin{pmatrix} \sum y_i \\ \sum t_i y_i \end{pmatrix}.$$

因此, 在 m 个数据点条件下的最小二乘法的解 $\mathbf{x}^*$ 满足

$$\mathbf{x}^* = \begin{pmatrix} m & \sum t_i \\ \sum t_i & \sum t_i^2 \end{pmatrix}^{-1} \begin{pmatrix} \sum y_i \\ \sum t_i y_i \end{pmatrix} \quad (2)$$

可以看到, 求解一般最小二乘解的主要难点在矩阵逆的计算。但由 $\mathbf{A}^\top \mathbf{A} = (\mathbf{a}_i^\top \mathbf{a}_j)_{ij}$ 知, 当 $\mathbf{A}$ 的各列相互正交时, 矩阵 $\mathbf{A}^\top \mathbf{A}$ 为对角阵, 其逆矩阵就变得好计算了。

在二维情境下, 由于矩阵 $\mathbf{A} = (\mathbf{a}_1, \mathbf{a}_2)$, 满足 $\mathbf{a}_1 = (1, \cdots, 1)$, 则 $\mathbf{A}$ 的列正交意味着 $\sum t_i = 0$ 。此时(2)中矩阵 $\mathbf{A}^\top \mathbf{A}$ 变对角矩阵。

因此, 在实践中, 对于这样的二维最小二乘问题, 我们通常会采取一个“标准化”的方法。即对每个数据点 t_i , 将其变为 $t_i - \frac{1}{m} \sum_{i=1}^m t_i = t_i - \bar{t}$, 再进行回归。此时, 矩阵 $\mathbf{A}^\top \mathbf{A}$ 为对角阵

$$\begin{pmatrix} m & 0 \\ 0 & \sum (t_i - \bar{t})^2 \end{pmatrix}$$

从而回归变得更加容易。

例 2 求解数据点 $(1, 1), (3, 2), (5, 6)$ 的最小二乘解。

解 横坐标的均值为 3, 因此先对所有数据点的横坐标减去其均值, 横坐标变为 $-2, 0, 2$ 。拟合直线变为

$$y = \alpha(t - \bar{t} + \bar{t}) + \beta = \alpha(t - \bar{t}) + \alpha\bar{t} + \beta.$$

带入公式(2), 得到

$$\mathbf{x}^* = \begin{pmatrix} 3 & 0 \\ 0 & 8 \end{pmatrix}^{-1} \begin{pmatrix} 9 \\ 10 \end{pmatrix} = \begin{pmatrix} 3 \\ \frac{5}{4} \end{pmatrix} = \begin{pmatrix} \alpha\bar{t} + \beta \\ \alpha \end{pmatrix}$$

则最终的系数为 $\alpha = \frac{5}{4}, \beta = 3 - \frac{5}{4} \cdot 3 = -\frac{3}{4}$ 。 ■

上面的例子都是二维场景下的最小二乘法, 下面考虑高维场景下的最小二乘法。

回顾原始的最小二乘问题 $\min_{\mathbf{x}} \|\mathbf{Ax} - \mathbf{b}\|^2$, 此时矩阵 $\mathbf{A}$ 的维数就由 $m \times 2$ 变为 $m \times n$ 。在“拟合直线”角度下, 最小二乘问题变为:

$$\min_{\mathbf{x}} \sum_{i=1}^m \left(y_i - \sum_{j=1}^n x_j t_{ij} \right)^2,$$

对应着

$$\mathbf{A} = \begin{pmatrix} t_{11} & \cdots & t_{1n} \\ \vdots & & \vdots \\ t_{m1} & \cdots & t_{mn} \end{pmatrix}, \quad \mathbf{x} = \begin{pmatrix} x_1 \\ \vdots \\ x_n \end{pmatrix}, \quad \mathbf{b} = \begin{pmatrix} y_1 \\ \vdots \\ y_m \end{pmatrix}.$$

这一问题的直观含义就是用高维空间上的一条直线来拟合给定的数据点。

前面最小二乘法的拟合过程没有脱离直线的范畴, 那么一个自然的问题就是, 能否在最小二乘的框架下引入非线性函数来拟合数据? 答案是可行的, 例如: 对于拟合直线 $\sum_{j=1}^m x_j t_j$, 取 t_j 为 t^j 。这样, 拟合模型就变为 $\sum_{j=1}^m x_j t^j$, 是一个关于自变量变量的多项式 (非线性) 函数了。

例 3 考虑 $n = 3$ 的情况, 选取拟合模型为 $\alpha + \beta t + \gamma t^2$ 去拟合收集到的数据点 $\{(t_i, y_i)\}_{i=1}^m$ 。

这个拟合问题是自然界中运动轨迹的模拟。根据基础的物理知识, 用直线来模拟运动轨迹显然是不合理的。因此, 我们在这里考虑引入抛物线模型, 它对于自变量 $(1, t, t^2)$ 是线性的, 但由于自变量本身具有非线性性, 它仍然能够模拟非线性的数据结构。在这一场景下:

$$\mathbf{A} = \begin{pmatrix} 1 & t_1 & t_1^2 \\ \vdots & \vdots & \vdots \\ 1 & t_m & t_m^2 \end{pmatrix}, \quad \mathbf{x} = \begin{pmatrix} \alpha \\ \beta \\ \gamma \end{pmatrix}, \quad \mathbf{b} = \begin{pmatrix} y_1 \\ \vdots \\ y_m \end{pmatrix}$$

可以将对应的公式带入最优解(2)中求得抛物线拟合场景下的最小二乘解。

思考: 前面讨论最小二乘问题时都假设矩阵 $\mathbf{A}$ 列满秩, 如果 $\mathbf{A}$ 并不列满秩时最小二乘问题又该如何求解? (请参考广义逆的)

作业

- (20 分) 已知向量 $(-1, 7), (1, 7), (2, 21)$ 三个点, 使用直线 $\mathbf{b} = \mathbf{C} + \mathbf{D}t$ 来拟合它们。
 - (10 分) 使用最小二乘法求解 $\mathbf{C}, \mathbf{D}$ 。
 - (10 分) 求出投影结果 $\mathbf{p}$ 以及误差 $\mathbf{e}$ 。
- (20 分) 考虑 $n = 3$ 的情况, 选取拟合模型为 $\alpha + \beta t + \gamma t^2$ 去拟合收集到的数据点 $\{(t_i, y_i)\}_{i=1}^5$, 其中

$$\mathbf{t} = (-2, -1, 0, 1, 2), \quad \mathbf{y} = (0, 0, 1, 0, 0).$$

- (20 分) 设 $\mathbf{X}_1, \mathbf{X}_2$ 都是方程组 $\mathbf{AX} = \mathbf{b}$ 的最小二乘解, 证明 $\mathbf{AX}_1 = \mathbf{AX}_2$ 。
- (20 分) 设 $\mathbf{A} \in \mathbb{R}^{m \times n}$, 求证: 对任意的 m 维实列向量 $\mathbf{b}$, n 元线性方程组 $\mathbf{A}^T \mathbf{A} \mathbf{x} = \mathbf{A}^T \mathbf{b}$ 一定有解。

5. (20 分) 设 $\mathbf{A} \in \mathbb{R}^{m \times n}$, $\mathbf{b}_1, \dots, \mathbf{b}_r \in \mathbb{R}^m$, 试证

$$\mathbf{x}^* = \min_x \sum_{i=1}^r \|\mathbf{Ax} - \mathbf{b}_i\|_2^2$$

的充分必要条件为 $\mathbf{x}^*$ 是方程组

$$\mathbf{Ax} = \frac{1}{r} \sum_{i=1}^r \mathbf{b}_i$$

的最小二乘解。