

第八讲：赋范线性空间与压缩映射原理及其应用

1 赋范线性空间与算子范数

定义 1.1 (范数与赋范线性空间). 设 U 是实数域 (或复数域) 上的线性空间. 若函数 $\|\cdot\|: U \rightarrow \mathbb{R}$ 满足:

1. **正定性**: $\|x\| \geq 0$, 且 $\|x\| = 0 \iff x = 0$;
2. **齐次性**: 对任意标量 a , $\|ax\| = |a| \|x\|$;
3. **三角不等式**: $\|x + y\| \leq \|x\| + \|y\|$, $\forall x, y \in U$,

则称 $\|\cdot\|$ 为 U 上的**范数**, $(U, \|\cdot\|)$ 称为**赋范线性空间**. 定义两点 x, y 间的距离为 $d(x, y) = \|x - y\|$.

例 1.1 (常见范数). 1. 在 $\mathbb{R}^n$ 中, 常用 ℓ_p 范数 ($1 \leq p \leq \infty$):

$$\|x\|_p = \left(\sum_{i=1}^n |x_i|^p \right)^{1/p}, \quad \|x\|_\infty = \max_{1 \leq i \leq n} |x_i|.$$

2. 在连续函数空间 $C[a, b]$ 中, 定义范数 $\|f\|_\infty = \max_{x \in [a, b]} |f(x)|$, 称为**一致范数** (或 **sup 范数**). 易验证它满足范数三条公理。
3. 设 T 为 $n \times n$ 正定矩阵, 则 $\|x\|_T = (x^\top T x)^{1/2}$ 定义了一个范数 (常称为 T -范数或加权欧氏范数)。

定义 1.2 (线性算子范数). 设 V, W 均为赋范线性空间, $A: V \rightarrow W$ 为有界线性算子 (即存在常数 M 使 $\|Ax\| \leq M\|x\|$ 对所有 $x \in V$ 成立). 定义 A 的**算子范数**为

$$\|A\| = \sup_{x \neq 0} \frac{\|Ax\|}{\|x\|} = \sup_{\|x\|=1} \|Ax\|.$$

特别地, 当 A 为方阵 ($V = \mathbb{R}^n$ 取 ℓ_2 范数) 时, 有 $\|A\| = \sqrt{\rho(A^\top A)}$, 其中 $\rho(\cdot)$ 表示谱半径 (最大特征值)。

例 1.2 (算子范数的性质). 设 A, B 均为 $\mathbb{R}^n \rightarrow \mathbb{R}^n$ 的线性映射 (矩阵), 则成立:

$$\|AB\| \leq \|A\| \|B\|.$$

证明思路: 对任意 x , $\|ABx\| \leq \|A\| \|Bx\| \leq \|A\| \|B\| \|x\|$, 再由定义即得。

2 压缩映射原理 (Banach 不动点定理)

定义 2.1 (压缩映射). 设 U 是赋范线性空间, $A : U \rightarrow U$ 是一个映射. 若存在常数 $L \in [0, 1)$ 使得

$$\|A(x) - A(y)\| \leq L \|x - y\|, \quad \forall x, y \in U,$$

则称 A 为**压缩映射** (或**压缩算子**).

注 2.1. 若 A 是线性算子, 则压缩条件等价于 $\|A\| \leq L < 1$.

定理 2.1 (Banach 不动点定理). 设 U 是完备的赋范线性空间 (即 Banach 空间), $A : U \rightarrow U$ 是压缩映射, 则 A 存在唯一的不动点 x^* (即 $A(x^*) = x^*$). 并且对任意初始点 x_0 , 迭代序列 $x_{n+1} = A(x_n)$ 收敛到 x^* .

证明. 取任意 $x_0 \in U$, 定义 $x_{n+1} = A(x_n)$. 则

$$\|x_{n+1} - x_n\| = \|A(x_n) - A(x_{n-1})\| \leq L \|x_n - x_{n-1}\| \leq \cdots \leq L^n \|x_1 - x_0\|.$$

从而对 $m > n$,

$$\|x_m - x_n\| \leq \sum_{k=n}^{m-1} \|x_{k+1} - x_k\| \leq \|x_1 - x_0\| \sum_{k=n}^{m-1} L^k \leq \frac{L^n}{1-L} \|x_1 - x_0\| \rightarrow 0 \quad (n \rightarrow \infty).$$

故 $\{x_n\}$ 是 Cauchy 列, 由完备性知存在极限 x^* . 由 A 的连续性 (压缩映射必连续) 得 $x^* = A(x^*)$. 唯一性: 若 x^*, y^* 均为不动点, 则 $\|x^* - y^*\| = \|A(x^*) - A(y^*)\| \leq L \|x^* - y^*\|$, 由于 $L < 1$, 必有 $\|x^* - y^*\| = 0$, 即 $x^* = y^*$. $\square$

3 应用一: 常微分方程解的存在唯一性

考虑初值问题

$$\frac{dy}{dx} = f(x, y), \quad y(x_0) = y_0.$$

将其转化为积分方程

$$y(x) = y_0 + \int_{x_0}^x f(t, y(t)) dt.$$

定义算子 A 为

$$A(y)(x) = y_0 + \int_{x_0}^x f(t, y(t)) dt.$$

则原问题的解等价于 A 的不动点。

例 3.1 (压缩性条件). 设 f 关于 y 满足 Lipschitz 条件:

$$|f(x, y_1) - f(x, y_2)| \leq L|y_1 - y_2|, \quad \forall x \in [x_0, x_0 + h], \quad \forall y_1, y_2.$$

则对任意 y_1, y_2 有

$$\begin{aligned}
\|A(y_1) - A(y_2)\|_\infty &= \max_{x \in [x_0, x_0+h]} \left| \int_{x_0}^x [f(t, y_1(t)) - f(t, y_2(t))] dt \right| \\
&\leq \max_{x \in [x_0, x_0+h]} \int_{x_0}^x |f(t, y_1) - f(t, y_2)| dt \\
&\leq L \max_x \int_{x_0}^x |y_1(t) - y_2(t)| dt \\
&\leq Lh \|y_1 - y_2\|_\infty.
\end{aligned}$$

因此, 当 $h < 1/L$ 时, A 是 $C[x_0, x_0+h]$ 上的压缩映射, 从而存在唯一的不动点, 即原微分方程在区间 $[x_0, x_0+h]$ 上存在唯一解。

4 应用二：梯度下降法的收敛性分析

考虑无约束优化问题 $\min_{\theta} f(\theta)$, 其中 $f: \mathbb{R}^n \rightarrow \mathbb{R}$ 二阶连续可微。梯度下降法迭代格式为

$$\theta_{t+1} = \theta_t - \eta \nabla f(\theta_t), \quad \eta > 0.$$

定义算子 $A(\theta) = \theta - \eta \nabla f(\theta)$, 则优化问题的稳定点 (满足 $\nabla f(\theta) = 0$) 恰为 A 的不动点。

例 4.1 (二次函数的梯度下降). 若 $f(\theta) = \theta^2$ (一维), 则 $\nabla f(\theta) = 2\theta$, 迭代为 $\theta_{t+1} = (1 - 2\eta)\theta_t$. 当 $0 < \eta < 1$ 时, $|1 - 2\eta| < 1$, 迭代收敛到不动点 $\theta = 0$ 。

为分析一般情形下的收敛性, 考虑 A 是否为压缩映射。计算

$$A(\theta_1) - A(\theta_2) = (\theta_1 - \theta_2) - \eta(\nabla f(\theta_1) - \nabla f(\theta_2)).$$

利用积分表示:

$$\nabla f(\theta_1) - \nabla f(\theta_2) = \int_0^1 \nabla^2 f(\theta_2 + s(\theta_1 - \theta_2)) (\theta_1 - \theta_2) ds.$$

记 $H(s) = \nabla^2 f(\theta_2 + s(\theta_1 - \theta_2))$, 则

$$A(\theta_1) - A(\theta_2) = \left[I - \eta \int_0^1 H(s) ds \right] (\theta_1 - \theta_2).$$

若假设 f 是 μ -强凸且 L -光滑的, 即

$$\mu I \preceq \nabla^2 f(\theta) \preceq LI, \quad \forall \theta,$$

则 $\int_0^1 H(s) ds$ 的特征值介于 μ 和 L 之间。从而矩阵 $I - \eta \int_0^1 H(s) ds$ 的特征值介于 $1 - \eta L$ 和 $1 - \eta \mu$ 之间。为使 A 成为压缩映射, 需 $|1 - \eta L| < 1$ 且 $|1 - \eta \mu| < 1$, 即

$$0 < \eta < \frac{2}{L}.$$

此时 $\|A(\theta_1) - A(\theta_2)\| \leq \max\{|1 - \eta \mu|, |1 - \eta L|\} \|\theta_1 - \theta_2\| < 1$, 迭代收敛到唯一不动点 (即全局极小值点)。