

第九讲：矩阵近似与主成分分析

1 问题背景：为什么要做矩阵近似

从图像处理的例子出发。在计算机中，一幅图像通常被表示为一个 $n \times n$ 的矩阵 A ，其中元素 a_{ij} 表示像素点的灰度值。若像素取值为区间 $[0, 256)$ 中的整数，则每个像素需要用 8 bits 存储，因此一幅图像的数据量约为

$$n \times n \times 8 \text{ bits.}$$

若考虑视频数据，还需乘以每秒帧数 f ，则一秒钟的数据量约为

$$f \times n \times n \times 8 \text{ bits/second.}$$

当图像分辨率较高时，存储与传输开销都会迅速增大，因此自然会提出如下问题：能否找到一种更经济的表示方式，对信号进行压缩？

例：一个最简单的例子是全 1 矩阵：

$$A = \begin{pmatrix} 1 & \cdots & 1 \\ \vdots & \ddots & \vdots \\ 1 & \cdots & 1 \end{pmatrix}_{n \times n}.$$

若直接存储，需要 $n^2 \times 8$ bits；但它也可以写成

$$A = \begin{pmatrix} 1 \\ \vdots \\ 1 \end{pmatrix} \begin{pmatrix} 1 & \cdots & 1 \end{pmatrix},$$

此时只需存储两个长度为 n 的向量，总开销约为 $(n + n) \times 8$ bits。也就是说，若矩阵能写成

$$A = \mathbf{a}\mathbf{b}^T,$$

则可以用更少的信息描述矩阵。

例：类似地，例如德国国旗对应的三色条纹图像，可以写成

$$A = \begin{pmatrix} a & a & b & b & c & c \\ \vdots & \vdots & \vdots & \vdots & \vdots & \vdots \\ a & a & b & b & c & c \end{pmatrix} = \begin{pmatrix} 1 \\ \vdots \\ 1 \end{pmatrix} \begin{pmatrix} a & a & b & b & c & c \end{pmatrix}.$$

同样只需要 $(n+n) \times 8$ bits 即可传输。即如果矩阵内部具有某种结构, 那么就有可能用更紧凑的形式对它进行表达。

若矩阵满足

$$A = u\vec{v}^T,$$

则 $\text{rank}(A) = 1$ 。但秩为 1 的矩阵只是非常特殊的情形。对于一般矩阵, 怎样系统地寻找一个“尽量低秩但又足够准确”的近似, 便是本讲的核心内容。

2 由特征值分解得到的近似思想

若矩阵 A 可以对角化, 则存在可逆矩阵 P 使得

$$P^{-1}AP = \text{diag}(\lambda_1, \dots, \lambda_n) = \Lambda.$$

于是

$$A = P\Lambda P^{-1} = \sum_{i=1}^n \lambda_i \vec{p}_i \vec{q}_i^T,$$

则传输 $\{(\vec{p}_i, \vec{q}_i)\}_{i=1}^n$ 也可以表达 A 。然而这种方式需要传输 $(2n+1) \times n \times 8$ bits, 并没有减少传输的信息量。

但可能出现两种情况:

1. $\lambda_i = \lambda_{i+1} = \dots = \lambda_n = 0$. 从某个位置开始, 后面的特征值恰好都为 0;
2. $\lambda_i \lambda_{i+1} \dots \lambda_n \approx 0$. 即使不完全为 0, 也许后面的特征值已经非常小, 可以忽略。

在这种情况下, 就可以用前若干项来近似原矩阵:

$$A \approx \sum_{j=1}^k \lambda_j \vec{p}_j \vec{q}_j^T.$$

这正是矩阵近似的基本思想。

2.1 对称矩阵的情形

若 A 是对称矩阵, 则可以正交对角化:

$$A = P\Lambda P^T = \sum_{i=1}^n \lambda_i \vec{p}_i \vec{p}_i^T,$$

例: 设

$$A = \begin{pmatrix} 5 & 2 \\ 2 & 2 \end{pmatrix}.$$

它的两个特征值为

$$\lambda_1 = 6, \quad \lambda_2 = 1,$$

对应的一组单位特征向量可取为

$$\vec{v}_1 = \frac{1}{\sqrt{5}} \begin{pmatrix} 2 \\ 1 \end{pmatrix}, \quad \vec{v}_2 = \frac{1}{\sqrt{5}} \begin{pmatrix} 1 \\ -2 \end{pmatrix}.$$

于是

$$A = \lambda_1 \vec{v}_1 \vec{v}_1^T + \lambda_2 \vec{v}_2 \vec{v}_2^T.$$

计算第一项可得

$$\lambda_1 \vec{v}_1 \vec{v}_1^T = \begin{pmatrix} 4.8 & 2.4 \\ 2.4 & 1.2 \end{pmatrix},$$

它已经相当接近原矩阵

$$A = \begin{pmatrix} 5 & 2 \\ 2 & 2 \end{pmatrix}.$$

这说明，若最大的特征值远大于其余特征值，那么仅仅保留对应的主方向就能得到较好的近似。同时，保留高特征值，能保留更准确的 A 。

3 截断特征展开的误差估计

设 A 为对称矩阵，特征值满足

$$|\lambda_1| \geq |\lambda_2| \geq \cdots \geq |\lambda_n|,$$

对应单位特征向量为 $\{\vec{p}_1, \dots, \vec{p}_n\}$ 。记

$$\hat{A} = \sum_{i=1}^k \lambda_i \vec{p}_i \vec{p}_i^T.$$

则有如下结论：

$$\|\hat{A} - A\| \leq |\lambda_{k+1}|.$$

证明：

由定义可得

$$A - \hat{A} = \sum_{i=k+1}^n \lambda_i \vec{p}_i \vec{p}_i^T.$$

该矩阵的非零特征值恰好是 $\lambda_{k+1}, \dots, \lambda_n$ ，因此它的算子范数为这些特征值绝对值中的最大者，即

$$\|A - \hat{A}\| = \max\{|\lambda_{k+1}|, \dots, |\lambda_n|, |0|\} = |\lambda_{k+1}|.$$

证毕。

这个定理表明：若后续特征值很小，那么截断后的矩阵近似误差也很小。因此，按特征值大小选取主要成分来近似矩阵，就是一种非常自然且有效的方法。

这种基于主特征值与主特征向量对矩阵进行近似的过程，称为**主成分分析 (Principal Component Analysis, PCA)**。

4 PCA 的求解步骤

主成分分析的核心，是依次寻找最重要的几个方向。直观地说，第一个主方向应当是使矩阵作用效果最强的方向。

由 Rayleigh 熵的思想可知，第一个主方向对应于最大的特征值，其刻画为

$$|\lambda_1| = \max_{\vec{x} \neq 0} \frac{\|A\vec{x}\|}{\|\vec{x}\|}.$$

这说明：求第一主成分，本质上就是在所有非零向量中，寻找一个经过 A 作用后伸长比例最大的方向。

在求得第一个主方向后，第二个主方向应当与第一个正交，并在这个约束下继续使伸长比例最大。因此

$$|\lambda_2| = \max_{\vec{x} \in \text{span}\{\vec{p}_1\}^\perp} \frac{\|A\vec{x}\|}{\|\vec{x}\|}.$$

证明思路：

将 A 写成

$$A = \lambda_1 \vec{p}_1 \vec{p}_1^T + A'.$$

则对 $\forall \vec{x} \in \text{span}\{\vec{p}_1\}^\perp$ ，有 $A\vec{x} = A'\vec{x}$ ，故

$$\frac{\|A\vec{x}\|}{\|\vec{x}\|} = \frac{\|A'\vec{x}\|}{\|\vec{x}\|} \leq |\lambda_2|$$

等号在 $\vec{x}$ 为 λ_2 对应特征向量时取到。因此，在与第一主方向正交的子空间中继续求最大伸长比例，得到的正是第二主方向。

同理，可以递归地得到第 i 个主成分：

$$\vec{p}_i^* = \arg \max_{\vec{x} \in \text{span}\{\vec{p}_1, \dots, \vec{p}_{i-1}\}^\perp} \frac{\|A\vec{x}\|}{\|\vec{x}\|}.$$

这表明 PCA 的主方向可以理解为一组依次求得的、互相正交的“最重要方向”。

5 从数据逼近的角度理解 PCA

前面的讨论是从矩阵分解出发的。下面换一个角度，从数据表示与降维的角度理解 PCA。

设有数据样本

$$\{\vec{x}^1, \vec{x}^2, \dots, \vec{x}^n\}, \quad \vec{x}_i \in \mathbb{R}^d.$$

理论上，表示这些数据需要 d 个基方向。若记一组基为

$$\{\vec{z}_1, \vec{z}_2, \dots, \vec{z}_d\},$$

那么每个样本都可以表示成

$$\vec{x}_i = \sum_{j=1}^d w_{ij} \vec{z}_j.$$

现在希望减少基的数量，只保留 $d' < d$ 个方向，使得

$$\vec{x}_i \approx \sum_{j=1}^{d'} w_{ij} \vec{z}_j, \quad i = 1, \dots, n.$$

这就是降维问题。

通常先将数据做中心化处理，即要求样本均值为 0，即对 $\forall i$ ，取 $\{\vec{z}_1, \dots, \vec{z}_n\}$ 为标准正交基，则 $\frac{1}{n} \sum_{i=1}^n \vec{x}_i = \vec{0}$ 。若原始数据均值不为 0，则先令

$$\tilde{\vec{x}}_i = \vec{x}_i - \frac{1}{n} \sum_{i=1}^n \vec{x}_i.$$

后续讨论默认数据已经中心化。

5.1 一维情形

先考虑最简单的情形 $d' = 1$ 。这时希望用一个方向 $\vec{z}$ 来近似所有数据点，即求解

$$\min_{\vec{z}, \{a_i\}} \frac{1}{n} \sum_{i=1}^n \|\vec{x}_i - a_i \vec{z}\|^2.$$

展开得

$$\frac{1}{n} \sum_{i=1}^n (\vec{x}_i - a_i \vec{z})^T (\vec{x}_i - a_i \vec{z}) = \frac{1}{n} \sum_{i=1}^n \left(\|\vec{x}_i\|^2 - 2a_i \vec{z}^T \vec{x}_i + a_i^2 \right).$$

对 a_i 求最优可得

$$a_i = \vec{z}^T \vec{x}_i.$$

代回后，目标函数等价于最小化

$$-\frac{1}{n} \sum_{i=1}^n \vec{z}^T \vec{x}_i (\vec{x}_i)^T \vec{z} = -\frac{1}{n} \vec{z}^T X X^T \vec{z},$$

其中 X 为数据矩阵。

所以在一维情形下，做 PCA 等价于找一个向量，尽可能表示全部数据。

5.2 多维情形

若希望保留 $d' > 1$ 个方向，则设有多个逼近基

$$Z = \{\vec{z}_1, \vec{z}_2, \dots, \vec{z}_{d'}\}$$

此时数据逼近问题为

$$\min_{\{\vec{z}_j\}, W} \frac{1}{n} \sum_{i=1}^n \left\| \vec{x}_i - \sum_{j=1}^{d'} w_{ij} \vec{z}_j \right\|^2.$$

其中 $W = (w_{ij})$ 为待求系数矩阵。这里有两层优化，包括 W 的优化和 $\{\vec{z}_1, \vec{z}_2, \dots, \vec{z}_{d'}\}$ 的优化。

对 W 的优化：

对于固定的基向量组 $\{\vec{z}_1, \vec{z}_2, \dots, \vec{z}_{d'}\}$ 。

$$\min_W \frac{1}{n} \sum_{i=1}^n \left\| \vec{x}_i - \sum_{j=1}^{d'} w_{ij} \vec{z}_j \right\|^2.$$

x_i 到 $\text{span}\{\vec{z}_1, \vec{z}_2, \dots, \vec{z}_{d'}\}$ 的正交投影，即是最优解。

$$w_{ij}^* = \langle \vec{x}_i, \vec{z}_j \rangle.$$

推导过程：

$$\begin{aligned} \left\| \vec{x}_i - \sum_{j=1}^{d'} w_{ij} \vec{z}_j \right\|^2 &= \left\langle \vec{x}_i - \sum_{j=1}^{d'} w_{ij} \vec{z}_j, \vec{x}_i - \sum_{j=1}^{d'} w_{ij} \vec{z}_j \right\rangle \\ &\propto \vec{x}_i^T \sum_{j=1}^{d'} w_{ij} \vec{z}_j + \sum_{j=1}^{d'} w_{ij}^2 \\ &\Rightarrow w_{ij}^* = \langle \vec{x}_i, \vec{z}_j \rangle. \end{aligned}$$

进一步，最小化重构误差等价于最大化方差：

$$\begin{aligned} \frac{1}{n} \sum_{i=1}^n \left\| \vec{x}_i - \sum_{j=1}^{d'} w_{ij} \vec{z}_j \right\|^2 &\propto \frac{1}{n} \sum_{i=1}^n \sum_{j=1}^{d'} \vec{z}_j^T \vec{x}_i \vec{x}_i^T \vec{z}_j - \frac{2}{n} \sum_{i=1}^n \sum_{j=1}^{d'} \vec{z}_j^T \vec{x}_i \vec{x}_i^T \vec{z}_j \\ &= - \sum_{j=1}^{d'} \vec{z}_j^T \left(\frac{1}{n} \sum_{i=1}^n \vec{x}_i \vec{x}_i^T \right) \vec{z}_j \\ &\propto -\text{tr}(Z^T X X^T Z). \end{aligned}$$

PCA 等价于：

$$\max_Z \text{tr}(Z^T X X^T Z), \quad \text{s.t.} \quad Z^T Z = I,$$

其中数据矩阵 $X = (\vec{x}_1, \dots, \vec{x}_n) \in \mathbb{R}^{d \times n}$ ，投影矩阵 $Z = (\vec{z}_1, \dots, \vec{z}_{d'}) \in \mathbb{R}^{d \times d'}$ 。

优化问题展开为：

$$\max_{\vec{z}_1, \dots, \vec{z}_{d'}} \sum_{j=1}^{d'} \vec{z}_j^T X X^T \vec{z}_j, \quad \text{s.t.} \quad \vec{z}_i^T \vec{z}_j = \delta_{ij}. \quad (1)$$

求解策略：依次优化各主成分

1. 优化 $\vec{z}_1$ ： $\vec{z}_1$ 为 $X X^T$ 的第一主成分（即最大特征值对应的单位特征向量）。

2. 优化 $\vec{z}_2$: 在约束 $\vec{z}_2 \in \text{span}\{\vec{z}_1\}^\perp$ (与 $\vec{z}_1$ 正交) 下, $\vec{z}_2$ 为 XX^T 的第二主成分 (次大特征值对应的单位特征向量)。
3. 继续迭代: 依此类推, $\vec{z}_k$ 为 XX^T 的第 k 大特征值对应的单位特征向量。

PCA 的优化顺序: 按特征值从大到小依次求解。

6 总结

综上, PCA 可以从两个等价视角来理解:

1. **矩阵近似视角**: 保留最大的若干个特征值及其对应特征向量, 用低秩矩阵近似原矩阵;
2. **数据降维视角**: 寻找若干个彼此正交的主方向, 使样本投影后的总体方差最大, 从而用更少的维度保留尽可能多的信息。

因此, PCA 的本质就是在信息损失尽量小的前提下, 找到一组最重要的正交方向, 用来描述原始矩阵或原始数据中的主要结构。