

第十讲

从数据分析角度理解 PCA。 回顾 PCA 的形式, 用 $\text{span}\{\vec{z}_1, \dots, \vec{z}_{d'}\}$ 中元素代替原始数据 $\{\vec{x}_1, \dots, \vec{x}_n\}$ 。等价于

$$\begin{aligned} & \min \frac{1}{n} \sum_{i=1}^n \left\| \vec{x}_i - \sum_{j=1}^{d'} w_{ij} \vec{z}_j \right\|^2 \\ \Rightarrow & \min \frac{1}{n} \sum_{j=1}^{d'} \vec{z}_j^T X \cdot X^T \vec{z}_j \quad X = (\vec{x}_1 \dots \vec{x}_n) \end{aligned}$$

注意到 $\frac{1}{n} X \cdot X^T = \frac{1}{n} (\vec{x}_1 \dots \vec{x}_n) \cdot \begin{pmatrix} \vec{x}_1^T \\ \vdots \\ \vec{x}_n^T \end{pmatrix} = \frac{1}{n} \sum_{i=1}^n \vec{x}_i \cdot \vec{x}_i^T$

由 $\frac{1}{n} \sum_{i=1}^n \vec{x}_i = \vec{0}$ 知

$$\begin{aligned} \frac{1}{n} \sum_{i=1}^n \vec{x}_i \cdot \vec{x}_i^T &= \frac{1}{n} \sum_{i=1}^n (\vec{x}_i - \vec{\bar{x}}) \cdot (\vec{x}_i - \vec{\bar{x}})^T \\ &\approx \text{Var}(\vec{x}) \end{aligned}$$

定义: $\vec{x} = (y_1, \dots, y_d)$ 。其中 y_i 为随机变量。

y_i 的方差为 $\text{Var}(y_i) = E(y_i - Ey_i)^2$ 。

y_i, y_j 之间的协方差为 $\text{Cov}(y_i, y_j) = E[(y_i - Ey_i)(y_j - Ey_j)]$ 。

随机向量 $\vec{x}$ 的协方差 (矩阵) 是一个 $d \times d$ 维矩阵. $\text{Var}(\vec{x}) = E[(\vec{x} - E\vec{x})(\vec{x} - E\vec{x})^T]$ 。

$\text{Var}(\vec{x})_{ij} = \text{Cov}(y_i, y_j)$. $\text{Var}(\vec{x})_{ii} = \text{Var}(y_i)$ 。

直观上, 平均数会逼近真实均值 (期望), 记 $\text{Var}(\vec{x})$ 为 Σ 。

若用 Σ 代替 $\sum_{j=1}^{d'} \vec{z}_j^T \Sigma \vec{z}_j$, 问题变成了对 Σ , 即数据 $\vec{y}$ 的协方差矩阵做 PCA。

考虑 $d' = 1$, $\max_{\vec{z}: \|\vec{z}\|=1} \vec{z}^T \Sigma \vec{z}$ 的含义是什么?

由期望的线性性

$$\begin{aligned} E(\xi_1 + \xi_2) &= E\xi_1 + E\xi_2, \quad E(\vec{a}^T \vec{x}) = Ea_1 y_1 + \dots + Ea_d y_d \\ &= a_1 \cdot Ey_1 + \dots + a_d Ey_d \end{aligned}$$

而假设 $E\vec{x} = \vec{0}$, 即 $Ey_1 = \dots = Ey_d = 0 \Rightarrow E(\vec{a}^T \vec{x}) = 0$ 。

$$\text{Var}(\vec{a}^T \vec{x}) = E(\vec{a}^T \vec{x})^2 = E\vec{a}^T \vec{x} \vec{x}^T \vec{a} = \vec{a}^T E[(\vec{x} - E\vec{x})(\vec{x} - E\vec{x})^T] \vec{a} = \vec{a}^T \Sigma \vec{a}.$$

在 $d' = 1$ 下的 PCA, $\max_{\vec{z}: \|\vec{z}\|=1} \vec{z}^T \Sigma \vec{z} \Leftrightarrow \max_{\vec{z}: \|\vec{z}\|=1} \text{Var}(\vec{z}^T \vec{x})$ 。

即找数据 $\vec{x}$ 的一个线性组合的方向, 使其方差最大。 $\frac{1}{n} \sum_{i=1}^n \vec{x}_i \cdot \vec{x}_i^T \approx \text{Var}(\vec{x})$

总结: 矩阵 (协方差) 层面的 PCA $\Leftrightarrow$ 数据降维视角下的 PCA 是样本协方差的 PCA。

例: $X = \begin{pmatrix} 1 & 2 & 3 & 4 & 5 \\ 3 & 2 & 1 & 4 & 5 \end{pmatrix}$, 第一个特征均值为 3, 第二个特征均值为 3, 中心化后的数据 $X = \begin{pmatrix} -2 & -1 & 0 & 1 & 2 \\ 0 & -1 & -2 & 1 & 2 \end{pmatrix}$ 。对中心化后的 X 算协方差矩阵 $X \cdot X^T = \begin{pmatrix} 10 & 6 \\ 6 & 10 \end{pmatrix}$ 。

其特征值为 $\lambda_1 = 16, \lambda_2 = 4$ 。对应 $\vec{v}_1 = \begin{pmatrix} \frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} \end{pmatrix}, \vec{v}_2 = \begin{pmatrix} \frac{1}{\sqrt{2}} \\ -\frac{1}{\sqrt{2}} \end{pmatrix}$ 。

则

$$\begin{aligned} X \cdot X^T &= 16 \cdot \vec{v}_1 \cdot \vec{v}_1^T + 4 \cdot \vec{v}_2 \cdot \vec{v}_2^T \\ &= 16 \begin{pmatrix} \frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} \end{pmatrix} \begin{pmatrix} \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} \end{pmatrix} + 4 \begin{pmatrix} \frac{1}{\sqrt{2}} \\ -\frac{1}{\sqrt{2}} \end{pmatrix} \begin{pmatrix} \frac{1}{\sqrt{2}} & -\frac{1}{\sqrt{2}} \end{pmatrix} \\ &= 16 \begin{pmatrix} \frac{1}{2} & \frac{1}{2} \\ \frac{1}{2} & \frac{1}{2} \end{pmatrix} + 4 \begin{pmatrix} \frac{1}{2} & -\frac{1}{2} \\ -\frac{1}{2} & \frac{1}{2} \end{pmatrix} = \begin{pmatrix} 10 & 6 \\ 6 & 10 \end{pmatrix} \end{aligned}$$

而第一主成分 $16\vec{v}_1\vec{v}_1^T = \begin{pmatrix} 8 & 8 \\ 8 & 8 \end{pmatrix}$, 占主要比例。

降维后的数据: 方向: $\vec{v}_1 = \begin{pmatrix} \frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} \end{pmatrix}$, 在 $(\vec{x}_1 \cdots \vec{x}_j)$ 上的逼近为

$$\langle \vec{x}_1, \vec{v}_1 \rangle \vec{v}_1, \dots, \langle \vec{x}_j, \vec{v}_1 \rangle \vec{v}_1$$

$$\begin{pmatrix} 1 \\ 3 \end{pmatrix} \leftrightarrow \begin{pmatrix} 2 \\ 2 \end{pmatrix}, \begin{pmatrix} 2 \\ 2 \end{pmatrix} \leftrightarrow \begin{pmatrix} 2 \\ 2 \end{pmatrix}, \begin{pmatrix} 3 \\ 1 \end{pmatrix} \leftrightarrow \begin{pmatrix} 2 \\ 2 \end{pmatrix}, \begin{pmatrix} 4 \\ 4 \end{pmatrix} \leftrightarrow \begin{pmatrix} 4 \\ 4 \end{pmatrix}, \begin{pmatrix} 5 \\ 5 \end{pmatrix} \leftrightarrow \begin{pmatrix} 5 \\ 5 \end{pmatrix}。$$

主成分分析针对的是半正定对称矩阵 $A = P \Lambda P^T = \sum_{i=1}^n \lambda_i \vec{p}_i \vec{p}_i^T$ 。

前 k 个主成分为 $\sum_{i=1}^k \lambda_i \vec{p}_i \vec{p}_i^T$ 。通常称前 k 个主成分解释占比为 $\frac{\sum_{i=1}^k \lambda_i}{\sum_{i=1}^d \lambda_i}$ 。

在上例中, $\lambda_1 = 16, \lambda_2 = 4$, 则第一主成分占比为 $\frac{4}{5}$, 这个占比的含义是?

第一主成分分析 $\Leftrightarrow \max_{\vec{a}} \text{Var}(\vec{a}^T \vec{x})$ 。

引理: $\text{Var}(\xi_1 + \xi_2) = \text{Var}(\xi_1) + \text{Var}(\xi_2) + 2\text{Cov}(\xi_1, \xi_2)$ (设 $E(\xi_1) = E(\xi_2) = 0$)

证: $\text{Var}(\xi_1 + \xi_2) = E(\xi_1 + \xi_2)^2 = E[\xi_1^2 + 2\xi_1 \cdot \xi_2 + \xi_2^2] = E\xi_1^2 + 2E\xi_1 \cdot \xi_2 + E\xi_2^2$

若求第二主成分: $\max_{\vec{a}_2^T \vec{a}_1=0, \|\vec{a}_2\|=1} \vec{a}_2^T \cdot \text{Var}(\vec{x}) \cdot \vec{a}_2$, 即对矩阵做第二主成分分析

$\rightarrow \vec{a}_1, \dots, \vec{a}_k$ 为前 k 个特征值对应的正交特征向量

若 $k = n$, 则 $\vec{a}_1 \dots \vec{a}_n$ 为 $\text{Var}(\vec{x})$ 的 n 个特征向量。

引理: $\text{Var}(\vec{a}_1^T \vec{x} + \vec{a}_2^T \vec{x}) = \vec{a}_1^T \text{Var}(\vec{x}) \vec{a}_1 + \vec{a}_2^T \text{Var}(\vec{x}) \vec{a}_2 + 2\vec{a}_1 \text{Var}(\vec{x}) \vec{a}_2$

证: $(\vec{a}_1^T \vec{x} + \vec{a}_2^T \vec{x})^2 = \vec{a}_1^T \vec{x} \vec{x}^T \vec{a}_1 + \vec{a}_2^T \vec{x} \vec{x}^T \vec{a}_2 + 2\vec{a}_1^T \vec{x} \vec{x}^T \vec{a}_2$

取期望即得结论。

由 PCA 过程知 $\vec{a}_2$ 为特征向量, $Var(\vec{x})\vec{a}_2 = \lambda_2\vec{a}_2, \vec{a}_1^T Var(\vec{x})\vec{a}_2 = \lambda_2\vec{a}_1^T \vec{a}_2 = 0$

$$\Rightarrow Var(\vec{a}_1\vec{x}_1 + \cdots + \vec{a}_k\vec{x}_k) = \sum_{i=1}^k \vec{a}_i^T Var(\vec{x}_i) \vec{a}_i = \sum_{i=1}^k \lambda_i$$

$$\text{而 } Var(\vec{x}) = \begin{pmatrix} Var(y_1) & * & \cdots & * \\ \vdots & \ddots & & \vdots \\ * & \cdots & & Var(y_n) \end{pmatrix} \Rightarrow tr(Var(\vec{x})) = \sum_{i=1}^n Var(y_i), \text{ 即所}$$

有变量的方差和。

$\sum_{i=1}^n \lambda_i = tr(Var(\vec{x})) = \sum_{i=1}^n Var(y_i)$, $\frac{\sum_{i=1}^k \lambda_i}{\sum_{i=1}^n \lambda_i}$ 是主成分部分在整体方差中的占比。

PCA 的本质

1. 矩阵的近似表达 $A = \sum_{i=1}^n \lambda_i \vec{p}_i \vec{p}_i^T \approx \sum_{i=1}^k \lambda_i \vec{p}_i \vec{p}_i^T \quad (k \ll n)$ 。

2. 数据层面: 数据的一个维降维近似 $\min_Z \sum_{j=1}^k \vec{z}_j^T X \cdot X^T \vec{z}_j \quad Z^T Z = I$

$$\iff \min \frac{1}{n} \sum_{i=1}^n \|\vec{x}_i - \sum_{j=1}^k w_{ij} \vec{z}_j\|^2 \quad Z^T Z = I$$

3. 方差层面: 寻找方向 $\vec{a}$, 使得捕获随机向量 $\vec{x}$ 的最大变化方向

$$\max_{\vec{a}} Var(\vec{a}^T \vec{x}) \quad \|\vec{a}\| = 1$$