

第十八讲 最小二乘、神经网络求导与主成分分析

最小二乘法回顾

给定数据 $(\vec{x}_i, y_i)$, 假设线性模型为

$$y = \vec{x}^\top \vec{\beta}.$$

为了尽可能拟合 y 与 $\vec{x}$ 之间的关系, 考虑如下最小二乘目标:

$$\min_{\vec{\beta}} \sum_{i=1}^n \left(y_i - \vec{x}_i^\top \vec{\beta} \right)^2.$$

第一种求解方法

对目标函数关于 $\vec{\beta}$ 求导:

$$\begin{aligned} \frac{\partial}{\partial \vec{\beta}} \sum_{i=1}^n \left(y_i - \vec{x}_i^\top \vec{\beta} \right)^2 &= \sum_{i=1}^n \frac{\partial}{\partial \vec{\beta}} \left(y_i - \vec{x}_i^\top \vec{\beta} \right)^2 \\ &= \sum_{i=1}^n 2 \left(y_i - \vec{x}_i^\top \vec{\beta} \right) \frac{\partial \left(y_i - \vec{x}_i^\top \vec{\beta} \right)}{\partial \vec{\beta}} \\ &= -2 \sum_{i=1}^n \left(y_i - \vec{x}_i^\top \vec{\beta} \right) \vec{x}_i. \end{aligned}$$

令上式为 0, 得到

$$\left(\sum_{i=1}^n \vec{x}_i \vec{x}_i^\top \right) \vec{\beta} = \sum_{i=1}^n \vec{x}_i y_i.$$

取

$$X = \begin{pmatrix} \vec{x}_1^\top \\ \vdots \\ \vec{x}_n^\top \end{pmatrix}, \quad \vec{y} = \begin{pmatrix} y_1 \\ \vdots \\ y_n \end{pmatrix},$$

则

$$\sum_{i=1}^n \vec{x}_i \vec{x}_i^\top = X^\top X, \quad \sum_{i=1}^n \vec{x}_i y_i = X^\top \vec{y}.$$

故正规方程为

$$(X^T X) \vec{\beta} = X^T \vec{y}.$$

若 X 矩阵列满秩, 则

$$\vec{\beta} = (X^T X)^{-1} X^T \vec{y}.$$

第二种求解方法

将

$$\sum_{i=1}^n (\vec{x}_i^T \vec{\beta} - y_i)^2$$

看作

$$\|X\vec{\beta} - \vec{y}\|^2.$$

于是

$$\begin{aligned} \frac{\partial}{\partial \vec{\beta}} \|X\vec{\beta} - \vec{y}\|^2 &= \frac{\partial}{\partial \vec{\beta}} (\vec{\beta}^T X^T X \vec{\beta} - 2\vec{\beta}^T X^T \vec{y} + \vec{y}^T \vec{y}) \\ &= 2X^T X \vec{\beta} - 2X^T \vec{y}. \end{aligned}$$

令上式为零, 同样得到

$$(X^T X) \vec{\beta} = X^T \vec{y},$$

若 X 列满秩, 则

$$\vec{\beta} = (X^T X)^{-1} X^T \vec{y}.$$

神经网络与非线性变换

神经网络是由多层非线性函数组合而成的一个变换, 可以将向量 $\vec{x}$ 变为另一个向量 $\vec{z}$ 。例如一个单层变换可以写为

$$\vec{z} = \sigma(W\vec{x} + \vec{b}),$$

其中 σ 是一个非线性函数。可取 sigmoid 函数

$$\sigma(t) = \frac{1}{1 + e^{-t}}.$$

这里 $\sigma(\vec{y})$ 表示对 $\vec{y}$ 的每个元素分别作用 σ 函数, 即

$$\sigma(\vec{y}) = \begin{pmatrix} \sigma(y_1) \\ \vdots \\ \sigma(y_m) \end{pmatrix}.$$

矩阵对矩阵的导数

定义 1 设矩阵 $Y \in \mathbb{R}^{m \times n}$ 的每一个元素都是矩阵 $X \in \mathbb{R}^{p \times q}$ 中元素的函数, 则定义 Y 对 X 的导数为

$$\frac{\partial Y}{\partial X} = \frac{\partial \text{Vec}(Y)}{\partial \text{Vec}(X)}.$$

其中 $\text{Vec}(\cdot)$ 表示按列展开算子。

具体地, 若

$$A = (\vec{a}_1, \dots, \vec{a}_n) \in \mathbb{R}^{m \times n},$$

其中 $\vec{a}_j$ 表示矩阵 A 的第 j 列, 则

$$\text{Vec}(A) = \begin{pmatrix} \vec{a}_1 \\ \vdots \\ \vec{a}_n \end{pmatrix}.$$

也就是说, $\text{Vec}(A)$ 是将矩阵 A 按列依次拉成的向量。

因此, 对于

$$X = (x_{ij}) \in \mathbb{R}^{p \times q}, \quad Y = (y_{ij}) \in \mathbb{R}^{m \times n},$$

有

$$\text{Vec}(X) = \begin{pmatrix} x_{11} \\ x_{21} \\ \vdots \\ x_{p1} \\ x_{12} \\ x_{22} \\ \vdots \\ x_{p2} \\ \vdots \\ x_{1q} \\ x_{2q} \\ \vdots \\ x_{pq} \end{pmatrix}, \quad \text{Vec}(Y) = \begin{pmatrix} y_{11} \\ y_{21} \\ \vdots \\ y_{m1} \\ y_{12} \\ y_{22} \\ \vdots \\ y_{m2} \\ \vdots \\ y_{1n} \\ y_{2n} \\ \vdots \\ y_{mn} \end{pmatrix}.$$

于是

$$\frac{\partial Y}{\partial X} = \frac{\partial \text{Vec}(Y)}{\partial \text{Vec}(X)} \in \mathbb{R}^{mn \times pq}.$$

展开后为

$$\frac{\partial Y}{\partial X} = \begin{pmatrix} \frac{\partial y_{11}}{\partial x_{11}} & \frac{\partial y_{11}}{\partial x_{21}} & \dots & \frac{\partial y_{11}}{\partial x_{p1}} & \frac{\partial y_{11}}{\partial x_{12}} & \dots & \frac{\partial y_{11}}{\partial x_{pq}} \\ \frac{\partial y_{21}}{\partial x_{11}} & \frac{\partial y_{21}}{\partial x_{21}} & \dots & \frac{\partial y_{21}}{\partial x_{p1}} & \frac{\partial y_{21}}{\partial x_{12}} & \dots & \frac{\partial y_{21}}{\partial x_{pq}} \\ \vdots & \vdots & & \vdots & \vdots & & \vdots \\ \frac{\partial y_{m1}}{\partial x_{11}} & \frac{\partial y_{m1}}{\partial x_{21}} & \dots & \frac{\partial y_{m1}}{\partial x_{p1}} & \frac{\partial y_{m1}}{\partial x_{12}} & \dots & \frac{\partial y_{m1}}{\partial x_{pq}} \\ \frac{\partial y_{12}}{\partial x_{11}} & \frac{\partial y_{12}}{\partial x_{21}} & \dots & \frac{\partial y_{12}}{\partial x_{p1}} & \frac{\partial y_{12}}{\partial x_{12}} & \dots & \frac{\partial y_{12}}{\partial x_{pq}} \\ \vdots & \vdots & & \vdots & \vdots & & \vdots \\ \frac{\partial y_{mn}}{\partial x_{11}} & \frac{\partial y_{mn}}{\partial x_{21}} & \dots & \frac{\partial y_{mn}}{\partial x_{p1}} & \frac{\partial y_{mn}}{\partial x_{12}} & \dots & \frac{\partial y_{mn}}{\partial x_{pq}} \end{pmatrix}.$$

其中, 第 j 列表示 $\text{Vec}(Y)$ 对 $\text{Vec}(X)$ 中第 j 个分量的偏导。换言之, 行和列的排列顺序都与 Vec 的按列展开顺序一致。对于 X , 这个顺序为

$$x_{11}, x_{21}, \dots, x_{p1}, x_{12}, x_{22}, \dots, x_{p2}, \dots, x_{1q}, x_{2q}, \dots, x_{pq}.$$

由此, 展开后的矩阵即为 $\frac{\partial Y}{\partial X}$ 的向量表了。

单层神经网络的参数导数

设

$$W = \begin{pmatrix} \vec{w}_1^\top \\ \vdots \\ \vec{w}_m^\top \end{pmatrix}, \quad \vec{a} = W\vec{x} + \vec{b}, \quad \vec{z} = \sigma(\vec{a}).$$

则

$$a_i = \vec{w}_i^\top \vec{x} + b_i, \quad z_i = \sigma(a_i).$$

对于 W 中的元素 w_{ij} , 有

$$\frac{\partial \vec{z}}{\partial w_{ij}} = \frac{\partial}{\partial w_{ij}} \sigma(W\vec{x} + \vec{b}) = \begin{pmatrix} 0 \\ \vdots \\ \sigma'(\vec{w}_i^\top \vec{x} + b_i) x_j \\ \vdots \\ 0 \end{pmatrix}.$$

由于

$$\frac{d}{dt} \frac{1}{1 + e^{-t}} = \frac{e^{-t}}{(1 + e^{-t})^2} = \sigma(t)(1 - \sigma(t)),$$

因此

$$\frac{\partial \vec{z}}{\partial w_{ij}} = \begin{pmatrix} 0 \\ \vdots \\ \sigma(\vec{w}_i^\top \vec{x} + b_i)(1 - \sigma(\vec{w}_i^\top \vec{x} + b_i)) x_j \\ \vdots \\ 0 \end{pmatrix}.$$

即

$$\frac{\partial \vec{z}}{\partial W} = \begin{pmatrix} \vec{x}\sigma(\vec{w}_1^\top \vec{x} + b_1)(1 - \sigma(\vec{w}_1^\top \vec{x} + b_1)) & 0 & \cdots & 0 \\ 0 & \vec{x}\sigma(\vec{w}_2^\top \vec{x} + b_2)(1 - \sigma(\vec{w}_2^\top \vec{x} + b_2)) & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & \cdots & 0 & \vec{x}\sigma(\vec{w}_m^\top \vec{x} + b_m)(1 - \sigma(\vec{w}_m^\top \vec{x} + b_m)) \end{pmatrix}$$

或者 $\frac{\partial \vec{z}}{\partial W} = \frac{\partial \vec{z}}{\partial \text{Vec}(W)}$, 由 $\vec{z} = \sigma(W\vec{x} + \vec{b})$, 记 $\vec{a} = W\vec{x} + \vec{b}$ 则

$$\frac{\partial \vec{z}}{\partial \text{Vec}(W)} = \begin{pmatrix} \frac{\partial z_i}{\partial \text{Vec}(W)} \\ \vdots \\ \frac{\partial z_m}{\partial \text{Vec}(W)} \end{pmatrix}$$

由链式法则

$$\frac{\partial \vec{z}}{\partial \text{Vec}(W)} = \frac{\partial \vec{z}}{\partial \vec{a}} \frac{\partial \vec{a}}{\partial \text{Vec}(W)}.$$

其中

$$\frac{\partial \vec{z}}{\partial \vec{a}} = \text{diag}(\sigma'(a_1), \dots, \sigma'(a_m)) = \text{diag}(\sigma(a_1)(1 - \sigma(a_1)), \dots, \sigma(a_m)(1 - \sigma(a_m))).$$

并且

$$\frac{\partial a_k}{\partial \vec{w}_i} = \begin{cases} \vec{x}^\top, & k = i, \\ \vec{0}^\top, & k \neq i. \end{cases}$$

因此

$$\frac{\partial z_i}{\partial \text{Vec}(W)} = \sigma(a_i)(1 - \sigma(a_i)) (\vec{0}^\top, \dots, \vec{x}^\top, \vec{0}^\top, \dots, \vec{0}^\top),$$

其中 $\vec{x}^\top$ 位于第 i 个分块位置。于是

$$\frac{\partial \vec{z}}{\partial \text{Vec}(W)} = \begin{pmatrix} \sigma(a_1)(1 - \sigma(a_1))\vec{x}^\top & \vec{0}^\top & \dots & \vec{0}^\top \\ \vec{0}^\top & \sigma(a_2)(1 - \sigma(a_2))\vec{x}^\top & \dots & \vec{0}^\top \\ \vdots & \vdots & \ddots & \vdots \\ \vec{0}^\top & \vec{0}^\top & \dots & \sigma(a_m)(1 - \sigma(a_m))\vec{x}^\top \end{pmatrix}.$$

主成分分析

主成分分析可以转化为计算半正定矩阵 $A^\top A$ 的最大特征值及其对应的特征向量。这个问题等价于

$$\max_{\|\vec{x}\|=1} \vec{x}^\top A^\top A \vec{x}.$$

将上述约束优化问题写成 Lagrange 问题:

$$L(\lambda, \vec{x}) = \vec{x}^\top A^\top A \vec{x} - \lambda (\vec{x}^\top \vec{x} - 1).$$

对 $\vec{x}$ 求导, 得到

$$\begin{aligned} \frac{\partial}{\partial \vec{x}} L(\lambda, \vec{x}) &= \frac{\partial}{\partial \vec{x}} (\vec{x}^\top A^\top A \vec{x} - \lambda (\vec{x}^\top \vec{x} - 1)) \\ &= 2A^\top A \vec{x} - 2\lambda \vec{x}. \end{aligned}$$

因此最优解 $\vec{x}^*$ 满足

$$A^\top A \vec{x}^* = \lambda \vec{x}^*,$$

即 $\vec{x}^*$ 一定是 $A^\top A$ 的一个特征向量。

设 $A^\top A$ 的特征值满足

$$\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_n,$$

对应的一组标准正交特征向量为 $\vec{\xi}_1, \dots, \vec{\xi}_n$ 。若

$$\vec{x} = \sum_{i=1}^n a_i \vec{\xi}_i,$$

则

$$\left(\sum_{i=1}^n a_i \vec{\xi}_i\right)^{\top} A^{\top} A \left(\sum_{i=1}^n a_i \vec{\xi}_i\right) = \sum_{i=1}^n a_i^2 \lambda_i.$$

又因为 $\|\vec{x}\| = 1$, 所以

$$\sum_{i=1}^n a_i^2 = 1.$$

故

$$\sum_{i=1}^n a_i^2 \lambda_i \leq \lambda_1.$$

因此最大值为 λ_1 , 最大值对应的 $\vec{x}^*$ 为 λ_1 的特征向量。