

第二十讲：非线性模型、分类与梯度下降优化

从线性模型到参数化模型族

给定训练数据 $\{(x_1, y_1), \dots, (x_n, y_n)\}$ ，其中 $x_i \in \mathbb{R}^d$ 为特征向量， y_i 为响应变量。最简单的做法是假设 x 与 y 之间存在线性关系：

$$f(x) = x^\top \beta. \quad (1)$$

最小二乘估计的目标是让预测值 $f(x_i)$ 与真实值 y_i 的误差平方和最小：

$$\min_{\beta} \sum_{i=1}^n (x_i^\top \beta - y_i)^2. \quad (2)$$

然而，当 x 与 y 之间的真实关系高度非线性时，线性模型的表达能力严重不足。此时我们通常引入一个参数化的模型族，通过选择合适的参数来拟合非线性模式。

定义 1 (参数化模型族) 设 θ 为参数向量，一个参数化模型族可以表示为

$$\mathcal{F} = \{f(x; \theta) \mid \theta \in \mathbb{R}^p\}. \quad (3)$$

通过调整 θ 来让模型尽可能拟合给定的数据。

例 1 (线性模型) 线性模型是参数化模型的最简单形式：

$$\mathcal{F}_{lin} = \{x^\top \beta + b \mid (\beta, b) \in \mathbb{R}^{d+1}\}. \quad (4)$$

此时参数 $\theta = (\beta, b)$ ，模型关于参数是线性的。

例 2 (核方法模型) 使用核函数 $k(\cdot, \cdot)$ 的模型可以写成

$$\mathcal{F}_{kernel} = \left\{ \sum_{i=1}^n a_i k(x_i, x) \mid a_i \in \mathbb{R} \right\}. \quad (5)$$

常用的径向基核 (RBF) 定义为

$$k(x_i, x) = \exp \left\{ -\frac{\|x_i - x\|^2}{2\sigma^2} \right\}. \quad (6)$$

核方法通过数据点处的基函数展开来描述非线性关系。

例 3 (深度神经网络) 深度神经网络是更强大的非线性参数化模型：

$$f(x; \theta) = \sigma_L(W_L \sigma_{L-1}(\dots \sigma_1(W_1 x + b_1) \dots) + b_L). \quad (7)$$

其中每一层的参数 (W_ℓ, b_ℓ) 需要被优化， σ_ℓ 是非线性激活函数（如 *ReLU*、*Sigmoid* 等）。

无论模型形式如何，我们通常希望找到参数 θ ，使得模型在整个数据集上的某种损失最小。

回归与分类的目标函数

回归任务：最小二乘损失

对于连续取值的 y （回归任务），最常用的损失是平方损失：

$$L(\theta) = \frac{1}{2} \sum_{i=1}^n (f(x_i; \theta) - y_i)^2. \quad (8)$$

这里加上因子 $1/2$ 是为了求导后形式简洁。

分类任务：交叉熵损失

当 y_i 为离散标签（例如二分类 $y_i \in \{0, 1\}$ ）时，我们不再直接拟合 y_i 的值，而是用模型拟合条件概率 $p(y | x)$ 。对于二分类问题，最常用的模型是 logistic 回归：

$$p(y = 1 | x; \theta) = \frac{1}{1 + e^{-\theta^T x}} \triangleq \sigma(\theta^T x), \quad (9)$$

其中 $\sigma(\cdot)$ 是 sigmoid 函数。其图像如图 1 所示。




图 1 Sigmoid 函数将任意实数压缩到 $(0, 1)$ 区间，可以解释为概率。

有时我们会引入一个尺度参数 $\lambda > 0$ ，定义带温度系数的 sigmoid 函数：

$$\sigma_\lambda(z) = \frac{1}{1 + e^{-\lambda z}}. \quad (10)$$

当 λ 增大时，函数在 $z = 0$ 附近的过渡带变窄。特别地，当 $\lambda \rightarrow +\infty$ 时， $\sigma_\lambda(z)$ 逐点收敛到阶跃函数（符号函数）：

$$\lim_{\lambda \rightarrow +\infty} \sigma_\lambda(z) = \begin{cases} 0, & z < 0, \\ \frac{1}{2}, & z = 0, \\ 1, & z > 0. \end{cases} \quad (11)$$

这一极限特性使得带温度系数的 sigmoid 可以用于“软”分类到“硬”分类的连续过渡，在知识蒸馏、对抗训练等场景中有重要应用。

对于训练数据，极大似然估计给出损失函数为负对数似然（即交叉熵损失）：

$$L(\theta) = - \sum_{i=1}^n \left[y_i \log p(y = 1 | x_i) + (1 - y_i) \log(1 - p(y = 1 | x_i)) \right]. \quad (12)$$

直观上，当真实标签 $y_i = 1$ 时，我们希望 $p(y = 1 | x_i)$ 尽可能大；当 $y_i = 0$ 时，希望 $p(y = 1 | x_i)$ 尽可能小，从而让负对数似然值降低。

因此，无论是回归还是分类，我们最终都需要求解如下优化问题：

$$\min_{\theta} L(\theta) = \frac{1}{n} \sum_{i=1}^n l_i(\theta), \quad (13)$$

其中 $L(\theta)$ 是依赖于数据的损失函数， $l_i(\theta)$ 是每一个数据上的损失，如 $((x^T \beta - y)^2)$ 。

如何优化上述目标？

梯度下降法

对于可微的损失函数 $L(\theta)$ ，最基础的优化算法是梯度下降 (Gradient Descent, GD)。迭代格式为

$$\theta_{t+1} = \theta_t - \eta \cdot \nabla L(\theta_t), \quad (14)$$

其中 $\eta > 0$ 称为学习率。其思想是沿着负梯度方向（函数下降最快的方向）更新参数。

梯度下降的局部展开解释

梯度下降可以从 Taylor 展开的角度理解：在 θ_t 附近对 $L(\theta)$ 做一阶展开，并加上一个二阶近似的正则项：

$$L(\theta) \approx L(\theta_t) + \langle \nabla L(\theta_t), \theta - \theta_t \rangle + \frac{1}{2\eta} \|\theta - \theta_t\|^2. \quad (15)$$

这里将二阶项近似为 $\frac{1}{2\eta} I$ 倍的单位矩阵。上式关于 θ 是强凸二次函数，其极小点恰好就是 $\theta_{t+1} = \theta_t - \eta \nabla L(\theta_t)$ 。可见梯度下降每一步是在当前点用一个简单的二次代理模型来指导更新。

例 4 (一维二次函数) 设 $L(\theta) = \theta^2$ ，则 $\nabla L(\theta) = 2\theta$ 。梯度下降迭代为

$$\theta_{t+1} = \theta_t - \eta \cdot 2\theta_t = (1 - 2\eta)\theta_t. \quad (16)$$

当 $0 < \eta < 1$ 时， $\theta_t \rightarrow 0$ ，即收敛到全局最小点。




图 2 梯度下降在一维二次函数上的迭代示意图。

随机梯度下降 (SGD)

当数据量 n 很大时，每次计算完整的梯度 $\nabla L(\theta) = \frac{1}{n} \sum_{i=1}^n \nabla \ell_i(\theta)$ 需要 $O(nd)$ 的计算量， d 为参数规模，代价过高。随机梯度下降 (Stochastic Gradient Descent, SGD) 每次随机选择一个样本 i_t ，用该样本的梯度代替完整梯度：

$$\theta_{t+1} = \theta_t - \gamma \cdot \nabla \ell_{i_t}(\theta_t), \quad (17)$$

其中 $\nabla \ell_{i_t}(\theta_t)$ 是单个数据点的损失梯度。单步更新的复杂度为 $O(d)$ ，与样本总量 n 无关。

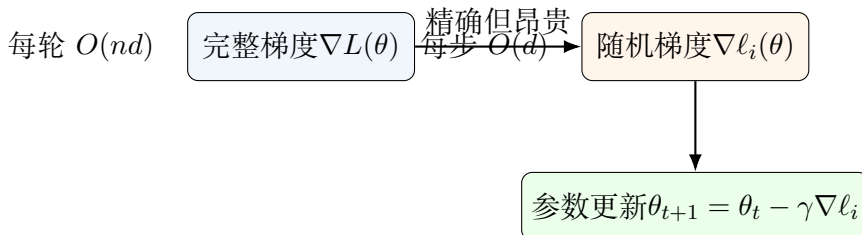


图 3 随机梯度下降与完整梯度下降的对比：SGD 每次只用单个样本的梯度进行更新，计算量大幅降低。

SGD 的梯度是真实梯度的无偏估计：

$$\mathbb{E}[\nabla \ell_i(\theta)] = \nabla L(\theta). \quad (18)$$

虽然每次更新带有随机噪声，但经过多次迭代，参数 θ 同样能够趋近于最优解。由于现代数据集规模巨大，SGD 及其变种（如 Adam、RMSprop 等）已成为深度学习模型训练的默认算法。

小结

本次课程从线性模型的局限性出发，引出了参数化模型族（核方法、神经网络等）来处理非线性关系。针对回归和分类任务分别介绍了最小二乘损失和交叉熵损失，并指出两者都可以归结为关于参数 θ 的优化问题。随后详细讲解了梯度下降的基本原理——利用局部 Taylor 展开构造代理模型并迭代更新；最后讨论了在大数据场景下随机梯度下降的动机和基本形式。梯度下降和随机梯度下降是几乎所有现代机器学习模型（尤其是深度神经网络）训练过程中的核心优化引擎。