

高等代数 II 习题集

evilayuria 2025999999

2026 年 8 月 17 日

目录

1 二次型与对称矩阵、正定性	2
2 二次型的标准形、惯性指数与正定判别	3
3 双线性型、Gram 矩阵与对称双线性型	4
4 线性映射与线性变换、核与像、矩阵表示	5
5 秩—零化度定理、基变换与相似矩阵、可对角化判定	6
6 子空间的直和、维数公式与对称/反对称分解	7
7 不变子空间与分块矩阵	8
8 赋范向量空间、Banach 不动点定理与算子范数	9
9 主成分分析 (PCA): 特征值分解与低秩近似	10
10 PCA 与协方差矩阵、方差最大化与主成分方向	11
11 奇异值分解 (SVD)、奇异值与低秩近似	12
12 SVD 与四个基本子空间、极分解与数值稳定性	13
13 复矩阵与 Hermite 矩阵、酉对角化与 Fourier 矩阵	14
14 Hermite 正定矩阵、伴随算子与复内积空间	15
15 Fourier 变换与 FFT: 蝶形算法、多项式插值与复杂度分析	16
16 矩阵微积分: 向量/矩阵求导、迹的导数与行列式求导	17
17 正规方程、Sigmoid 导数与 PCA 的 Lagrange 对偶	18
18 Moore–Penrose 广义逆与最小二范数解	19
19 人工神经元: 前向计算、激活函数与梯度消失	20

目录	2
20 全连接网络：结构、参数量、前向计算与 Softmax 回归	21
21 ReLU 激活模式、仿射映射、卷积参数量与 Softmax 梯度	22
22 反向传播、自动微分与一维卷积的矩阵形式	24

1 二次型与对称矩阵、正定性

Problem 1

给定二次型

$$Q(x_1, x_2, x_3) = 2x_1^2 + 3x_2^2 + x_3^2 + 4x_1x_2 - 2x_1x_3 + 6x_2x_3.$$

写出其对应的对称矩阵.

Problem 2

判断下列二次型的正定性:

1. $Q_1(x, y) = x^2 + 2xy + 2y^2$,
2. $Q_2(x, y, z) = x^2 + y^2 + z^2 - xy - xz - yz$.

Problem 3

设 $f(\mathbf{x}) = \mathbf{x}^\top A \mathbf{x}$, 定义双线性形

$$g(\mathbf{x}, \mathbf{y}) = \frac{1}{2} [f(\mathbf{x} + \mathbf{y}) - f(\mathbf{x}) - f(\mathbf{y})].$$

若

$$A = \begin{bmatrix} 2 & 1 \\ 1 & 3 \end{bmatrix},$$

求 $g(\mathbf{e}_1, \mathbf{e}_2)$, 其中 $\mathbf{e}_1 = (1, 0)^\top$, $\mathbf{e}_2 = (0, 1)^\top$.

Problem 4

将二次型

$$Q(x, y) = 2x^2 + 4xy + 5y^2$$

化为标准形, 并写出所用的可逆变换矩阵 P .

2 二次型的标准形、惯性指数与正定判别

Problem 1

将

$$Q(\mathbf{x}) = x_1^2 + 2x_2^2 + 3x_3^2 + 2x_1x_2 + 4x_1x_3 + 2x_2x_3$$

化为标准形.

Problem 2

设

$$Q(x_1, x_2, x_3) = ax_1^2 + bx_2^2 + cx_3^2 + 2ax_1x_2 + 2bx_1x_3 + 2cx_2x_3,$$

求 a, b, c 满足什么条件时 Q 为正定二次型.

Problem 3

设

$$Q(\mathbf{x}) = x_1^2 + 2x_2^2 + 3x_3^2 - 2x_1x_2 + 4x_2x_3$$

求其正负惯性指数.

Problem 4

设

$$A = \begin{bmatrix} 2 & -1 & 1 \\ -1 & 2 & -1 \\ 1 & -1 & 0 \end{bmatrix}$$

1. 构造 P 使 P^TAP 为标准形;
2. 求惯性指数;
3. 判断是否正定.

3 双线性型、Gram 矩阵与对称双线性型

Problem 1

设 $g: \mathbb{R}^2 \times \mathbb{R}^2 \rightarrow \mathbb{R}$ 定义为

$$g(\mathbf{x}, \mathbf{y}) = 2x_1y_1 + 3x_1y_2 - x_2y_1 + 4x_2y_2,$$

其中 $\mathbf{x} = (x_1, x_2)$, $\mathbf{y} = (y_1, y_2)$.

1. 写出 g 在标准基下的 Gram 矩阵 G ;
2. 判断 g 是否为对称双线性型.

Problem 2

设 V 是 2 维线性空间, 基为 $\{\mathbf{e}_1, \mathbf{e}_2\}$, 定义双线性型 g 满足

$$g(\mathbf{e}_1, \mathbf{e}_1) = 1,$$

$$g(\mathbf{e}_1, \mathbf{e}_2) = 2,$$

$$g(\mathbf{e}_2, \mathbf{e}_1) = 3,$$

$$g(\mathbf{e}_2, \mathbf{e}_2) = 4.$$

1. 写出 g 在基 $\{\mathbf{e}_1, \mathbf{e}_2\}$ 下的 Gram 矩阵;
2. 若新基 $\{\mathbf{f}_1, \mathbf{f}_2\}$ 满足 $\mathbf{f}_1 = \mathbf{e}_1 + \mathbf{e}_2$, $\mathbf{f}_2 = \mathbf{e}_1 - \mathbf{e}_2$, 求 g 在新基下的 Gram 矩阵.

Problem 3

设 $g(\mathbf{x}, \mathbf{y}) = \mathbf{x}^\top A \mathbf{y}$ 是 $\mathbb{R}^n$ 上的双线性型, A 为 $n \times n$ 矩阵. 证明: g 是对称双线性型, 当且仅当 A 是对称矩阵.

4 线性映射与线性变换、核与像、矩阵表示

Problem 1

定义映射 $\mathcal{T}: \mathbb{R}^3 \rightarrow \mathbb{R}^2$ 为

$$T(x_1, x_2, x_3) = (x_1 + 2x_2, 3x_2 - x_3)^T.$$

1. 证明: $\mathcal{T}$ 是线性映射;
2. 求 $\ker(\mathcal{T})$ 和 $\text{Im}(\mathcal{T})$ 的维数与一组基.

Problem 2

设 V 是 3 维线性空间, 基为 $\{\boldsymbol{v}_1, \boldsymbol{v}_2, \boldsymbol{v}_3\}$, 线性变换 $\mathcal{A}: V \rightarrow V$ 满足

$$\mathcal{A}(\boldsymbol{v}_1) = \boldsymbol{v}_1 + \boldsymbol{v}_2,$$

$$\mathcal{A}(\boldsymbol{v}_2) = \boldsymbol{v}_2 + \boldsymbol{v}_3,$$

$$\mathcal{A}(\boldsymbol{v}_3) = \boldsymbol{v}_1 + \boldsymbol{v}_3.$$

1. 写出 $\mathcal{A}$ 在基 $\{\boldsymbol{v}_1, \boldsymbol{v}_2, \boldsymbol{v}_3\}$ 下的矩阵表示;
2. 求 $\mathcal{A}$ 的像空间 $\text{Im}(\mathcal{A})$ 和核空间 $\ker(\mathcal{A})$ 的基.

Problem 3

设 $\mathcal{A}: \mathbb{R}^2 \rightarrow \mathbb{R}^2$ 是线性变换, 在标准基下的矩阵为

$$A = \begin{bmatrix} 1 & 2 \\ 0 & 3 \end{bmatrix}.$$

1. 求 $\mathcal{A}$ 的像空间 $\text{Im}(\mathcal{A})$ 和核空间 $\ker(\mathcal{A})$;
2. 判断 $\mathcal{A}$ 是否为单射、满射.

5 秩-零化度定理、基变换与相似矩阵、可对角化判定

Problem 1

给定线性映射 $T: \mathbb{R}^3 \rightarrow \mathbb{R}^3$, 其在标准基下对应的矩阵为

$$A = \begin{bmatrix} 1 & 2 & 3 \\ 2 & 4 & 6 \\ 1 & 2 & 3 \end{bmatrix}.$$

请计算矩阵 A 的秩 $\text{rank}(A)$, 并依此求出 T 的像空间维数 $\dim \text{Im}(\mathcal{T})$ 与核空间维数 $\dim \ker(\mathcal{T})$, 最后说明其计算结果是否满足秩零化度定理.

Problem 2

设线性变换 $T: \mathbb{R}^2 \rightarrow \mathbb{R}^2$ 定义为

$$T \begin{pmatrix} x_1 \\ x_2 \end{pmatrix} = \begin{pmatrix} 2x_1 + x_2 \\ x_1 + 2x_2 \end{pmatrix}.$$

1. 求 T 在标准基 $\mathbf{e}_1 = \begin{pmatrix} 1 \\ 0 \end{pmatrix}$, $\mathbf{e}_2 = \begin{pmatrix} 0 \\ 1 \end{pmatrix}$ 下对应的矩阵 A ;
2. 给定新基 (已固定顺序)

$$\tilde{\mathbf{e}}_1 = \begin{pmatrix} 1 \\ 1 \end{pmatrix}, \quad \tilde{\mathbf{e}}_2 = \begin{pmatrix} -1 \\ 1 \end{pmatrix},$$

求从标准基到新基的过渡矩阵 P , 并计算 T 在该新基下对应的矩阵 B .

Problem 3

设矩阵

$$A = \begin{bmatrix} 4 & -2 \\ 1 & 1 \end{bmatrix}.$$

求矩阵 A 的所有特征值. 对于每一个特征值, 求其对应的特征子空间的维数 (即几何重数), 并据此判断矩阵 A 是否可对角化.

6 子空间的直和、维数公式与对称/反对称分解

Problem 1

在 $\mathbb{R}^3$ 中, 设子空间 W_1 由方程 $x + y - z = 0$ 确定, 子空间 W_2 由方程 $x - y = 0$ 确定. 请分别计算子空间 W_1 、 W_2 以及交空间 $W_1 \cap W_2$ 的维数, 并利用维数公式求和空间 $W_1 + W_2$ 的维数.

Problem 2

设 $\mathbb{R}^4$ 中的两个子空间分别为

$$U = \text{span} \left\{ (1, 0, 0, 0)^\top, (0, 1, 0, 0)^\top \right\},$$

$$V = \text{span} \left\{ (1, 1, 1, 1)^\top, (0, 0, 1, 1)^\top \right\}.$$

请通过计算维数 $\dim(U + V)$, 来判断 $U + V$ 是否为直和 (即判断是否满足 $U \oplus V$).

Problem 3

已知 n 阶方阵空间 $V = \mathbb{R}^{n \times n}$ 可以分解为对称矩阵子空间 W_1 与反对称矩阵子空间 W_2 的直和 (即 $V = W_1 \oplus W_2$). 给定矩阵

$$A = \begin{bmatrix} 1 & 2 & 4 \\ 4 & 5 & 6 \\ 2 & 8 & 9 \end{bmatrix},$$

请利用直和分解的性质, 求出唯一确定的对称矩阵 $S \in W_1$ 和反对称矩阵 $K \in W_2$, 使得 $A = S + K$.

7 不变子空间与分块矩阵

Problem 1

设线性变换 $\mathcal{A} : \mathbb{R}^3 \rightarrow \mathbb{R}^3$ 的矩阵为

$$A = \begin{bmatrix} 2 & 1 & 0 \\ 0 & 2 & 0 \\ 0 & 0 & 3 \end{bmatrix}.$$

判断下列子空间是否为 $\mathcal{A}$ 的不变子空间，并说明理由：

$$W_1 = \text{span}\{(1, 0, 0)^\top\}, \quad W_2 = \text{span}\{(1, 0, 0)^\top, (0, 1, 0)^\top\}, \quad W_3 = \text{span}\{(1, 1, 0)^\top\}.$$

Problem 2

设

$$A = \begin{bmatrix} A_1 & A_2 \\ O & A_3 \end{bmatrix}$$

为 n 阶分块矩阵，其中 A_1 为 r 阶方阵。证明子空间

$$W_1 = \left\{ (\alpha_1, \dots, \alpha_r, 0, \dots, 0)^\top : \alpha_i \in \mathbb{R} \right\}$$

是 A 的不变子空间；并证明

$$W_2 = \left\{ (0, \dots, 0, \beta_{r+1}, \dots, \beta_n)^\top : \beta_j \in \mathbb{R} \right\}$$

是 A 的不变子空间当且仅当 $A_2 = O$ 。

8 赋范向量空间、Banach 不动点定理与算子范数

Problem 1

在 $\mathbb{R}^2$ 上定义无穷范数

$$\|(x, y)\|_{\infty} = \max\{|x|, |y|\}.$$

设映射 $\mathcal{T}: \mathbb{R}^2 \rightarrow \mathbb{R}^2$ 定义为

$$\mathcal{T}(x, y) = \left(\frac{1}{4}x + \frac{1}{2}y + 1, \frac{1}{3}x + \frac{1}{6}y - 2 \right)^{\top}.$$

证明 $\mathcal{T}$ 是压缩映射，并求其唯一不动点。

Problem 2

设 $\mathcal{T}: \mathbb{R} \rightarrow \mathbb{R}$ 定义为

$$\mathcal{T}(x) = \frac{1}{2} \cos x.$$

证明方程

$$x = \frac{1}{2} \cos x$$

有唯一实根，并说明迭代

$$x_{n+1} = \mathcal{T}(x_n)$$

对任意初值 $x_0 \in \mathbb{R}$ 都收敛到该实根。

Problem 3

设

$$A = \begin{bmatrix} 1 & 2 \\ 2 & 4 \end{bmatrix}.$$

在 $\mathbb{R}^2$ 中取 Euclid 范数 $\|\cdot\|_2$ ，求算子范数 $\|A\|_2$ 。

Problem 4

考虑初值问题

$$y'(x) = y(x), \quad y(0) = 1.$$

将其改写为积分方程

$$y(x) = 1 + \int_0^x y(t) \, dt.$$

在区间 $[0, a]$ 上的连续函数空间 $C[0, a]$ 中取范数

$$\|y\|_{\infty} = \max_{x \in [0, a]} |y(x)|.$$

定义算子

$$(Ay)(x) = 1 + \int_0^x y(t) \, dt.$$

证明当 $0 < a < 1$ 时， A 为压缩映射，从而该初值问题在 $C[0, a]$ 中有唯一解。

9 主成分分析 (PCA): 特征值分解与低秩近似

Problem 1

已知矩阵

$$A = \begin{bmatrix} 1 & 2 & 3 \\ 2 & 4 & 6 \\ 1 & 2 & 3 \end{bmatrix}.$$

该矩阵的各行之间存在明显的倍数关系，因此可以用低秩形式表示。

1. 将矩阵 A 写成外积形式

$$A = \mathbf{u}\mathbf{v}^\top.$$

2. 求矩阵 A 的秩。
3. 若直接存储矩阵 A 需要存储全部 3×3 个元素，而采用外积形式时只需存储向量 $\mathbf{u}$ 和 $\mathbf{v}$ 的全部分量，求：
 - (a) 原矩阵的存储量；
 - (b) 外积表示下的存储量；
 - (c) 传输效率提升倍数（定义为压缩前存储量 / 压缩后存储量）。

Problem 2

设对称矩阵

$$A = \begin{bmatrix} 3 & 1 \\ 1 & 3 \end{bmatrix}.$$

利用特征值分解研究该矩阵的低秩近似。

1. 求矩阵 A 的全部特征值及对应的单位特征向量；
2. 写出矩阵 A 的特征值分解形式；
3. 取最大特征值所对应的一项，写出矩阵 A 的最佳秩 1 近似矩阵 $\hat{A}$ 。

Problem 3

设对称矩阵

$$A = \begin{bmatrix} 2 & 1 & 0 \\ 1 & 2 & 0 \\ 0 & 0 & 1 \end{bmatrix}$$

1. 求矩阵 A 的全部特征值及对应的一组单位特征向量；
2. 按特征值从大到小排序，并写出前三个主成分方向；
3. 设 $\hat{A}_k$ 为保留前 k 个主成分得到的近似矩阵，判断当误差要求

$$\|A - \hat{A}_k\| \leq 1$$

时，至少需要保留几个主成分。

10 PCA 与协方差矩阵、方差最大化与主成分方向

Problem 1

给定数据矩阵

$$X = \begin{bmatrix} 1 & 2 & 3 & 4 \\ 2 & 1 & 0 & 3 \end{bmatrix}$$

1. 求两个特征的样本均值，并写出中心化后的数据矩阵 $\tilde{X}$ ；
2. 求 $\tilde{X}\tilde{X}^\top$ 的第一主成分方向。

Problem 2

设随机向量 $\mathbf{x}$ 的协方差矩阵为

$$\Sigma = \begin{bmatrix} 5 & 2 \\ 2 & 2 \end{bmatrix}.$$

1. 证明

$$\text{Var}(\mathbf{a}^\top \mathbf{x}) = \mathbf{a}^\top \Sigma \mathbf{a}.$$

2. 在约束 $\|\mathbf{a}\| = 1$ 下，求使方差最大的方向。
3. 写出最大方差，并说明其所对应方向的意义。

Problem 3

设协方差矩阵

$$\Sigma = \begin{bmatrix} 4 & 1 & 0 \\ 1 & 4 & 0 \\ 0 & 0 & 1 \end{bmatrix}.$$

1. 求 Σ 的全部特征值及对应的一组单位特征向量。
2. 求前 1 个、前 2 个主成分捕获的总方差。
3. 计算前 1 个、前 2 个主成分的方差解释比例，并说明其意义。

11 奇异值分解 (SVD)、奇异值与低秩近似

Problem 1

设矩阵

$$A = \begin{bmatrix} 3 & 0 \\ 0 & 2 \\ 0 & 0 \end{bmatrix}.$$

1. 计算 $A^T A$, 求其特征值与单位特征向量, 写出 A 的奇异值 $\sigma_1 > \sigma_2$ 及右奇异向量 $\mathbf{v}_1, \mathbf{v}_2$ 。
2. 利用公式

$$\mathbf{u}_i = \frac{A\mathbf{v}_i}{\sigma_i},$$

求左奇异向量 $\mathbf{u}_1, \mathbf{u}_2$, 并将其补全为 $\mathbb{R}^3$ 的标准正交基。

3. 写出 A 的奇异值分解 $A = U\Sigma V^T$ 。

Problem 2

设矩阵

$$A = \begin{bmatrix} 3 & 0 \\ 0 & 1 \end{bmatrix}.$$

1. 直接写出 A 的 SVD (该矩阵已是对角形式, 奇异值即对角元)。
2. 利用谱范数定义

$$\|A\|_2 = \sup_{x \neq 0} \frac{\|Ax\|_2}{\|x\|_2},$$

证明 $\|A\|_2 = \sigma_1 = 3$ 。

3. 写出 A 的秩 - 1 近似 A_1 , 计算 $\|A - A_1\|_2$ 。

Problem 3

设矩阵

$$A = \begin{bmatrix} 3 & 0 & 0 \\ 0 & 2 & 0 \\ 0 & 0 & 1 \end{bmatrix},$$

其奇异值为

$$\sigma_1 = 3, \quad \sigma_2 = 2, \quad \sigma_3 = 1.$$

1. 写出 A 的秩 - 1 近似 A_1 与秩 - 2 近似 A_2 , 分别计算近似误差 $\|A - A_1\|_2$ 与 $\|A - A_2\|_2$ 。
2. 由 Eckart - Young 定理, A_1 是 A 的最优秩 - 1 近似。若另取秩 - 1 矩阵

$$B = 3\mathbf{e}_1\mathbf{e}_2^T,$$

其中 $\mathbf{e}_1, \mathbf{e}_2$ 为标准基向量, 计算 $\|A - B\|_2$ 并验证其不小于 $\|A - A_1\|_2$ 。

12 SVD 与四个基本子空间、极分解与数值稳定性

Problem 1

设矩阵

$$A = \begin{bmatrix} 1 & 2 \\ 2 & 4 \end{bmatrix}.$$

1. 求 A 的秩, 以及列空间 $C(A)$ 与零空间 $N(A)$ 各自的一组基。
2. 对 A 进行 SVD, 在该矩阵的 SVD 中, 说明非零奇异值对应的左、右奇异向量分别张成哪个基本子空间; 补齐后的其余左、右奇异向量又分别张成哪个基本子空间。
3. 将向量 $\mathbf{x} = (3, 1)^\top$ 分解为行空间分量与零空间分量之和, 即写出 $\mathbf{x} = \mathbf{x}_R + \mathbf{x}_N$ 。

Problem 2

设矩阵

$$A = \begin{bmatrix} 0 & -1 \\ 2 & 0 \end{bmatrix}.$$

1. 对 A 进行 SVD, 求 U, Σ, V 。
2. 由 SVD 写出极分解 $A = QS$, 其中 $Q = UV^\top$, $S = V\Sigma V^\top$, 明确给出 Q 和 S 的数值。
3. 验证 S 是对称半正定矩阵, 并说明 S 的特征值与 A 的奇异值有何关系。

Problem 3

设矩阵

$$A = \begin{bmatrix} 0 & 2 \\ 0 & 0 \end{bmatrix}, \quad A_\varepsilon = \begin{bmatrix} 0 & 2 \\ \varepsilon & 0 \end{bmatrix}, \quad \varepsilon > 0.$$

1. 计算 A 的全部特征值; 再计算 A_ε 的特征值, 说明当 ε 很小时特征值的变化情况。
2. 分别计算 $A^\top A$ 与 $A_\varepsilon^\top A_\varepsilon$ 的特征值, 写出 A 与 A_ε 各自的奇异值, 比较二者的差异。
3. 综合以上结果, 说明奇异值相比特征值具有更好数值稳定性的原因。

13 复矩阵与 Hermite 矩阵、酉对角化与 Fourier 矩阵

Problem 1

设

$$A = \begin{bmatrix} 3 & 2 - i \\ 2 + i & 7 \end{bmatrix}.$$

1. 证明 A 是 Hermite 矩阵。
2. 求 A 的特征值与对应的特征向量。
3. 求酉矩阵 U 使得 $U^H A U$ 为对角矩阵，并写出该对角矩阵。

Problem 2

设 A 为 n 阶 Hermite 矩阵。证明：

1. $I + iA$ 可逆。
2. 矩阵 $U = (I - iA)(I + iA)^{-1}$ 是酉矩阵。

Problem 3

设 F_4 为 4 阶 Fourier 矩阵。

1. 写出 F_4 的具体形式（即写出每个元素）；
2. 证明 F_4 是酉矩阵；
3. 计算 $F_4 \mathbf{v}$ ，其中 $\mathbf{v} = (1, i, -1, -i)^T$ 。

14 Hermite 正定矩阵、伴随算子与复内积空间

Problem 1

设

$$A = \begin{bmatrix} 1 & 1+i \\ 1-i & 3 \end{bmatrix}.$$

1. 证明 A 是 Hermite 正定矩阵。
2. 求可逆矩阵 P 使得 $P^H A P = I$ 。
3. 写出 A 对应的 Hermite 二次型 $H(\mathbf{x}) = \mathbf{x}^H A \mathbf{x}$ 在某组新基下的标准形。

Problem 2

设 M 是 $m \times n$ 的复矩阵。证明：

1. $M^H M$ 是 Hermite 半正定矩阵。
2. $M^H M$ 是正定矩阵当且仅当 M 的列向量线性无关。
3. 任意 Hermite 正定矩阵 A 都可以写成 $A = B^H B$ ，其中 B 是某可逆矩阵。

Problem 3

设 V 为有限维复内积空间（内积为 Hermite 内积）， $\mathcal{A}, \mathcal{B}$ 为 V 上的线性算子， $\mathcal{A}^*, \mathcal{B}^*$ 分别为其伴随算子。证明：

1. $(\mathcal{A}\mathcal{B})^* = \mathcal{B}^* \mathcal{A}^*$ 。
2. 若 λ 为 $\mathcal{A}$ 的特征值，则 $\bar{\lambda}$ 是 $\mathcal{A}^*$ 的特征值。
3. 若 $\mathcal{A}$ 是 Hermite 算子（即 $\mathcal{A}^* = \mathcal{A}$ ）且可逆，则 $\mathcal{A}^{-1}$ 也是 Hermite 算子。

15 Fourier 变换与 FFT: 蝶形算法、多项式插值与复杂度分析

Problem 1

设 $\omega_n = e^{-2\pi i/n}$ 为 n 次单位根。请证明: 对任意整数 $a, b \in \{0, 1, \dots, n-1\}$,

$$\sum_{k=0}^{n-1} \omega_n^{(a-b)k} = \begin{cases} n, & a = b, \\ 0, & a \neq b. \end{cases}$$

并由此推出 n 阶 Fourier 矩阵

$$F_n = \left(\omega_n^{jk} \right)_{j,k=0}^{n-1}$$

满足

$$F_n^H F_n = nI_n, \quad F_n^{-1} = \frac{1}{n} F_n^H.$$

Problem 2

取 $n = 4$, $\omega_4 = e^{-2\pi i/4} = -i$ 。设输入向量

$$\mathbf{x} = (1, 2, 3, 4)^\top.$$

1. 直接利用 Fourier 矩阵 F_4 计算 $\mathbf{y} = F_4 \mathbf{x}$ 。
2. 用 FFT 的蝶形分解 (即先分别计算偶数项 (x_0, x_2) 与奇数项 (x_1, x_3) 的 2 点 DFT, 再用旋转因子合并) 重新计算 $\mathbf{y}$, 并核对两种方法结果一致。

Problem 3

设次数小于 n 的多项式

$$p(z) = x_0 + x_1 z + x_2 z^2 + \cdots + x_{n-1} z^{n-1},$$

记 $\omega_n = e^{-2\pi i/n}$ 。

1. 证明 $\mathbf{y} = F_n \mathbf{x}$ 的第 j 个分量恰为 $y_j = p(\omega_n^j)$, 即 DFT 是把多项式从“系数表示”转为“在 n 次单位根处的点值表示”。
2. 设 $n = 2m$ 。把 $p(z)$ 按偶、奇次项拆分为

$$p(z) = p_e(z^2) + zp_o(z^2),$$

利用 $\omega_{2m}^2 = \omega_m$ 与 $\omega_{2m}^m = -1$ 推导 FFT 的蝶形合并公式

$$y_j = p_e(\omega_m^j) + \omega_{2m}^j p_o(\omega_m^j), \quad y_{j+m} = p_e(\omega_m^j) - \omega_{2m}^j p_o(\omega_m^j),$$

其中 $j = 0, 1, \dots, m-1$ 。

3. 写出递推式 $T(n) = 2T(n/2) + O(n)$ 的解, 并说明 FFT 相比直接计算 DFT 在复杂度上的优势。

16 矩阵微积分：向量/矩阵求导、迹的导数与行列式求导

Problem 1

设 $\mathbf{a}, \mathbf{b} \in \mathbb{R}^n$ 为常向量, $A \in \mathbb{R}^{n \times n}$ 为常矩阵 (不必对称), $\mathbf{x} \in \mathbb{R}^n$. 计算下列各式对 $\mathbf{x}$ 的导数:

1. $f_1(\mathbf{x}) = \mathbf{a}^\top \mathbf{x}$;
2. $f_2(\mathbf{x}) = \mathbf{x}^\top A \mathbf{x}$ (A 不必对称);
3. $f_3(\mathbf{x}) = (\mathbf{a}^\top \mathbf{x})(\mathbf{b}^\top \mathbf{x})$.

Problem 2

设 $X \in \mathbb{R}^{n \times n}$ 为可逆矩阵, A, B 为常矩阵, 使下列各式有意义。利用矩阵求导的链式法则及行列式求导公式, 计算:

1. $\frac{\partial}{\partial X} \ln \det(X)$ (不假设 X 对称);
2. $\frac{\partial}{\partial X} \ln \det(AXB)$ (设 AXB 可逆);
3. 验证当 X 为对称可逆矩阵时,

$$\frac{\partial}{\partial X} \ln \det(X) = 2X^{-1} - \text{diag}(X^{-1}).$$

Problem 3

设 $X \in \mathbb{R}^{n \times m}$, $A \in \mathbb{R}^{m \times m}$, $B \in \mathbb{R}^{n \times n}$ 均为常矩阵。利用 $\frac{\partial \text{tr}(\cdot)}{\partial X}$ 的求导技巧, 证明:

1. $\frac{\partial}{\partial X} \text{tr}(XAX^\top) = X(A + A^\top)$;
2. $\frac{\partial}{\partial X} \text{tr}(X^\top BXA) = BXA + B^\top XA^\top$;
3. 作为 (2) 的应用, 设 B 对称且 $X^\top BX$ 可逆, 证明

$$\frac{\partial}{\partial X} \ln \det(X^\top BX) = 2BX(X^\top BX)^{-1}.$$

17 正规方程、Sigmoid 导数与 PCA 的 Lagrange 对偶

Problem 1

在多元线性回归中，假设设计矩阵 X 列满秩。为了极小化最小二乘目标函数

$$\|X\boldsymbol{\beta} - \mathbf{y}\|^2,$$

请推导参数 $\boldsymbol{\beta}$ 的最优解所满足的正规方程 (Normal Equation)。

Problem 2

在单层神经网络

$$\mathbf{z} = \sigma(W\mathbf{x} + \mathbf{b})$$

中，设激活函数为 Sigmoid 函数

$$\sigma(t) = \frac{1}{1 + e^{-t}}.$$

请推导导数 $\sigma'(t)$ ，并将其恒等变形为仅包含 $\sigma(t)$ 的表达式。

Problem 3

在主成分分析 (PCA) 中，求解半正定矩阵 $A^\top A$ 的最大特征值问题等价于求解约束优化问题

$$\max_{\|\mathbf{x}\|=1} \mathbf{x}^\top A^\top A \mathbf{x}.$$

请利用拉格朗日 (Lagrange) 乘子法证明：该优化问题的最大值即为矩阵 $A^\top A$ 的最大特征值 λ_1 。

18 Moore-Penrose 广义逆与最小二范数解

Problem 1

已知矩阵

$$A = \begin{bmatrix} 1 & 1 \\ 1 & -1 \\ 1 & 0 \end{bmatrix}.$$

由于矩阵 A 列满秩, 其 Moore-Penrose 广义逆 A^+ 可以通过公式

$$A^+ = (A^T A)^{-1} A^T$$

来计算。请写出详细的计算过程, 求出 A^+ 。

Problem 2

假设线性方程组 $A\mathbf{x} = \mathbf{b}$ 有解。利用广义逆的通解性质可知, 该方程组的解可以统一表示为

$$\mathbf{x} = A^+ \mathbf{b} + (I - A^+ A) \mathbf{z},$$

其中 $\mathbf{z}$ 为任意向量, 且 A^+ 为 A 的 Moore-Penrose 广义逆。请证明:

$$\mathbf{x}^* = A^+ \mathbf{b}$$

是该方程组所有解中二范数 (模长) 最小的解。

Problem 3

已知 A^+ 是矩阵 A 的 Moore-Penrose 广义逆, 满足以下四条定义性质:

$$\begin{aligned} (1) \quad & AA^+A = A; & (2) \quad & A^+AA^+ = A^+; \\ (3) \quad & (AA^+)^T = AA^+; & (4) \quad & (A^+A)^T = A^+A. \end{aligned}$$

请利用上述四条性质, 证明 $(A^+)^T$ 也是 A^T 的 Moore-Penrose 广义逆, 从而得出结论

$$(A^T)^+ = (A^+)^T.$$

19 人工神经元：前向计算、激活函数与梯度消失

Problem 1

一个人工神经元的输入为

$$\mathbf{x} = (1, -2, 3)^\top, \quad \mathbf{w} = (2, -1, 0.5)^\top, \quad b = -1.$$

记净输入为 $z = \mathbf{w}^\top \mathbf{x} + b$ 。

1. 计算该神经元的净输入 z 。
2. 若激活函数为阶梯函数

$$h(z) = \begin{cases} 1, & z \geq 0, \\ 0, & z < 0, \end{cases}$$

求神经元输出。

3. 若激活函数分别为 $\text{ReLU}(z) = \max\{0, z\}$ 和 LeakyReLU ，其中

$$\text{LeakyReLU}(z) = \begin{cases} z, & z \geq 0, \\ 0.01z, & z < 0, \end{cases}$$

分别求神经元输出，并说明二者在 $z < 0$ 时的主要区别。

Problem 2

Logistic 激活函数定义为

$$\sigma(z) = \frac{1}{1 + \exp(-z)}.$$

已知其导数为 $\sigma'(z) = \sigma(z)(1 - \sigma(z))$ 。

1. 计算 $\sigma(0)$ 与 $\sigma'(0)$ 。
2. 近似计算 $\sigma(4), \sigma'(4), \sigma(-4), \sigma'(-4)$ 。可使用 $\exp(-4) \approx 0.0183$, $\exp(4) \approx 54.6$ 。
3. 根据以上结果，解释为什么 Logistic 激活函数在 $|z|$ 较大时容易导致梯度消失。

Problem 3

考虑一个使用 ReLU 激活函数的神经元

$$z = \mathbf{w}^\top \mathbf{x} + b, \quad a = \text{ReLU}(z),$$

设训练集中所有样本都满足 $\mathbf{x} \geq 0$ （逐分量非负）。

1. 写出 ReLU 的函数表达式及其在 $z \neq 0$ 处的导数。
2. 设 $\mathbf{w} = (-1, -2)^\top, b = 0$ ，对任意满足 $\mathbf{x} \geq 0$ 的样本，说明为什么有 $z \leq 0$ 。
3. 若某个神经元对所有训练样本都有 $z < 0$ ，说明其权重为什么难以通过梯度下降更新，并说明 LeakyReLU 为什么可以缓解这一问题。

20 全连接网络：结构、参数量、前向计算与 Softmax 回归

Problem 1

一个前馈全连接神经网络有输入层、一个隐藏层和输出层。输入维度为 $d = 4$ ，隐藏层神经元个数为 $n_1 = 3$ ，输出层神经元个数为 $n_2 = 2$ 。忽略偏置项时，前向传播为

$$\mathbf{a}^{(0)} = \mathbf{x}, \quad \mathbf{z}^{(1)} = W^{(1)}\mathbf{a}^{(0)}, \quad \mathbf{a}^{(1)} = \sigma_1(\mathbf{z}^{(1)}), \quad \mathbf{z}^{(2)} = W^{(2)}\mathbf{a}^{(1)}.$$

1. 写出 $W^{(1)}$ 与 $W^{(2)}$ 的维度。
2. 分别计算忽略偏置项时和加入偏置项时的参数总数。
3. 简要说明为什么全连接前馈网络中“相邻两层之间的神经元全部两两连接”会使参数量随层宽快速增大。

Problem 2

考虑一个一层隐藏层的前馈神经网络：

$$\mathbf{a}^{(0)} = \mathbf{x}, \quad \mathbf{z}^{(1)} = W^{(1)}\mathbf{x}, \quad \mathbf{a}^{(1)} = \text{ReLU}(\mathbf{z}^{(1)}), \quad \hat{\mathbf{y}} = W^{(2)}\mathbf{a}^{(1)},$$

其中

$$\mathbf{x} = \begin{pmatrix} 1 \\ -1 \end{pmatrix}, \quad W^{(1)} = \begin{bmatrix} 1 & 2 \\ -1 & 1 \\ 2 & 0 \end{bmatrix}, \quad W^{(2)} = \begin{bmatrix} 1 & -2 & 0.5 \end{bmatrix}.$$

1. 计算隐藏层净输入 $\mathbf{z}^{(1)}$ 。
2. 计算隐藏层输出 $\mathbf{a}^{(1)}$ 。
3. 计算网络输出 $\hat{\mathbf{y}}$ ；若真实标签为 $y = 2$ ，采用平方损失 $\ell = (\hat{y} - y)^2$ ，求该样本的损失值。

Problem 3

某三分类模型最后一层输出的 logits 为

$$\mathbf{z} = (1, 2, 0)^\top.$$

经过 softmax 后得到预测概率

$$\hat{y}_c = \frac{\exp(z_c)}{\sum_{j=1}^3 \exp(z_j)}, \quad c = 1, 2, 3.$$

设真实标签为第 2 类，即 $\mathbf{y} = (0, 1, 0)^\top$ 。

1. 写出 $\hat{\mathbf{y}} = \text{softmax}(\mathbf{z})$ 的各个分量表达式。
2. 取 $\exp(1) \approx 2.718$, $\exp(2) \approx 7.389$, $\exp(0) = 1$ ，近似计算 $\hat{\mathbf{y}}$ 。
3. 计算交叉熵损失

$$\ell(\mathbf{y}, \hat{\mathbf{y}}) = -\mathbf{y}^\top \log \hat{\mathbf{y}}.$$

并记 $\frac{\partial \ell}{\partial \mathbf{z}} = \hat{\mathbf{y}} - \mathbf{y}$ ，写出该样本对 logits 的梯度。

21 ReLU 激活模式、仿射映射、卷积参数量与 Softmax 梯度

Problem 1

在全连接神经网络中，ReLU 激活函数会将输入空间划分为若干个区域。在每一个固定的激活区域内，网络实际上退化为一个仿射映射。设一个两层全连接神经网络定义为

$$\mathbf{z}^{(1)} = W_1 \mathbf{x} + \mathbf{b}_1, \quad \mathbf{h} = \text{ReLU}(\mathbf{z}^{(1)}), \quad \mathbf{z}^{(2)} = W_2 \mathbf{h} + \mathbf{b}_2,$$

其中

$$W_1 = \begin{bmatrix} 1 & -1 \\ 2 & 1 \\ -1 & 2 \end{bmatrix}, \quad \mathbf{b}_1 = \begin{pmatrix} 0 \\ -1 \\ 1 \end{pmatrix}, \quad W_2 = \begin{bmatrix} 1 & 0 & 2 \\ -1 & 1 & 0 \end{bmatrix}, \quad \mathbf{b}_2 = \begin{pmatrix} 1 \\ 0 \end{pmatrix},$$

对输入

$$\mathbf{x} = \begin{pmatrix} 2 \\ 1 \end{pmatrix},$$

完成以下任务：

1. 计算 $\mathbf{z}^{(1)}$ 、 $\mathbf{h}$ 、 $\mathbf{z}^{(2)}$ 。
2. 判断该输入对应的 ReLU 激活模式。
3. 在该激活模式保持不变的区域内，写出网络对应的仿射映射。

Problem 2

全连接层的一个主要问题是参数量随输入维度迅速增长。卷积层通过局部连接和权重共享显著减少参数量。设输入是一张大小为 32×32 的 RGB 图像，即输入通道数为 3。

现在比较以下两种结构：

- 结构 A：将图像展平成向量后，接一个含有 1024 个神经元的全连接层。
- 结构 B：使用 16 个 3×3 的卷积核，步长为 1，无零填充。

假设所有层都含有偏置项。完成以下任务：

1. 计算结构 A 的参数量。
2. 计算结构 B 的参数量。
3. 计算结构 B 的输出特征图大小。
4. 若将结构 B 的输出展平后接一个 10 类分类器，计算该分类器的参数量。

Problem 3

在多分类任务中，神经网络通常先输出 logits，再通过 softmax 转化为类别概率。设一个三分类模型的 logits 由

$$\mathbf{z} = W\mathbf{x} + \mathbf{b}$$

给出，其中

$$W = \begin{bmatrix} 1 & 0 \\ 0 & 1 \\ -1 & 0 \end{bmatrix}, \quad \mathbf{b} = \begin{pmatrix} 0 \\ 0 \\ 0 \end{pmatrix}, \quad \mathbf{x} = \begin{pmatrix} 1 \\ 0 \end{pmatrix},$$

真实标签为第一类，即

$$\mathbf{y} = \begin{pmatrix} 1 \\ 0 \\ 0 \end{pmatrix}.$$

softmax 输出定义为

$$p_i = \frac{\exp(z_i)}{\sum_{j=1}^3 \exp(z_j)},$$

交叉熵损失函数为

$$L = - \sum_{i=1}^3 y_i \log p_i.$$

完成以下任务：

1. 计算 $\mathbf{z}$ 和 $\mathbf{p}$ 。
2. 计算损失 L 。
3. 利用 $\nabla_{\mathbf{z}} L = \mathbf{p} - \mathbf{y}$ ，计算 $\nabla_W L$ 和 $\nabla_{\mathbf{b}} L$ 。

22 反向传播、自动微分与一维卷积的矩阵形式

Problem 1

反向传播算法的核心思想是先计算高层误差，再将误差逐层传回低层。设一个两层线性网络为

$$\mathbf{h} = W_1 \mathbf{x}, \quad \hat{\mathbf{y}} = W_2 \mathbf{h},$$

其中

$$W_1 = \begin{bmatrix} 1 & 2 \\ 0 & -1 \end{bmatrix}, \quad W_2 = \begin{bmatrix} 1 & 0 \\ 2 & -1 \end{bmatrix}, \quad \mathbf{x} = \begin{pmatrix} 1 \\ -1 \end{pmatrix}, \quad \mathbf{y} = \begin{pmatrix} 0 \\ 1 \end{pmatrix}.$$

损失函数为

$$L = \frac{1}{2} \|\hat{\mathbf{y}} - \mathbf{y}\|_2^2.$$

完成以下任务：

1. 计算 $\mathbf{h}$ 、 $\hat{\mathbf{y}}$ 、 $\mathbf{e} = \hat{\mathbf{y}} - \mathbf{y}$ 。
2. 计算 $\nabla_{W_2} L$ 。
3. 计算 $\nabla_{W_1} L$ 。

Problem 2

自动微分可以看作是系统地应用链式法则。设计算图为

$$L = \mathbf{c}^\top \mathbf{v}, \quad \mathbf{v} = \tanh(\mathbf{u}), \quad \mathbf{u} = A\mathbf{x} + \mathbf{b},$$

其中

$$A = \begin{bmatrix} 1 & -1 \\ 0 & 2 \end{bmatrix}, \quad \mathbf{x} = \begin{pmatrix} 1 \\ 0 \end{pmatrix}, \quad \mathbf{b} = \begin{pmatrix} -1 \\ 0 \end{pmatrix}, \quad \mathbf{c} = \begin{pmatrix} 2 \\ -1 \end{pmatrix}.$$

这里 $\tanh$ 逐坐标作用于向量。完成以下任务：

1. 进行前向计算，求 $\mathbf{u}$ 、 $\mathbf{v}$ 、 L 。
2. 使用反向模式自动微分思想，求 $\nabla_{\mathbf{x}} L$ 、 $\nabla_A L$ 、 $\nabla_{\mathbf{b}} L$ 。

Problem 3

一维卷积或互相关可以看作是一个具有特殊稀疏结构的矩阵乘法。设一维输入信号为

$$\mathbf{x} = (x_1, x_2, x_3, x_4, x_5)^\top,$$

滤波器为

$$\mathbf{a} = (a_1, a_2, a_3)^\top.$$

采用步长为 1、无零填充的窄互相关运算：

$$y_i = a_1 x_i + a_2 x_{i+1} + a_3 x_{i+2}, \quad i = 1, 2, 3.$$

完成以下任务：

1. 将该运算写成 $\mathbf{y} = K\mathbf{x}$ 的矩阵形式。
2. 令 $\mathbf{a} = (1, 0, -1)^\top$, $\mathbf{x} = (2, 1, 3, 0, -2)^\top$, 计算 $\mathbf{y}$ 。
3. 若目标输出为 $\mathbf{t} = (0, 1, 3)^\top$, 损失函数为 $L = \frac{1}{2}\|\mathbf{y} - \mathbf{t}\|_2^2$, 求 $\nabla_{\mathbf{x}}L$ 和 $\nabla_{\mathbf{a}}L$ 。